

ΕΓΧΕΙΡΙΔΙΟ ΕΚΠΑΙΔΕΥΣΗΣ

TIME SERIES ANALYSIS

FROM ZERO TO HERO

ΤΕΥΧΟΣ Α΄

Θεμέλια · Εφαρμογές · Διερεύνηση Δεδομένων · Αποσύνθεση

Μέρη 1-4 του πλήρους προγράμματος

Επίπεδο: Απόλυτος αρχάριος → Στέρεο ενδιαμέσο

Έμφαση σε εφαρμογές φαρμακευτικής αγοράς & δημόσιας υγείας

Αύγουστος 2026

ΚΕΦΑΛΑΙΟ 0 — Πώς θα δουλέψουμε

Το αίτημά σου καλύπτει 29 ενότητες: από τον ορισμό της χρονοσειράς μέχρι VECM, GARCH, Temporal Fusion Transformers, παρουσίαση 40 διαφανειών και εξέταση. Αυτό **δεν χωράει σε ένα αρχείο** — ούτε πρέπει. Ένα εγχειρίδιο 400 σελίδων που διαβάζεται μία φορά είναι χειρότερο από πέντε τεύχη που τα δουλεύεις διαδοχικά.

Γι' αυτό το πρόγραμμα δομείται σε **έξι τεύχη**. Κάθε τεύχος είναι αυτοτελές, χτίζει πάνω στο προηγούμενο και κλείνει με έλεγχο κατανόησης.

Τεύχος	Μέρη	Περιεχόμενο	Τι θα μπορείς να κάνεις μετά
Α' (αυτό)	1-4	Βασικές έννοιες · Πεδία εφαρμογής · Data audit & γραφήματα · Decomposition (classical, STL)	Να «διαβάξεις» οπτικά μια σειρά, να εντοπίζεις trend/seasonality/breaks, να μην ξεκινάς ποτέ μοντέλο σε βρόμικα δεδομένα
Β'	5-8	Stationarity & unit roots (ADF/KPSS/PP) · Transformations · ACF/PACF · Baselines, ETS, ARIMA/SARIMA/SARIMAX	Να επιλέγεις και να εκτιμάς σωστά ένα univariate μοντέλο πρόβλεψης
Γ'	9-14	VAR/ARDL/VECM · Cointegration · Causality · Interrupted Time Series · Structural breaks · ARCH/GARCH	Να κάνεις πολυμεταβλητή και <i>causal</i> ανάλυση — το κομμάτι που αφορά άμεσα τη δουλειά σου σε policy evaluation
Δ'	15-20	Ειδικές σειρές (Croston, TBATS, counts) · ML & Deep Learning · Validation · Metrics · Model selection	Να αξιολογείς μοντέλα με time-aware backtesting και να μη σε ξεγελά το AIC
Ε'	21-26	Residual diagnostics · Uncertainty · Τα 20 λάθη · Decision tree · Master checklist · 5 case studies με κώδικα	Να τρέχεις πλήρη ανάλυση end-to-end μόνος σου
ΣΤ'	27-29	Παρουσίαση 30-40 slides (.pptx) · Exam mode · One-page cheat sheet	Να διδάξεις ή να παρουσιάσεις το αντικείμενο

Κανόνες που ισχύουν σε όλο το πρόγραμμα

Κάθε στατιστικός έλεγχος παρουσιάζεται με ρητή H_0 και H_1 . Κανένα «σοβαρό» μοντέλο δεν προτείνεται χωρίς benchmark. Καμία αξιολόγηση πρόβλεψης δεν γίνεται in-sample. Καμία αιτιακή διατύπωση χωρίς αιτιακό σχεδιασμό. Κάθε τεχνικός όρος εξηγείται πριν χρησιμοποιηθεί.

ΚΕΦΑΛΑΙΟ 1 — Τι ακριβώς είναι μια χρονοσειρά;

Ξεκινάμε από το απόλυτο μηδέν. Κάθε έννοια παρουσιάζεται με πέντε σταθερά επίπεδα: **ΑΠΛΟΣ ΟΡΙΣΜΟΣ** → **ΕΠΙΣΤΗΜΟΝΙΚΟΣ ΟΡΙΣΜΟΣ** → **ΜΑΘΗΜΑΤΙΚΑ** → **ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ** → **ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ**.

1.1 Χρονοσειρά (Time Series)

ΑΠΛΑ: Μια σειρά μετρήσεων του ίδιου πράγματος, στην ίδια μονάδα, σε διαδοχικές χρονικές στιγμές, όπου **η σειρά έχει σημασία**. Αν ανακατέψεις τα δεδομένα και χάσεις πληροφορία, έχεις χρονοσειρά.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Πραγματοποίηση (realization) μιας στοχαστικής διαδικασίας $\{Y_t\}$ σε διακριτό χρόνο $t = 1, 2, \dots, T$. Δεν παρατηρούμε την «κατανομή» — παρατηρούμε **μία** τροχιά της.

$$\{Y_t\}_{t=1}^T = (Y_1, Y_2, \dots, Y_T), \text{ με } Y_t \in \mathbb{R} \text{ και } t \text{ διατεταγμένο}$$

ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ: Η θερμοκρασία στα Γιαννιτσά κάθε μεσημέρι για 365 ημέρες.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Η μηνιαία κατανάλωση αντιβιοτικών στην Ελλάδα σε DID/1000 κατοίκους/ημέρα, 2018–2024 (84 παρατηρήσεις). Η σειρά αυτή έχει τάση, ισχυρή χειμερινή εποχικότητα και μια απότομη πτώση την άνοιξη του 2020 — τρία χαρακτηριστικά που θα μάθουμε να απομονώνουμε.

1.2 Χρονοσειρά vs Cross-sectional vs Panel vs Longitudinal

Η πιο συχνή πηγή λάθους στην πράξη είναι να εφαρμόζεις εργαλεία λάθος τύπου δεδομένων.

Τύπος	Δομή	Παράδειγμα (φάρμακο)	Τι κινδυνεύει αν το μπερδέψεις
Cross-sectional	Πολλές μονάδες, <i>μία</i> χρονική στιγμή	Πωλήσεις 250 φαρμακείων τον Ιούνιο 2025	Χάνεις κάθε δυναμική· δεν μπορείς να μιλήσεις για τάση
Time series	<i>Μία</i> μονάδα, πολλές χρονικές στιγμές	Οι δικές σου μηνιαίες πωλήσεις 2018–2025	OLS με αυτοσυσχετισμένα κατάλοιπα → λάθος standard errors, ψευδής σημαντικότητα
Panel (longitudinal)	Πολλές μονάδες × πολλές στιγμές	250 φαρμακεία × 96 μήνες	Αγνόηση της ομαδοποίησης → υπερεκτίμηση ακρίβειας (clustered SE απαραίτητα)
Longitudinal (βιοϊατρικός όρος)	Ίδια άτομα παρακολουθούνται διαχρονικά, συχνά λίγες & άνισες μετρήσεις	Λιπιδαιμικό προφίλ 120 ασθενών σε 0, 3, 6, 12 μήνες	Χρήση ARIMA σε 4 σημεία ανά άτομο· το σωστό είναι mixed models / GEE

Πρακτικός κανόνας

Πολλά t , λίγα i → εργαλεία χρονοσειρών (ARIMA, ITS, VAR). Λίγα t , πολλά i → panel econometrics (fixed effects, DiD). Και τα δύο πολλά → panel time series (Driscoll-Kraay, panel unit roots).

1.3 Χρονική εξάρτηση (Temporal dependence)

ΑΠΛΑ: Το σήμερα «θυμάται» το χθες. Αν ξέρω την τιμή του Μαΐου, ξέρω κάτι χρήσιμο για τον Ιούνιο. Αυτό παραβιάζει την υπόθεση ανεξαρτησίας που κρύβεται πίσω από σχεδόν κάθε βασικό στατιστικό τεστ.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Οι παρατηρήσεις δεν είναι i.i.d. Υπάρχει μη μηδενική από κοινού εξάρτηση $\text{Cov}(Y_t, Y_{t-k}) \neq 0$ για κάποιο $k \geq 1$.

$\text{Cov}(Y_t, Y_{t-k}) = \gamma(k) \neq 0 \implies$ οι παρατηρήσεις μεταφέρουν επικαλυπτόμενη πληροφορία

ΓΙΑΤΙ ΕΧΕΙ ΣΗΜΑΣΙΑ: Το «ενεργό μέγεθος δείγματος» είναι μικρότερο από το T . Με 84 μήνες ισχυρά αυτοσυσχετισμένων δεδομένων μπορεί να έχεις ουσιαστική πληροφορία 20-30 ανεξάρτητων παρατηρήσεων. Ένα t-test που αγνοεί αυτό δίνει $p = 0,001$ εκεί που το σωστό είναι $p = 0,15$.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Σύγκριση μέσης μηνιαίας φαρμακευτικής δαπάνης πριν/μετά από μια πολιτική με απλό t-test — κλασικό λάθος σε εκθέσεις. Η δαπάνη είναι έντονα αυτοσυσχετισμένη· χρειάζεται ITS με διόρθωση αυτοσυσχέτισης.

1.4 Υστέρηση (Lag)

ΑΠΛΑ: Το lag k είναι η ίδια σειρά «σπρωγμένη» k περιόδους πίσω. Είναι η βασική μονάδα δόμησης όλων των μοντέλων χρονοσειρών.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Ορίζεται μέσω του τελεστή υστέρησης (lag/backshift operator) L (ή B).

$$L Y_t = Y_{t-1}, \quad L^k Y_t = Y_{t-k}, \quad (1 - L) Y_t = Y_t - Y_{t-1} = \Delta Y_t$$

ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ: Σε μηνιαία δεδομένα, lag 1 = προηγούμενος μήνας, lag 12 = ίδιος μήνας πέρυσι.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Οι επισκέψεις σε ιατρό προηγούνται των συνταγογραφήσεων κατά ~1 μήνα και της αποζημίωσης ΕΟΠΥΥ κατά 2-3 μήνες. Το σωστό lag δεν είναι στατιστική επιλογή — είναι θεσμική γνώση που ελέγχεται στατιστικά.

1.5 Αυτοσυσχέτιση (Autocorrelation)

ΑΠΛΑ: Πόσο μοιάζει η σειρά με τον εαυτό της k περιόδους πριν. Συσχέτιση Pearson της σειράς με το lag της.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Η συνάρτηση αυτοσυσχέτισης (ACF) $\rho(k)$ είναι η κανονικοποιημένη αυτοσυνδιακύμανση.

$$\rho(k) = \gamma(k) / \gamma(0) = \text{Cov}(Y_t, Y_{t-k}) / \text{Var}(Y_t) \quad \text{με } -1 \leq \rho(k) \leq 1$$

$$\text{Δειγματική εκτίμηση: } r_k = \sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y}) / \sum_{t=1}^T (y_t - \bar{y})^2$$

ΕΡΜΗΝΕΙΑ: $\rho(1) = 0,9 \rightarrow$ πολύ αργή δυναμική (η σειρά «κολλάει»). $\rho(12)$ υψηλό σε μηνιαία δεδομένα $\rightarrow$ εποχικότητα. $\rho(k)$ που φθίνει πολύ αργά και γραμμικά $\rightarrow$ πιθανή μη-στασιμότητα.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Στην κατανάλωση αντιβιοτικών, $\rho(12) \approx 0,7-0,8$ λόγω του χειμερινού peak. Ένα μοντέλο που δεν το πιάνει αυτό θα έχει συστηματικά λάθη κάθε Ιανουάριο.

Προσοχή

Η αυτοσυσχέτιση στα δεδομένα είναι αναμενόμενη και χρήσιμη. Η αυτοσυσχέτιση στα κατάλοιπα του μοντέλου είναι πρόβλημα: σημαίνει ότι έμεινε πληροφορία που το μοντέλο δεν εκμεταλλεύτηκε.

1.6 Τάση (Trend)

ΑΠΛΑ: Η μακροχρόνια κατεύθυνση — ανοδική, καθοδική ή σταθερή — αν αγνοήσεις τον «θόρυβο» και τις εποχικές διακυμάνσεις.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Η αργά μεταβαλλόμενη συνιστώσα $T_t = E[Y_t]$ που δεν επανέρχεται σε σταθερό μέσο εντός του δείγματος. Δεν είναι απαραίτητως γραμμική.

$$\text{Γραμμική: } T_t = \beta_0 + \beta_1 t \quad \cdot \quad \text{Τετραγωνική: } T_t = \beta_0 + \beta_1 t + \beta_2 t^2 \quad \cdot \quad \text{Μη παραμετρική: } T_t = \text{LOESS}(Y_t)$$

ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ: Ο πληθυσμός μιας πόλης που αυξάνεται σταθερά επί 30 χρόνια.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Η διεύθυνση των γενοσήμων στην Ελλάδα 2012-2024: σαφής ανοδική τάση με φθίνοντα ρυθμό (κορεσμός) — γι' αυτό γραμμική τάση θα υπερεκτιμούσε δραματικά τις προβλέψεις για το 2027.

1.7 Εποχικότητα (Seasonality)

ΑΠΛΑ: Επαναλαμβανόμενο μοτίβο με **σταθερή, γνωστή περίοδο** συνδεδεμένο με το ημερολόγιο.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Συνιστώσα S_t με $S_t = S_{t-s}$, όπου s η εποχική περίοδος (12 για μηνιαία, 4 για τριμηνιαία, 7 για ημερήσια με εβδομαδιαίο μοτίβο, 52 για εβδομαδιαία).

$$Y_t = T_t + S_t + R_t, \text{ με } \sum_{j=1}^s S_j = 0 \text{ (περιορισμός ταυτοποίησης)}$$

ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ: Πωλήσεις αντηλιακών: κορυφή κάθε Ιούλιο, πάτος κάθε Ιανουάριο.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Αντιβιοτικά και αντικά: peak Δεκέμβριο-Φεβρουάριο. Αντιισταμινικά: peak Απρίλιο-Μάιο. Στα φαρμακεία υπάρχει και *δεύτερη* εποχικότητα: ημέρα του μήνα (συγκέντρωση συνταγών στην αρχή του μήνα λόγω κύκλων συνταγογράφησης) — περίπτωση multiple seasonality (Τεύχος Δ').

1.8 Κύκλος (Cycle)

ΑΠΛΑ: Και αυτό είναι επαναλαμβανόμενη διακύμανση — αλλά με **μεταβλητή, άγνωστη** διάρκεια, χωρίς ημερολογιακό «κλείδωμα».

Η ΚΡΙΣΙΜΗ ΔΙΑΦΟΡΑ:

Χαρακτηριστικό	Εποχικότητα	Κύκλος
Περίοδος	Σταθερή & γνωστή a priori (12, 4, 7)	Μεταβλητή, εκτιμώμενη εκ των υστέρων
Διάρκεια	Συνήθως ≤ 1 έτος	Συνήθως > 1 έτος (2-10 έτη)
Πλάτος	Σχετικά σταθερό	Έντονα μεταβλητό
Προβλεψιμότητα	Υψηλή	Χαμηλή — εδώ αποτυγχάνουν τα περισσότερα μοντέλα

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Ο οικονομικός κύκλος επηρεάζει την ιδιωτική φαρμακευτική δαπάνη (ΟΤC, συμπληρώματα) με διάρκεια 4-8 ετών — μη προβλέψιμη. Η γρίπη έχει εποχικότητα (κάθε χειμώνα) αλλά και υπερετήσιο κύκλο έντασης λόγω ανοσίας πληθυσμού.

1.9 Θόρυβος (Noise / Irregular component)

ΑΠΛΑ: Ό,τι μένει αφού αφαιρέσεις τάση, εποχικότητα και κύκλο. Το «ανεξήγητο» υπόλοιπο.

ΕΠΙΣΤΗΜΟΝΙΚΑ: Η στοχαστική συνιστώσα R_t (remainder). Στόχος κάθε μοντέλου: να μετατρέψει το R_t σε λευκό θόρυβο. Αν το υπόλοιπο έχει ακόμη δομή, το μοντέλο είναι ελλιπές.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Σε μηνιαίες νοσηλείες, το «noise» περιέχει τυχαία γεγονότα (ένα ατύχημα με πολλά θύματα) αλλά και συστηματικά που δεν μοντελοποιήσαμε (απεργία, καύσωνας). Το να τα ξεχωρίσεις είναι το ουσιώδες μέρος της δουλειάς.

1.10 Λευκός θόρυβος (White Noise)

ΑΠΛΑ: Ακολουθία καθαρά τυχαίων τιμών, χωρίς καμία μνήμη. Η «τέλεια απουσία δομής».

ΕΠΙΣΤΗΜΟΝΙΚΑ: Διαδικασία με μηδενικό μέσο, σταθερή διακύμανση και μηδενική αυτοσυσχέτιση σε κάθε $\text{lag} \neq 0$.

$$\varepsilon_t \sim \text{WN}(0, \sigma^2): E[\varepsilon_t] = 0, \text{Var}(\varepsilon_t) = \sigma^2, \text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0 \quad \forall k \neq 0$$

Gaussian WN προσθέτει: $\varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2)$

ΠΩΣ ΤΟ ΑΝΑΓΝΩΡΙΖΕΙΣ: Στο ACF, όλες οι ράβδοι μέσα στις ζώνες $\pm 1,96/\sqrt{T}$. Ljung-Box $p > 0,05$.

ΓΙΑΤΙ ΕΙΝΑΙ ΤΟ ΠΙΟ ΣΗΜΑΝΤΙΚΟ CONCEPT ΤΟΥ ΚΕΦΑΛΑΙΟΥ: Δεν το ψάχνεις στα δεδομένα — το ψάχνεις στα **κατάλοιπα**. Είναι το κριτήριο επιτυχίας κάθε μοντέλου που θα φτιάξεις.

1.11 Τυχαίος περίπατος (Random Walk)

ΑΠΛΑ: Η αυριανή τιμή = η σημερινή + ένα τυχαίο βήμα. Η σειρά «περιπλανιέται» χωρίς να επιστρέφει σε κάποιο μέσο.

$$Y_t = Y_{t-1} + \varepsilon_t \iff \Delta Y_t = \varepsilon_t$$

$$\text{Με drift: } Y_t = \delta + Y_{t-1} + \varepsilon_t \implies Y_t = Y_0 + \delta t + \sum_{i=1}^t \varepsilon_i$$

ΚΡΙΣΙΜΗ ΙΔΙΟΤΗΤΑ: $\text{Var}(Y_t) = t\sigma^2 \rightarrow$ η διακύμανση αυξάνεται *χωρίς όριο* με τον χρόνο. Οι διαταραχές είναι **μόνιμες**: ένα shock σήμερα μετατοπίζει το επίπεδο για πάντα.

ΑΠΛΟ ΠΑΡΑΔΕΙΓΜΑ: Μεθυσμένος που κάνει ένα τυχαίο βήμα ανά λεπτό — δεν έχει «σπίτι» στο οποίο επιστρέφει.

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Οι τιμές μετοχών προσεγγίζονται πολύ καλά από random walk. Γι' αυτό το naive forecast ($\hat{y}_{T+h} = y_T$) είναι *βέλτιστο* για μετοχές — και γι' αυτό κάθε μοντέλο πρόβλεψης τιμών οφείλει να συγκριθεί μαζί του πριν διεκδικήσει αξία.

1.12 Μοναδιαία ρίζα (Unit Root)

ΑΠΛΑ: Η τεχνική συνθήκη που κάνει μια σειρά να συμπεριφέρεται σαν random walk — να «μη θυμάται πού ανήκει».

ΕΠΙΣΤΗΜΟΝΙΚΑ: Γράφουμε το AR(1) ως $Y_t = \phi Y_{t-1} + \varepsilon_t$. Το χαρακτηριστικό πολυώνυμο είναι $(1 - \phi L) = 0$, με ρίζα $L = 1/\phi$. Αν $\phi = 1$, η ρίζα ισούται με τη μονάδα $\rightarrow$ *unit root*.

Τιμή ϕ	Συμπεριφορά	Επίδραση shock	Στάσιμη;
$ \phi < 1$	Επιστρέφει στον μέσο (mean reversion)	Σβήνει εκθετικά	Ναι — $I(0)$
$\phi = 1$	Random walk	Μόνιμη	Όχι — $I(1)$
$ \phi > 1$	Εκρηκτική	Ενισχύεται	Όχι — σπάνια ρεαλιστική

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Ο δείκτης τιμών φαρμάκων έχει σχεδόν πάντα unit root στο επίπεδο, αλλά όχι στις πρώτες διαφορές (τον πληθωρισμό). Γι' αυτό μοντελοποιούμε ρυθμούς μεταβολής, όχι επίπεδα.

1.13 Στασιμότητα (Stationarity) — πρώτη επαφή

ΑΠΛΑ: Μια σειρά είναι στάσιμη αν οι στατιστικές της ιδιότητες (μέσος, διακύμανση, δομή συσχέτισης) **δεν αλλάζουν** με τον χρόνο. Οπτικά: κυμαίνεται γύρω από σταθερό επίπεδο, με σταθερό πλάτος, χωρίς τάση.

ΑΣΘΕΝΗΣ (WEAK / COVARIANCE) ΣΤΑΣΙΜΟΤΗΤΑ — αυτή που χρησιμοποιούμε στην πράξη:

$$(1) E[Y_t] = \mu \quad \forall t \quad \cdot \quad (2) \text{Var}(Y_t) = \sigma^2 < \infty \quad \forall t \quad \cdot \quad (3) \text{Cov}(Y_t, Y_{t-k}) = \gamma(k) \text{ — εξαρτάται μόνο από το } k, \text{ όχι από το } t$$

ΑΥΣΤΗΡΗ (STRICT) ΣΤΑΣΙΜΟΤΗΤΑ: Ολόκληρη η από κοινού κατανομή είναι αμετάβλητη σε χρονικές μετατοπίσεις: $F(Y_{t1}, \dots, Y_{tn}) = F(Y_{t1+h}, \dots, Y_{tn+h})$. Πολύ ισχυρότερη, σπάνια ελέγξιμη — γι' αυτό δουλεύουμε με την ασθενή.

ΓΙΑΤΙ ΜΑΣ ΝΟΙΑΖΕΙ: Σχεδόν όλη η κλασική θεωρία (ARMA, standard errors, t-tests) προϋποθέτει στασιμότητα. Χωρίς αυτήν, οι εκτιμητές δεν συγκλίνουν κανονικά και προκύπτουν *ψευδείς παλινδρομήσεις* (spurious regression).

Θα το δούμε πλήρως στο Τεύχος Β'

Εκεί: strict vs weak, trend- vs difference-stationarity, $I(0)/I(1)/I(2)$, ADF, KPSS, Phillips-Perron, και ο πίνακας συνδυασμού ADF×KPSS με το επόμενο βήμα σε κάθε περίπτωση.

1.14 Ντετερμινιστική vs Στοχαστική τάση

Δύο σειρές μπορεί να φαίνονται πανομοιότυπες στο γράφημα και να απαιτούν εντελώς διαφορετική μεταχείριση.

	Ντετερμινιστική τάση	Στοχαστική τάση
Εξίσωση	$Y_t = \beta_0 + \beta_1 t + \varepsilon_t$	$Y_t = \delta + Y_{t-1} + \varepsilon_t$
Ονομασία	Trend-stationary	Difference-stationary, $I(1)$
Επίδραση shock	Προσωρινή — επιστρέφει στη γραμμή	Μόνιμη — μετατοπίζει την τροχιά
Σωστή θεραπεία	Detrending (αφαίρεση της γραμμής)	Differencing (ΔY_t)
Λάθος θεραπεία	Differencing → over-differencing, εισάγει MA(1) με $\theta = -1$	Detrending → μένει unit root, spurious αποτελέσματα
Var μακροπρόθεσμα	Σταθερή	Αυξάνεται γραμμικά ($t\sigma^2$)

ΠΡΑΓΜΑΤΙΚΗ ΣΗΜΑΣΙΑ: Αν η φαρμακευτική δαπάνη έχει ντετερμινιστική τάση, μια περικοπή προϋπολογισμού έχει προσωρινό αποτέλεσμα και η δαπάνη επανέρχεται. Αν έχει στοχαστική τάση, η ίδια περικοπή αλλάζει μόνιμα το επίπεδο. **Ίδιο γράφημα, αντίθετο policy συμπέρασμα.** Η διάκριση γίνεται με τεστ μοναδιαίας ρίζας — όχι με το μάτι.

1.15 Προσθετική vs Πολλαπλασιαστική δομή

ΠΡΟΣΘΕΤΙΚΗ: Οι συνιστώσες αθροίζονται. Το εποχικό πλάτος είναι σταθερό σε απόλυτες μονάδες, ανεξάρτητο από το επίπεδο.

$$Y_t = T_t + S_t + R_t$$

ΠΟΛΛΑΠΛΑΣΙΑΣΤΙΚΗ: Οι συνιστώσες πολλαπλασιάζονται. Το εποχικό πλάτος μεγαλώνει αναλογικά με το επίπεδο.

$$Y_t = T_t \times S_t \times R_t \implies \log Y_t = \log T_t + \log S_t + \log R_t$$

Ο ΠΡΑΚΤΙΚΟΣ ΚΑΝΟΝΑΣ: Κοίτα το γράφημα. Αν οι εποχικές «καμπούρες» μεγαλώνουν καθώς ανεβαίνει η σειρά (χοάνη που ανοίγει), είναι πολλαπλασιαστική. Λογαριθμίζεις και γίνεται προσθετική.

ΑΡΙΘΜΗΤΙΚΟ ΠΑΡΑΔΕΙΓΜΑ: Πωλήσεις με βασικό επίπεδο 1.000 → 2.000 μονάδες σε 5 έτη, με Δεκεμβριάτικο peak.

· Προσθετικό: peak = επίπεδο + 200 (πάντα +200, είτε 1.000 είτε 2.000).

· Πολλαπλασιαστικό: peak = επίπεδο × 1,20 (δηλαδή +200 όταν το επίπεδο είναι 1.000, αλλά +400 όταν είναι 2.000).

ΠΡΑΓΜΑΤΙΚΗ ΕΦΑΡΜΟΓΗ: Σχεδόν όλα τα οικονομικά και φαρμακευτικά μεγέθη (πωλήσεις, δαπάνη, συνταγές) είναι **πολλαπλασιαστικά**. Γι' αυτό η λογαριθμική μετατροπή είναι σχεδόν default και οι συντελεστές ερμηνεύονται ως ποσοστιαίες μεταβολές.

Σύνοψη Κεφαλαίου 1 — Οι 5 ερωτήσεις που πρέπει να απαντάς για κάθε νέα σειρά

1. Είναι όντως χρονοσειρά ή panel/longitudinal δεδομένα;
2. Υπάρχει τάση; Είναι ντετερμινιστική ή στοχαστική;
3. Υπάρχει εποχικότητα; Με ποια περίοδο s; Προσθετική ή πολλαπλασιαστική;
4. Είναι σταθερή η διακύμανση ή χρειάζεται log/Box-Cox;
5. Πόσο ισχυρή είναι η αυτοσυσχέτιση — πόση πραγματική πληροφορία έχω πίσω από τις T παρατηρήσεις;

ΚΕΦΑΛΑΙΟ 2 — Πού χρησιμοποιούμε χρονοσειρές

Δεν αρκεί να ξέρεις τα μοντέλα· πρέπει να αναγνωρίζεις τη *δομή* ενός προβλήματος. Ο παρακάτω πίνακας απαντά, για κάθε πεδίο, στα πέντε ερωτήματα που καθορίζουν τη μεθοδολογία: εξαρτημένη μεταβλητή, συχνότητα, ορίζοντας πρόβλεψης, πιθανοί προβλεπτές, κατάλληλο μοντέλο.

2.1 Μακροοικονομία & Χρηματοοικονομικά

Πεδίο	Εξαρτημένη (Y)	Συ- χνότη- τα	Ορίζο- ντας	Προβλεπτές	Μοντέλο
Πληθωρι- σμός	ΔCPI (% , YoY ή MoM)	Μηνιαία	1-24 μή- νες	Τιμές ενέργειας, συναλλαγ- ματική ισοτιμία, output gap, προσδοκίες	SARIMAX, ARDL, VAR· Phillips curve ως δομικό
ΑΕΠ	Πραγματικό ΑΕΠ ή ρυθμός	Τριμη- νιαία	1-8 τρίμη- να	PMI, δείκτες εμπιστοσύνης, βιομηχανική παραγωγή (mixed frequency)	VAR / VECM· MIDAS για nowcasting
Ανεργία	Ποσοστό ανεργίας	Μη- νιαία/ Τριμ.	1-12 μή- νες	ΑΕΠ (νόμος Okun), κενές θέσεις, εποχικοί κλάδοι	SARIMA, ARDL, Markov-switching
Χρηματι- στήριο	Τιμή ή log-return	Ημερή- σια+	1-20 ημέρες	Όγκος, VIX, macro announcements	<i>Επίπεδο:</i> random walk (naive). <i>Μεταβλητότητα:</i> GARCH/EGARCH

Το πιο σημαντικό μάθημα αυτού του πίνακα

Στα χρηματιστηριακά επίπεδα, το καλύτερο μοντέλο είναι το απλούστερο (naïve). Αυτό που είναι *πράγ-
ματι* προβλέψιμο δεν είναι η απόδοση αλλά η **μεταβλητότητα** — γι' αυτό υπάρχει το GARCH. Να θυ-
μάσαι τη διάκριση: προβλεψιμότητα του μέσου $\neq$ προβλεψιμότητα της διακύμανσης.

2.2 Επιχειρήσεις, πωλήσεις, αποθέματα

Πεδίο	Εξαρτημένη (Y)	Συ- χνότη- τα	Ορίζο- ντας	Προβλεπτές	Μοντέλο
Πωλήσεις	Μονάδες ή τζίρος ανά SKU	Εβδ./ Μην.	1-12 μή- νες	Τιμή, προωθητικές, αργίες, ανταγωνιστές, καιρός	ETS/SARIMA για few SKUs· LightGBM με global features για χιλιάδες SKUs
Αποθέματα	Ζήτηση ανά κωδικό	Ημερή- σια/Εβδ.	Lead time (1-8 εβδ.)	Ιστορικό ζήτησης, εποχικότη- τα, lead time	Ταχυκίνητα: ETS/ARIMA. Βραδυκίνητα: Croston / SBA / TSB

Ειδικά για φαρμακείο

Το ~70% των κωδικών σε ένα φαρμακείο είναι *intermittent demand*: πολλά μηδενικά, σποραδικές πω-
λήσεις. Το ARIMA εκεί είναι λάθος εργαλείο — προβλέπει 0,3 κουτιά και δεν λέει τίποτα για τον
κίνδυνο έλλειψης. Χρειάζεσαι Croston/TSB και, κυρίως, πρόβλεψη *κατανομής* (service level), όχι ση-
μειακή τιμή. Αναλυτικά στο Τεύχος Δ'.

2.3 Φαρμακευτική αγορά, HTA, αποζημίωση

Πεδίο	Εξαρτημένη (Y)	Συ-χρότητα	Ορίζοντας	Προβλεπτές	Μοντέλο
Συνταγογράφηση	DDD/1000/ημέρα ή αριθμός συνταγών	Μηνιαία	6-24 μήνες	Θεραπευτικές οδηγίες, εποχικότητα λοιμώξεων, νέα μόρια, ιατρικές επισκέψεις	SARIMA/SARIMAX· ITS για αξιολόγηση παρέμβασης
Φαρμ. δαπάνη	€ δημόσια δαπάνη	Μηνιαία	12-36 μήνες	Όγκος × τιμή, διείσδυση γενοσήμων, νέες εντάξεις, clawback	SARIMAX με decomposition όγκου/τιμής· σεναριακή ανάλυση
Clawback rebate	/ Υπέρβαση έναντι κλειστού Π/Υ	Εξαμηνιαία	1-4 εξάμηνα	Προβολή δαπάνης, όριο Π/Υ, μερίδιο εταιρείας	Πρόβλεψη δαπάνης → λογιστικός υπολογισμός· prediction intervals κρίσιμα
HTA / budget impact	Επιπλέον δαπάνη νέας τεχνολογίας	Ετήσια	3-5 έτη	Επιδημιολογία, uptake curve, τιμή, market displacement	Επιδημιολογικό/Markov μοντέλο τροφοδοτούμενο από πρόβλεψη χρονοσειράς για το baseline
Αποζημίωση (policy change)	Δαπάνη, όγκος, μερίδιο	Μηνιαία	— (αιτιακό)	Ημερομηνία εφαρμογής, control series	ITS / CITS / Synthetic Control — όχι forecasting

2.4 Επιδημιολογία & Δημόσια Υγεία

Πεδίο	Εξαρτημένη (Y)	Συ-χρότητα	Ορίζοντας	Προβλεπτές	Μοντέλο
Νοσηλείες	Εισαγωγές/μήνα (count)	Μηνιαία	1-12 μήνες	Εποχικότητα, γρίπη, θερμοκρασία, αργίες, πληθυσμός (offset)	Negative Binomial GLM με harmonics· SARIMA αν μεγάλοι αριθμοί
Επιτήρηση νόσου	Νέα κρούσματα	Εβδ./ Ημερ.	1-4 εβδομάδες	Κινητικότητα, τεστ, ιστορικό	SEIR / R_t estimation· ensembles
Θνησιμότητα	Θάνατοι, mortality	excess Εβδομαδιαία	—	Baseline από ιστορικά έτη, καύσωνες	EuroMOMO / Serfling regression
Παρέμβαση ΔΥ	Καπνιστές, εμβολιαστική κάλυψη	Μηνιαία	—	Ημ/νία νόμου	ITS με control

Count data — προσοχή

Όταν το Y είναι *μέτρημα* με μικρές τιμές (π.χ. 3-15 εισαγωγές/μήνα σε μικρό νοσοκομείο), το ARIMA προϋποθέτει συνεχή, κανονικά κατανομημένη μεταβλητή και μπορεί να προβλέψει αρνητικές τιμές. Το σωστό είναι Poisson/Negative Binomial regression με χρονικούς όρους. Με μεγάλους αριθμούς (>100/περίοδο) η κανονική προσέγγιση είναι αποδεκτή.

2.5 Ενέργεια & Καιρός

Πεδίο	Εξαρτημένη (Y)	Συχνότητα	Ορίζοντας	Προβλεπτές	Μοντέλο
Ζήτηση ενέργειας	ηλ. MW	Ημωριαία	1-7 ημέρες	Θερμοκρασία, ημέρα, αργίες	ώρα, TBATS ή Prophet — τριπλή εποχικότητα (ημερήσια/εβδομαδιαία/ετήσια)
Τιμές ενέργειας	€/MWh	Ωριαία/Ημερ.	1-30 ημέρες	Φυσικό αέριο, CO ₂ , ΑΠΕ	SARIMAX + GARCH (spikes)
Θερμοκρασία	°C	Ημερήσια	1-10 ημέρες	—	Φυσικά μοντέλα NWP· στατιστικά μόνο για κλιματολογία

Το μοτίβο που πρέπει να κρατήσεις

Πριν ανοίξεις οποιοδήποτε λογισμικό, συμπλήρωσε αυτές τις έξι γραμμές:

Y = ... · Συχνότητα = ... · T (πλήθος παρατηρήσεων) = ... · Ορίζοντας h = ... · Ερώτημα: πρόβλεψη ή αιτιότητα; ... · Ποια X είναι γνωστά τη στιγμή της πρόβλεψης; ...

Η τελευταία γραμμή είναι αυτή που ξεχνιέται πιο συχνά και ακυρώνει ολόκληρα μοντέλα (βλ. Μέρος 23, λάθος #13).

ΚΕΦΑΛΑΙΟ 3 — Πρώτη διερεύνηση των δεδομένων (Data Audit & EDA)

Το 80% των σοβαρών λαθών σε αναλύσεις χρονοσειρών δεν είναι λάθη μοντέλου — είναι λάθη δεδομένων που δεν εντοπίστηκαν. Ένα «level shift» που στην πραγματικότητα είναι αλλαγή κωδικοποίησης, ένας μήνας που λείπει και συμπληρώθηκε σιωπηρά με μηδέν, δύο πηγές με διαφορετικό ορισμό της μεταβλητής. Αυτό το κεφάλαιο είναι το πιο «βαρετό» και το πιο κρίσιμο.

3.1 Ο έλεγχος του χρονικού άξονα

Έλεγχος	Τι ψάχνεις	Τι κάνεις αν το βρεις
Τύπος ημερομηνίας	Είναι πραγματικό <code>datetime</code> ή κείμενο; Μπερδεμένο DD/MM με MM/DD;	Ρητή μετατροπή με σταθερό <code>format</code> : ποτέ αυτόματο <code>parsing</code> χωρίς έλεγχο. Επιβεβαίωσε ότι <code>min/max</code> ημερομηνία βγάζουν νόημα.
Συχνότητα	Ημερήσια, εβδομαδιαία, μηνιαία; Είναι <i>δηλωμένη</i> ;	Όρισε την ρητά (<code>asfreq('MS')</code>). Πολλά σφάλματα προκύπτουν επειδή η βιβλιοθήκη «μαντεύει».
Ακανόνιστα διαστήματα	Άνισα κενά μεταξύ παρατηρήσεων	Aggregate σε κοινή συχνότητα ή χρήση μεθόδων για <i>irregular series</i> (Gaussian processes, state space)
Διπλότυπα	Δύο εγγραφές για την ίδια ημερομηνία	Ερεύνησε γιατί: διόρθωση, δύο πηγές, ή λάθος <code>join</code> . Μην αθροίζεις τυφλά.
Ημερομηνίες που λείπουν	Παρατηρήσεις που δεν υπάρχουν καθόλου (όχι NaN — <i>απουσίες γραμμές</i>)	Πιο επικίνδυνο από τα NaN , γιατί δεν φαίνεται. <code>Reindex</code> σε πλήρες ημερολόγιο και δεξ που εμφανίζονται NaN.
Ελλείπουσες τιμές	NaN, κενά, «0» που στην πραγματικότητα σημαίνει «άγνωστο»	Διάκρισε: πραγματικό 0 vs ελλείπον. <code>Interpolation</code> μόνο για λίγα, διάσπαρτα κενά· ποτέ για μεγάλα διαστήματα (Kalman/state space καλύτερα).
Ημερολογιακά	Μήνες με 28-31 ημέρες, κινητές αργίες (Πάσχα), εργάσιμες	Κανονικοποίηση ανά ημέρα ή ανά εργάσιμη· <code>dummy</code> για Πάσχα (κινητή γιορτή = κλασική πηγή «ανεξήγητου» θορύβου σε ελληνικά δεδομένα)

3.2 Ο έλεγχος των τιμών

Έλεγχος	Πώς εντοπίζεται	Αντιμετώπιση
Ακραίες τιμές (outliers)	$ z > 3$ στα υπόλοιπα μιας STL, όχι στα raw δεδομένα (αλλιώς η εποχικότητα δείχνει ψευδή outliers)	Ταξινόμηση: (α) λάθος καταχώρισης → διόρθωση· (β) πραγματικό γεγονός → μοντελοποίηση με dummy· (γ) άγνωστο → ευαισθησία με και χωρίς
Σφάλματα καταχώρισης	Τιμές $\times 10$ ή $\div 10$, αρνητικές τιμές σε ποσότητες, μονάδες που αλλάζουν	Έλεγχος τάξης μεγέθους ανά έτος· σύγκριση με ανεξάρτητη πηγή
Αλλαγή τρόπου μέτρησης	Το πιο ύπουλο. Αλλαγή ορισμού, κωδικοποίησης ATC, εύρους πηγής, μεθόδου δειγματοληψίας	Ρώτα την πηγή. Δεν λύνεται στατιστικά. Αν επιβεβαιωθεί: dummy μετατόπισης ή διαχωρισμός σε δύο περιόδους
Μετατόπιση επιπέδου (level shift)	Απότομο, μόνιμο άλμα στο μέσο επίπεδο	Διάκριση: πραγματικό γεγονός (COVID, πολιτική) vs τεχνούργημα δεδομένων. Μοντελοποίησε ρητά — αλλιώς μολύνει όλες τις εκτιμήσεις
Μεταβολή διακύμανσης	Το πλάτος διακύμανσης μεγαλώνει/μικραίνει με τον χρόνο	Αν αναλογικό στο επίπεδο → log ή Box-Cox. Αν αυτόνομο clustering → ARCH/GARCH

3.3 Τα εννέα γραφήματα που φτιάχνεις ΠΑΝΤΑ

Πριν από κάθε μοντέλο, πριν από κάθε τεστ. Το ανθρώπινο μάτι εντοπίζει σε 30 δευτερόλεπτα πράγματα που κανένα αυτόματο τεστ δεν πιάνει.

Γράφημα	Τι δείχνει	Τι ΑΚΡΙΒΩΣ πρέπει να παρατηρείς
1. Raw time plot	Υ ως προς t, γραμμή	Κατεύθυνση και σχήμα τάσης (γραμμική/καμπύλη/καμία)· επαναλαμβανόμενα μοτίβα· απότομα άλματα και πότε συμβαίνουν· κενά· αν το πλάτος διακύμανσης μεγαλώνει (χοάνη) → πολλαπλασιαστική δομή, χρειάζεται log
2. Seasonal plot	Κάθε έτος ως ξεχωριστή γραμμή, με άξονα x = μήνας	Αν οι γραμμές έχουν το ίδιο σχήμα → σταθερή εποχικότητα. Αν κάποια χρονιά ξεφεύγει → ειδικό γεγονός. Αν το σχήμα αλλάζει σταδιακά → εξελισσόμενη εποχικότητα (χρειάζεται STL, όχι σταθερούς εποχικούς δείκτες)
3. Subseries plot	Ξεχωριστό μίνι-γράφημα για κάθε μήνα, με τον μέσο του	Ποιοι μήνες είναι συστηματικά υψηλοί/χαμηλοί (μέγεθος εποχικού effect)· και αν μέσα σε κάθε μήνα υπάρχει τάση διαχρονικά → η τάση δεν είναι ομοιόμορφη σε όλες τις εποχές
4. Rolling mean	Κινητός μέσος (window = s ή 2s)	Την «καθαρή» τάση χωρίς εποχικότητα· αλλαγές κλίσης· σημεία καμπής
5. Rolling SD	Κινητή τυπική απόκλιση	Σταθερότητα διακύμανσης. Αν ανεβαίνει μαζί με τον rolling mean → πολλαπλασιαστική· αν κάνει «συστάδες» → ARCH effects
6. Histogram density	/ Κατανομή τιμών	Ασυμμετρία (θετική → log)· διπλή κορυφή (πιθανά δύο καθεστώτα)· «τοίχος» στο μηδέν (count/intermittent data)
7. Boxplots ανά μήνα	Κατανομή ανά εποχική θέση	Ποσοτικοποιεί το εποχικό effect και τη μεταβλητότητά του. Μήνες με μεγάλο IQR είναι δυσκολότερα προβλέψιμοι — χρήσιμο για prediction intervals
8. ACF	$\rho(k)$ για $k = 1...3s$	Πολύ αργή γραμμική φθίση → μη στάσιμη, χρειάζεται differencing. Κορυφές στα $k = s, 2s, 3s$ → εποχικότητα. Εκθετική φθίση → AR. Απότομος μηδενισμός μετά το lag q → MA(q)
9. PACF	Μερική αυτοσυσχέτιση	Απότομος μηδενισμός μετά το lag p → AR(p). Ένα κυρίαρχο spike στο lag 1 κοντά στο 1 → πιθανή unit root

Πρόσθετα γραφήματα που αξίζουν

Lag plot (Y_t vs Y_{t-1}): αποκαλύπτει μη γραμμική εξάρτηση που το ACF χάνει. · **Mean-vs-SD plot** ανά έτος: αν είναι ευθεία γραμμή, η λογαριθμική μετατροπή είναι η σωστή. · **Ημερολογιακή θερμοχάρτης** (heatmap μήνας × έτος): εντοπίζει μοτίβα και κενά ταυτόχρονα.

Ο απόλυτος κανόνας του Κεφαλαίου 3

Ποτέ μην τρέξεις μοντέλο σε σειρά που δεν έχεις κοιτάξει. Και ποτέ μην εμπιστευτείς τεστ στασιμότητας σε σειρά με μη διορθωμένο structural break — το ADF θα σου πει «μη στάσιμη» ακόμη κι όταν η σειρά είναι στάσιμη γύρω από δύο διαφορετικά επίπεδα.

ΚΕΦΑΛΑΙΟ 4 — Αποσύνθεση (Decomposition)

Η αποσύνθεση σπάει μια σειρά στις δομικές της συνιστώσες. Δεν είναι μοντέλο πρόβλεψης — είναι εργαλείο κατανόησης. Απαντά στην ερώτηση: «πόσο από αυτό που βλέπω είναι τάση, πόσο εποχικότητα και πόσο ανεξήγητο;»

4.1 Το βασικό μοντέλο

$$\text{Προσθετικό: } Y_t = T_t + S_t + R_t$$

$$\text{Πολλαπλασιαστικό: } Y_t = T_t \times S_t \times R_t$$

$$\text{Πολλαπλασιαστικό μέσω λογαρίθμου: } \log Y_t = \log T_t + \log S_t + \log R_t$$

Όπου T_t = trend-cycle (τάση και κύκλος μαζί — δεν διαχωρίζονται στην κλασική αποσύνθεση), S_t = εποχική συνιστώσα, R_t = υπόλοιπο.

Ένδειξη στο γράφημα	Επιλογή	Τυπικά παραδείγματα
Εποχικό πλάτος σταθερό σε απόλυτες μονάδες, ανεξάρτητα από το επίπεδο	Προσθετικό	Θερμοκρασία· ποσοστά· σειρές χωρίς έντονη τάση
Εποχικό πλάτος μεγαλώνει καθώς ανεβαίνει το επίπεδο (σχήμα χο-άνης)	Πολλαπλασιαστικό ή προσθετικό σε log	Πωλήσεις· δαπάνες· συνταγές· σχεδόν όλα τα οικονομικά μεγέθη
Η σειρά περιέχει μηδενικά ή αρνητικές τιμές	Υποχρεωτικά προσθετικό	Το log δεν ορίζεται· χρήση Box-Cox με $\lambda > 0$ ή προσθετικό

4.2 Κλασική αποσύνθεση (Classical decomposition)

Ο απλούστερος αλγόριθμος — καλός για κατανόηση, ανεπαρκής για σοβαρή δουλειά.

Βήματα (προσθετικό, εποχική περίοδος s):

- Εκτίμηση τάσης:** κεντρικός κινητός μέσος τάξης s. Για άρτιο s (π.χ. 12) χρησιμοποιείται $2 \times s$ -MA: $\hat{T}_t = (1/2 y_{t-6} + y_{t-5} + \dots + y_{t+5} + 1/2 y_{t+6})/12$
- Απο-τασιοποίηση:** $d_t = y_t - \hat{T}_t$ (ή $y_t/\hat{T}_t$ στο πολλαπλασιαστικό)
- Εποχικοί δείκτες:** μέσος όρος των d_t για κάθε εποχική θέση $j = 1 \dots s$, κεντραρισμένος ώστε $\sum S_j = 0$
- Υπόλοιπο:** $\hat{R}_t = y_t - \hat{T}_t - \hat{S}_t$

Πλεονεκτήματα	Μειονεκτήματα (γιατί δεν το χρησιμοποιούμε στην πράξη)
Πολύ απλό και διαφανές· κάθε βήμα υπολογίζεται με το χέρι· εξαιρετικό διδακτικά	Χάνει s/2 παρατηρήσεις στην αρχή και στο τέλος (ακριβώς εκεί που θέλεις πρόβλεψη)· υποθέτει απόλυτα σταθερή εποχικότητα σε όλο το δείγμα· υπερβολικά ευαίσθητο σε ακραίες τιμές· δεν αντέχει level shifts

4.3 Αριθμητικό παράδειγμα (τριμηνιαία σειρά, $s = 4$)

Πωλήσεις σε χιλιάδες μονάδες:

Περίοδος	2023-Q1	Q2	Q3	Q4	2024-Q1	Q2	Q3	Q4
y_t	100	120	90	150	112	132	102	162

Παρατήρηση 1: Ο μέσος του 2023 = $(100+120+90+150)/4 = 115$. Του 2024 = $(112+132+102+162)/4 = 127$. → Τάση +12/έτος = +3/τρίμηνο.

Παρατήρηση 2: Οι αποκλίσεις από τον ετήσιο μέσο είναι *ταυτόσημες* και στα δύο έτη: Q1: -15, Q2: +5, Q3: -25, Q4: +35. Άθροισμα = 0. ✓

Επειδή οι αποκλίσεις παραμένουν σταθερές σε *απόλυτες* μονάδες παρότι το επίπεδο ανέβηκε από 115 σε 127, η δομή είναι **προσθετική**.

$$\hat{S} = (-15, +5, -25, +35) \cdot \hat{T}_t \approx 113,5 + 3t \cdot \hat{R}_t \approx 0$$

Πρόβλεψη 2025-Q1: $\hat{T} \approx 113,5 + 3(9) = 140,5$ · συν εποχικός δείκτης Q1 (-15) → **≈ 125,5 χιλ. μονάδες**. (Στην πραγματικότητα το $\hat{R}$ δεν είναι ποτέ ακριβώς 0 — αυτό το τεχνητό παράδειγμα είναι «καθαρό» για λόγους κατανόησης.)

Έλεγχος: τι θα άλλαζε αν ήταν πολλαπλασιαστικό;

Οι αποκλίσεις θα ήταν σταθερές σε *λόγους*, όχι σε μονάδες: Q4/μέσος = $150/115 = 1,304$ το 2023 και θα έπρεπε να είναι $\approx 1,304$ και το 2024, δηλαδή Q4 $\approx 127 \times 1,304 \approx 165,6$ (αντί για 162). Η σύγκριση αυτών των δύο υπολογισμών είναι ο πρακτικός τρόπος να αποφασίσεις.

4.4 STL Decomposition — το εργαλείο επιλογής

STL = Seasonal and Trend decomposition using **Loess** (Cleveland et al., 1990). Είναι μη παραμετρική, επαναληπτική μέθοδος που εκτιμά τάση και εποχικότητα με τοπικές παλινδρομήσεις (loess smoothers).

Χαρακτηριστικό	Classical	STL
Εποχικότητα	Υποχρεωτικά σταθερή	Μπορεί να εξελίσσεται ομαλά με τον χρόνο (παράμετρος <code>seasonal</code>)
Ανθεκτικότητα σε outliers	Καμία	Ναι, με <code>robust=True</code> (μειώνει το βάρος ακραίων τιμών)
Απώλεια παρατηρήσεων	$s/2$ σε κάθε άκρο	Καμία
Ευελιξία τάσης	Μόνο MA	Ρυθμιζόμενη (<code>trend window</code>)
Πολλαπλή εποχικότητα	Όχι	Ναι, με MSTL
Περιορισμός	—	Μόνο προσθετικό — για πολλαπλασιαστικό, εφάρμοσέ το στους λογαρίθμους

Οι δύο παράμετροι που έχουν σημασία:

- `seasonal` (περιττός αριθμός): μικρή τιμή (π.χ. 7) → η εποχικότητα αλλάζει γρήγορα· μεγάλη ή `'periodic'` → σχεδόν σταθερή. Ξεκίνα μεγάλη και μείωσε μόνο αν το `seasonal plot` δείχνει σαφή εξέλιξη.

- `trend`: μεγαλύτερο παράθυρο → ομαλότερη τάση. Πολύ μικρό παράθυρο «ρουφάει» εποχικότητα μέσα στην τάση — κλασικό λάθος.

```
from statsmodels.tsa.seasonal import STL
res = STL(y, period=12, seasonal=13, robust=True).fit()
res.plot() # 4 πάνελ: observed / trend / seasonal / resid
```

4.5 Πώς διαβάζεις το αποτέλεσμα της αποσύνθεσης

Συνιστώσα	Τι κοιτάς	Τι σημαίνει / επόμενο βήμα
Trend	Είναι μονότονη; Αλλάζει κλίση; Υπάρχει καμπί ή άλμα;	Γραμμική → πιθανό ETS με trend ή ARIMA με $d=1$. Απότομο άλμα → structural break, χρειάζεται ρητή μοντελοποίηση
Seasonal	Μέγεθος πλάτους· αν σταθερό ή εξελισσόμενο	Μεγάλο & σταθερό → SARIMA/Holt-Winters. Εξελισσόμενο → STL+ETS ή ETS με πολλαπλασιαστική εποχικότητα
Remainder	Μοιάζει με λευκό θόρυβο; Υπάρχουν συστάδες; Ακραίες τιμές;	Δομημένο υπόλοιπο → η αποσύνθεση δεν αρκεί· υπάρχει μοντελοποιήσιμη δυναμική (ARMA). Συστάδες μεταβλητότητας → ARCH

Ποσοτικοποίηση: πόσο ισχυρή είναι κάθε συνιστώσα;

Οι δείκτες ισχύος (Wang, Smith & Hyndman) δίνουν τιμή στο $[0, 1]$:

$$F_T = \max\{0, 1 - \text{Var}(R_t) / \text{Var}(T_t + R_t)\} \quad (\text{ισχύς τάσης})$$

$$F_S = \max\{0, 1 - \text{Var}(R_t) / \text{Var}(S_t + R_t)\} \quad (\text{ισχύς εποχικότητας})$$

Τιμή κοντά στο 1 → πολύ ισχυρή συνιστώσα. Κοντά στο 0 → ασήμαντη. Πρακτικά: $F_S < 0,3$ σημαίνει ότι η εποχική μοντελοποίηση πιθανόν δεν αξίζει την πολυπλοκότητα. $F_S > 0,6$ σημαίνει ότι *πρέπει* να τη μοντελοποιήσεις.

4.6 Τι ΔΕΝ είναι η αποσύνθεση

Τρεις παρανοήσεις

1. Η αποσύνθεση δεν είναι μοντέλο πρόβλεψης από μόνη της. Είναι όμως χρήσιμη *μέσα* σε στρατηγική πρόβλεψης: αποσυνθέτεις → προβλέπεις χωριστά την εποχικά προσαρμοσμένη σειρά (π.χ. με ETS) → προσθέτεις πίσω το εποχικό μοτίβο (STL+ETS ή STL+ARIMA).
2. Η αποσύνθεση δεν είναι μοναδική. Διαφορετικές παράμετροι δίνουν διαφορετική κατανομή μεταξύ trend και remainder. Δεν υπάρχει «η αληθινή τάση» — υπάρχει η τάση που ορίζεις με τις επιλογές σου. Δήλωσέ τις.
3. Η εποχική προσαρμογή (seasonal adjustment) δεν είναι αθώα. Οι επίσημες σειρές (X-13ARIMA-SEATS της Eurostat/ΕΛΣΤΑΤ) αναθεωρούνται καθώς προστίθενται δεδομένα. Μια «στατιστικά σημαντική» μεταβολή σε εποχικά προσαρμοσμένα δεδομένα μπορεί να εξαφανιστεί στην επόμενη έκδοση.

ΕΛΕΓΧΟΣ ΚΑΤΑΝΟΗΣΗΣ — Τεύχος Α΄

Απάντησε πριν προχωρήσεις στο Τεύχος Β΄. Οι απαντήσεις δίνονται στην αρχή του επόμενου τεύχους.

A. Έννοιες (σύντομη απάντηση)

1. Δύο σειρές έχουν πανομοιότυπο γράφημα με ανοδική πορεία. Η μία είναι trend-stationary, η άλλη difference-stationary. Ποια είναι η *πρακτική* διαφορά για την αξιολόγηση μιας πολιτικής παρέμβασης;
2. Γιατί η ύπαρξη αυτοσυσχέτισης στα *δεδομένα* είναι φυσιολογική, ενώ στα *κατάλοιπα* είναι πρόβλημα;
3. Έχεις μηνιαία σειρά με $\rho(1) = 0,95$ και $T = 60$. Γιατί ένα t-test σύγκρισης μέσων πριν/μετά είναι παραπλανητικό;
4. Ποια είναι η διαφορά μεταξύ εποχικότητας και κύκλου — και γιατί η δεύτερη είναι πολύ δυσκολότερα προβλέψιμη;
5. Πότε είναι *υποχρεωτικά* προσθετική η αποσύνθεση, ακόμη κι αν το γράφημα δείχνει πολλαπλασιαστική δομή;

B. Εφαρμογή

1. Σου δίνουν μηνιαία δαπάνη ΕΟΠΥΥ 2018–2025 (96 σημεία) και σε ρωτούν αν μια αλλαγή στον κατάλογο αποζημίωσης του Ιουνίου 2022 «είχε αποτέλεσμα». Γράψε τα **έξι πρώτα βήματα** που θα κάνεις — πριν εκτιμήσεις οποιοδήποτε μοντέλο.
2. Σε ένα seasonal plot, οι γραμμές των ετών 2018–2021 έχουν το ίδιο σχήμα, αλλά του 2022–2024 έχουν χαμηλότερο peak και μετατοπισμένο σε διαφορετικό μήνα. Τι σημαίνει αυτό και ποια μέθοδο αποσύνθεσης επιλέγεις;
3. Το rolling SD ανεβαίνει αναλογικά με το rolling mean. Ποια μετατροπή εφαρμόζεις και πώς αλλάζει η ερμηνεία των συντελεστών;
4. Σε σειρά μηνιαίων εισαγωγών μικρού νοσοκομείου (μέσος 8 εισαγωγές/μήνα), γιατί το SARIMA είναι κακή επιλογή και τι προτείνεις;
5. Υπολόγισε F_S για σειρά όπου $\text{Var}(R) = 4$ και $\text{Var}(S+R) = 40$. Τι συμπεραίνεις;

Επόμενο βήμα

Το **Τεύχος Β΄** καλύπτει τα Μέρη 5–8: στασιμότητα σε βάθος (strict/weak, $I(0)/I(1)/I(2)$, spurious regression), τα τεστ ADF / KPSS / Phillips-Perron με πλήρη H_0-H_1 και τον συνδυαστικό πίνακα αποφάσεων, τις μετατροπές (log, Box-Cox, differencing, over/under-differencing), τα ACF/PACF ως εργαλεία ταυτοποίησης, και ολόκληρη την οικογένεια baselines → ETS → ARIMA → SARIMA → SARIMAX με εξισώσεις, υποθέσεις και πλεονεκτήματα/μειονεκτήματα κάθε μοντέλου.