

ΕΓΧΕΙΡΙΔΙΟ ΕΚΠΑΙΔΕΥΣΗΣ

TIME SERIES ANALYSIS

FROM ZERO TO HERO

ΤΕΥΧΟΣ Β΄

Στασιμότητα · Μετασχηματισμοί · ACF/PACF · Μοντέλα Πρόβλεψης

Μέρη 5-8 του πλήρους προγράμματος

Από τη διάγνωση της σειράς στο πρώτο σωστό μοντέλο

Περιλαμβάνει απαντήσεις ελέγχου Τεύχους Α΄

Αύγουστος 2026

ΑΠΑΝΤΗΣΕΙΣ — Έλεγχος κατανόησης Τεύχους Α΄

1. Trend-stationary vs difference-stationary στην αξιολόγηση πολιτικής.

Στην trend-stationary σειρά ένα shock είναι *προσωρινό*: η σειρά επιστρέφει στην ντετερμινιστική της γραμμή. Άρα μια παρέμβαση χωρίς μόνιμη θεσμική αλλαγή θα έχει φθίνουσα επίδραση και η σωστή μέτρηση είναι «πόσο διήρκεσε». Στη difference-stationary (I(1)) το shock είναι *μόνιμο*: μετατοπίζει το επίπεδο για πάντα. Ίδιο γράφημα, αντίθετο policy συμπέρασμα — και διαφορετική θεραπεία (detrending vs differencing).

2. Αυτοσυσχέτιση σε δεδομένα vs κατάλοιπα.

Στα δεδομένα είναι η *πληροφορία* που θέλουμε να εκμεταλλευτούμε — χωρίς αυτήν δεν θα υπήρχε τίποτα προβλέψιμο. Στα κατάλοιπα σημαίνει ότι το μοντέλο *δεν* την εκμεταλλεύτηκε: έμεινε δομή αναξιοποίητη, τα standard errors είναι λάθος και οι προβλέψεις υποβέλτιστες.

3. $\rho(1)=0,95$, $T=60$.

Το ενεργό μέγεθος δείγματος είναι δραματικά μικρότερο. Πρόχειρη προσέγγιση: $T_{\text{eff}} \approx T \cdot (1-\rho)/(1+\rho) = 60 \cdot (0,05/1,95) \approx 1,5$. Ουσιαστικά έχεις ελάχιστη ανεξάρτητη πληροφορία. Το t-test θα δώσει ψευδώς μικρό p, γιατί υποθέτει 60 ανεξάρτητες παρατηρήσεις. Σωστό: ITS με διόρθωση αυτοσυσχέτισης (Newey-West/Prais-Winsten) ή ARIMA με intervention.

4. Εποχικότητα vs κύκλος.

Εποχικότητα = σταθερή, ημερολογιακά κλειδωμένη περίοδος γνωστή εκ των προτέρων (12, 4, 7). Κύκλος = μεταβλητή διάρκεια >1 έτος, μεταβλητό πλάτος, χωρίς ημερολογιακή αγκύρωση. Ο κύκλος είναι δύσκολα προβλέψιμος επειδή πρέπει να προβλέψεις και πότε γυρίζει και πόσο έντονα — δύο άγνωστοι αντί για κανέναν.

5. Υποχρεωτικά προσθετική αποσύνθεση.

Όταν η σειρά περιέχει μηδενικά ή αρνητικές τιμές — ο λογάριθμος δεν ορίζεται και η πολλαπλασιαστική μορφή καταρρέει. Εναλλακτικά: Box-Cox με $\lambda > 0$, ή μετατόπιση ($y+c$) με ρητή δήλωση, ή προσθετικό μοντέλο σε πραγματικές μονάδες.

6. Τα έξι πρώτα βήματα (δαπάνη ΕΟΠΥΥ, παρέμβαση 06/2022).

(1) Επιβεβαίωση ορισμού μεταβλητής και σταθερότητας μεθοδολογίας σε όλη την περίοδο — άλλαξε ο τρόπος καταγραφής; (2) Πλήρες ημερολόγιο 96 μηνών, εντοπισμός απόντων γραμμών και NaN. (3) Αποπληθωρισμός ή/και κανονικοποίηση (ανά ασφαλισμένο, ανά εργάσιμη ημέρα). (4) Raw plot + seasonal plot + rolling mean/SD· οπτικός εντοπισμός άλλων ασυνεχειών εκτός της 06/2022 (COVID 2020, clawback, ανατιμολογήσεις). (5) Καταγραφή όλων των συγχυτικών γεγονότων σε ημερολόγιο παρεμβάσεων — αυτό καθορίζει αν το ITS είναι καν επικτό. (6) Επιλογή/κατασκευή σειράς ελέγχου (θεραπευτική κατηγορία που δεν επηρεάστηκε) για controlled ITS. Μόνο μετά: στασιμότητα και μοντέλο.

7. Seasonal plot που αλλάζει σχήμα μετά το 2022.

Εξελισσόμενη (μη σταθερή) εποχικότητα — πιθανόν λόγω πραγματικής αλλαγής συμπεριφοράς. Η κλασική αποσύνθεση και οι σταθεροί εποχικοί δείκτες είναι λάθος. Επιλογή: **STL με μικρότερο παράθυρο seasonal** (π.χ. 7-13, όχι 'periodic') ή ETS με πολλαπλασιαστική/προσαρμοζόμενη εποχικότητα. Ταυτόχρονα: έλεγξε μήπως πρόκειται για structural break και όχι ομαλή εξέλιξη.

8. Rolling SD $\propto$ rolling mean.

Λογαριθμική μετατροπή (ή Box-Cox με $\lambda \approx 0$). Μετά, οι συντελεστές ερμηνεύονται ως *ποσοστιαίες* μεταβολές: συντελεστής β σε log-μοντέλο σημαίνει $\approx 100\beta\%$ μεταβολή (ακριβώς: $100(e^\beta - 1)\%$). Προσοχή στη back-transformation bias κατά την επιστροφή σε αρχικές μονάδες.

9. Μηνιαίες εισαγωγές, μέσος 8.

Το SARIMA υποθέτει συνεχή, προσεγγιστικά κανονική μεταβλητή με σταθερή διακύμανση· με μέσο 8 θα παράγει μη ακέραιες και ενδεχομένως αρνητικές προβλέψεις και λανθασμένα διαστήματα. Σωστό: **Poisson ή Negative Binomial regression** (υπερδιασπορά είναι ο κανόνας στα νοσοκομειακά δεδομένα) με χρονική τάση, αρμονικούς όρους για εποχικότητα (sin/cos) και offset τον πληθυσμό αναφοράς· ή INGARCH/GLARMA αν υπάρχει και αυτοσυσχέτιση.

10. F_S με $\text{Var}(R)=4$, $\text{Var}(S+R)=40$.

$F_S = \max\{0, 1 - 4/40\} = \mathbf{0,90}$. Πολύ ισχυρή εποχικότητα — η εποχική μοντελοποίηση είναι υποχρεωτική. Ένα μη εποχικό ARIMA θα αφήσει συστηματικά σφάλματα στους ίδιους μήνες κάθε χρόνο.

ΚΕΦΑΛΑΙΟ 5 — Στασιμότητα σε βάθος

Η στασιμότητα είναι η βάση όλης της κλασικής θεωρίας χρονοσειρών. Δεν είναι γραφειοκρατική απαίτηση: χωρίς αυτήν οι εκτιμητές δεν συγκλίνουν στις συνήθεις κατανομές, τα t-statistics δεν ακολουθούν t-κατανομή και τα συμπεράσματα μπορεί να είναι κυριολεκτικά τυχαία.

5.1 Αυστηρή vs ασθενής στασιμότητα

	Αυστηρή (strict)	Ασθενής (weak / covariance)
Ορισμός	Η από κοινού κατανομή είναι αμετάβλητη σε χρονική μετατόπιση: $F(Y_{t_1}, \dots, Y_{t_n}) = F(Y_{t_1+h}, \dots, Y_{t_n+h}) \quad \forall h$	Μόνο οι δύο πρώτες ροπές είναι σταθερές: $E[Y_t] = \mu, \text{Var}(Y_t) = \sigma^2 < \infty, \text{Cov}(Y_t, Y_{t-k}) = \gamma(k)$
Απαιτεί	Όλες τις ροπές και όλη τη μορφή κατανομής	Μόνο μέσο, διακύμανση, αυτοσυνδιακύμανση
Ελέγξιμη;	Πρακτικά όχι	Ναι — αυτή ελέγχουν τα ADF/KPSS
Σχέση	Strict + πεπερασμένη δεύτερη ροπή $\Rightarrow$ weak. Το αντίστροφο δεν ισχύει, εκτός αν η διαδικασία είναι Gaussian (τότε ταυτίζονται).	

Πρακτική διατύπωση

Μια σειρά είναι (ασθενώς) στάσιμη αν, κοιτώντας οποιοδήποτε «παράθυρο» της, δεν μπορείς να μα-ντέψεις πότε βρίσκεσαι. Δεν υπάρχει τάση, το επίπεδο δεν μετατοπίζεται, το πλάτος διακύμανσης είναι σταθερό, και η σχέση μεταξύ γειτονικών τιμών δεν αλλάζει με τον χρόνο.

5.2 Unit root, random walk και τάξη ολοκλήρωσης

Γράφουμε ένα AR(p) με τον τελεστή υστέρησης:

$$\phi(L)Y_t = (1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)Y_t = \varepsilon_t$$

Η διαδικασία είναι στάσιμη αν **όλες** οι ρίζες του $\phi(L)=0$ βρίσκονται **έξω** από τον μοναδιαίο κύκλο ($|L|>1$). Αν **μία** ρίζα ισούται ακριβώς με 1, έχουμε **unit root** και η σειρά είναι μη στάσιμη.

Τάξη	Ορισμός	Συμπεριφορά	Τυπικά παραδείγματα
I(0)	Ήδη στάσιμη· δεν χρειάζεται differencing	Επιστρέφει στον μέσο· σταθερή διακύμανση· ACF φθίνει γρήγορα	Επιτόκιο spread· ποσοστό ανεργίας (συζητήσιμο)· κατάλοιπα καλού μο-ντέλου
I(1)	ΔY_t είναι I(0)· μία unit root	Random walk· shocks μόνιμα· Var αυξάνεται με t	Λογάριθμος ΑΕΠ· τιμές μετοχών· επί-πεδο τιμών· φαρμακευτική δαπάνη
I(2)	$\Delta^2 Y_t$ είναι I(0)· δύο unit roots	Ακόμη και ο ρυθμός μεταβολής πε-ριπλανιέται	Επίπεδο τιμών σε περιόδους επιταχυ-νόμενου πληθωρισμού· σπάνιο και συνήθως ένδειξη λάθους προδιαγρα-φής

Σπάνια χρειάζεσαι I(2)

Αν τα τεστ δείχνουν I(2), πρώτα υποψιάσου: (α) structural break που μιμείται δεύτερη unit root, (β) λάθος επιλογή lags στο ADF, (γ) μη λογαριθμισμένη εκθετικά αυξανόμενη σειρά. Το log συχνά μετατρέπει «I(2)» σε I(1).

5.3 Trend-stationary vs difference-stationary

	Trend-stationary (TS)	Difference-stationary (DS)
Μοντέλο	$Y_t = \beta_0 + \beta_1 t + u_t$, u_t στάσιμο	$Y_t = \delta + Y_{t-1} + \varepsilon_t$
Πρόβλεψη μακράς περιόδου	Συγκλίνει στην ντετερμινιστική γραμμή	Ακολουθεί την τελευταία παρατήρηση + $\delta \cdot h$
Πλάτος διαστημάτων πρόβλεψης	Σταθεροποιείται	Διευρύνεται ως $\sqrt{h}$ — απεριόριστα
Σωστός χειρισμός	Detrend (ή συμπερίληψη του t ως regressor)	Differencing
Κόστος λάθους	Αν κάνεις differencing σε TS → over-differencing, εισάγεται μη αντιστρέψιμη MA(1) με $\theta = -1$, μεγαλύτερη διακύμανση προβλέψεων	Αν κάνεις detrending σε DS → η unit root παραμένει, spurious αποτελέσματα, ψευδώς «σημαντικοί» συντελεστές

5.4 Ψευδής παλινδρόμηση (Spurious regression)

Το κλασικό πείραμα των Granger & Newbold (1974): παίρνουμε δύο *εντελώς ανεξάρτητους* random walks και τους παλινδρομούμε τον έναν στον άλλον.

$$X_t = X_{t-1} + u_t, \quad Y_t = Y_{t-1} + v_t, \quad u \perp v$$

Παλινδρόμηση: $Y_t = \alpha + \beta X_t + e_t$

Το αληθινό β είναι μηδέν. Στην πράξη όμως, σε επαναλαμβανόμενες προσομοιώσεις:

Μέτρο	Τι θα περιμένες	Τι προκύπτει πραγματικά
Ποσοστό απόρριψης $H_0: \beta=0$ στο 5%	$\approx 5\%$	$\approx 70-75\%$
R^2	≈ 0	Συχνά 0,3-0,8
Durbin-Watson	≈ 2	Πολύ κοντά στο 0

Το διαγνωστικό σήμα: υψηλό R^2 μαζί με πολύ χαμηλό Durbin-Watson (κανόνας: $R^2 > DW$) είναι σχεδόν βέβαιη ένδειξη ψευδούς παλινδρόμησης.

Γιατί σε αφορά άμεσα

Παλινδρόμηση «φαρμακευτική δαπάνη ~ ΑΕΠ» σε επίπεδα, χωρίς έλεγχο unit root, θα δώσει σχεδόν σίγουρα $R^2=0,95$ και $p<0,001$ — ακόμη κι αν δεν υπάρχει καμία σχέση. Και οι δύο σειρές ανεβαίνουν με τον χρόνο· αυτό αρκεί. Οι λύσεις: (α) παλινδρόμηση σε πρώτες διαφορές, (β) έλεγχος συνολοκλήρωσης και VECM/ARDL αν υπάρχει, (γ) ρητή συμπερίληψη χρονικής τάσης.

5.5 Augmented Dickey-Fuller (ADF)

Το ADF ελέγχει την ύπαρξη μοναδιαίας ρίζας. Ξεκινά από $Y_t = \phi Y_{t-1} + \varepsilon_t$, αφαιρεί Y_{t-1} και από τις δύο πλευρές ($\phi = \phi - 1$) και προσθέτει υστερήσεις των διαφορών ώστε τα κατάλοιπα να γίνουν λευκός θόρυβος (αυτό είναι το «Augmented»):

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^p \delta_i \Delta Y_{t-i} + \varepsilon_t$$

H_0	$\gamma = 0$ (ισοδύναμα $\phi = 1$) → υπάρχει μοναδιαία ρίζα → η σειρά ΔΕΝ είναι στάσιμη
H_1	$\gamma < 0$ → η σειρά είναι στάσιμη (ή trend-stationary, ανάλογα με τη μορφή)
Στατιστική	$t = \hat{\gamma} / SE(\hat{\gamma})$. Δεν ακολουθεί t-κατανομή· χρησιμοποιούνται οι κρίσιμες τιμές Dickey-Fuller (πιο αρνητικές από τις συνήθειες)
$p < 0,05$	Απορρίπτεται η H_0 → δεν υπάρχει ένδειξη unit root → στάσιμη
$p > 0,05$	Δεν απορρίπτεται → μη στάσιμη. Προσοχή στη διατύπωση: «αποτυγχάνουμε να απορρίψουμε», όχι «αποδεικνύουμε ότι υπάρχει unit root». Το ADF έχει χαμηλή ισχύ.

Οι τρεις εκδοχές — η επιλογή έχει σημασία

Εκδοχή	Όροι	Πότε τη χρησιμοποιείς
none	Χωρίς α , χωρίς t	Σειρά που κυμαίνεται γύρω από το μηδέν (π.χ. αποδόσεις, κατάλοιπα)
c (drift)	Με σταθερά α	Σειρά με μη μηδενικό μέσο αλλά χωρίς ορατή τάση
ct (trend)	Με α και βt	Σειρά με ορατή τάση. Η πιο συνηθισμένη επιλογή σε οικονομικά/υγειονομικά δεδομένα.

Το πιο συχνό λάθος στο ADF

Να τρέξεις τη **c** εκδοχή σε σειρά με ορατή τάση. Θα σου πει «μη στάσιμη» ακόμη κι αν είναι trend-stationary, γιατί η τάση δεν έχει μοντελοποιηθεί και εμφανίζεται ως μη στασιμότητα. **Πάντα κοίτα το γράφημα πριν επιλέξεις εκδοχή.**

Επιλογή αριθμού lags (p)

- **Πληροφοριακά κριτήρια** (AIC/BIC) με αυτόματη επιλογή — η προεπιλογή στο `statsmodels` (`autolag='AIC'`).
- **Κανόνας Schwert**: $p_{\max} = \lfloor 12 \cdot (T/100)^{1/4} \rfloor$ ως ανώτατο όριο.
- **Κριτήριο ελέγχου**: ό,τι κι αν επιλέξεις, τα κατάλοιπα του ADF πρέπει να είναι λευκός θόρυβος. Πολύ λίγα lags → μεροληψία μεγέθους (over-rejection)· πολλά lags → απώλεια ισχύος.

5.6 KPSS — το συμπληρωματικό τεστ

Το KPSS (Kwiatkowski, Phillips, Schmidt & Shin, 1992) έχει **αντεστραμμένη** μηδενική υπόθεση. Αυτό είναι το σημείο που μπερδεύει τους περισσότερους.

$$Y_t = \xi t + r_t + \varepsilon_t, \text{ με } r_t = r_{t-1} + u_t, u_t \sim WN(0, \sigma_u^2)$$

H_0	$\sigma_u^2 = 0$ → η σειρά ΕΙΝΑΙ στάσιμη (γύρω από επίπεδο ή γύρω από τάση)
H_1	$\sigma_u^2 > 0$ → υπάρχει στοχαστική τάση → μη στάσιμη
$p < 0,05$	Απορρίπτεται η στασιμότητα → μη στάσιμη
$p > 0,05$	Δεν απορρίπτεται → συμβατή με στασιμότητα

Μνημονικός κανόνας

ADF: «ένοχη μέχρι αποδείξεως του αντιθέτου» — H_0 = μη στάσιμη. · **KPSS:** «αθώα μέχρι αποδείξεως του αντιθέτου» — H_0 = στάσιμη. Ένα μικρό p στο ADF είναι καλά νέα· ένα μικρό p στο KPSS είναι κακά νέα.

5.7 Phillips-Perron (PP)

Ίδια H_0 με το ADF (υπάρχει unit root), αλλά αντί να προσθέτει lagged differences, διορθώνει **μη παραμετρικά** τη στατιστική για αυτοσυσχέτιση και ετεροσκεδαστικότητα (Newey-West τύπου διόρθωση).

Πότε προτιμάται	Πλεονεκτήματα	Μειονεκτήματα
Όταν υπάρχει ετεροσκεδαστικότητα· όταν δεν θέλεις να διαλέξεις αριθμό lags· ως έλεγχος ευρωστίας δίπλα στο ADF	Ανθεκτικό σε γενική μορφή αυτοσυσχέτισης/ετεροσκεδαστικότητας· δεν απαιτεί επιλογή p	Κακή συμπεριφορά σε μικρά δείγματα· ευαίσθητο σε αρνητικά αυτοσυσχετισμένους όρους MA· χαμηλή ισχύς όπως και το ADF

ΚΑΙ ΑΛΛΑ ΔΥΟ ΠΟΥ ΑΞΙΖΕΙ ΝΑ ΞΕΡΕΙΣ: **Zivot-Andrews** — unit root test που επιτρέπει *έναν ενδογενή structural break*· απαραίτητο όταν η σειρά έχει προφανές άλμα (COVID!). **HEGY** — έλεγχος εποχικών unit roots, για να αποφασίσεις αν χρειάζεσαι εποχικό differencing.

5.8 Ο πίνακας συνδυασμού ADF × KPSS

Αυτός ο πίνακας είναι το πιο πρακτικό εργαλείο του κεφαλαίου. Κρέμασέ τον πάνω από το γραφείο σου.

ADF	KPSS	Ερμηνεία	Επόμενο βήμα
Απορρίπτει H_0 (στάσιμη)	Δεν απορρίπτει (στάσιμη)	Συμφωνία: $I(0)$. Η σειρά είναι στάσιμη. Το πιο ξεκάθαρο σενάριο.	Προχώρα σε μοντελοποίηση επιπέδων: ARMA, VAR σε επίπεδα, κανονική παλινδρόμηση
Δεν απορρίπτει (μη στάσιμη)	Απορρίπτει (μη στάσιμη)	Συμφωνία: μη στάσιμη, πιθανά $I(1)$	Πάρε πρώτες διαφορές και επανάλαβε και τα δύο τεστ. Αν τώρα συμφωνούν σε στασιμότητα → $I(1)$
Δεν απορρίπτει (μη στάσιμη)	Δεν απορρίπτει (στάσιμη)	Ασαφές — ανεπαρκής πληροφορία. Και τα δύο τεστ «δεν ξέρουν». Συχνό σε μικρά δείγματα ή σε σειρές με μεγάλη μνήμη.	Μην αποφασίσεις μηχανικά. Δες το γράφημα και το ACF· δοκίμασε PP και Zivot-Andrews· εξέτασε fractional integration (ARFIMA)· κάνε ανάλυση ευαισθησίας με και χωρίς differencing
Απορρίπτει (στάσιμη)	Απορρίπτει (μη στάσιμη)	Αντίφαση. Ισχυρή ένδειξη λάθος προδιαγραφής: πιθανός structural break, εξελισσόμενη διακύμανση, ή trend-stationarity που δεν μοντελοποιήθηκε	Ψάξε structural break (Zivot-Andrews, Bai-Perron)· δοκίμασε ADF με τάση (ct) και KPSS με τάση· εξέτασε log για σταθεροποίηση διακύμανσης

Πρωτόκολλο σε 5 βήματα

1. Γράφημα + ACF. Αν το ACF φθίνει πολύ αργά και γραμμικά, ήδη υποψιάζεσαι $I(1)$. **2.** Επίλεξε εκδοχή ADF με βάση το γράφημα (c ή ct). **3.** Τρέξε ADF και KPSS με την ίδια προδιαγραφή. **4.** Διάβασε τον πίνακα παραπάνω. **5.** Αν χρειαστεί differencing, εφάρμοσέ το μία φορά και επανάλαβε τα τεστ. Ποτέ δύο διαφορές χωρίς έλεγχο ενδιάμεσα.

```
from statsmodels.tsa.stattools import adfuller, kpss

adf = adfuller(y, regression='ct', autolag='AIC')
print(f"ADF stat={adf[0]:.3f}  p={adf[1]:.4f}  lags={adf[2]}")

kps = kpss(y, regression='ct', nlags='auto')
print(f"KPSS stat={kps[0]:.3f}  p={kps[1]:.4f}")
# ΠΡΟΣΟΧΗ: το p του KPSS είναι πλαφοναρισμένο στο [0.01, 0.10]
```


ΚΕΦΑΛΑΙΟ 6 — Μετασχηματισμοί

Δύο εντελώς διαφορετικά προβλήματα, δύο διαφορετικές οικογένειες λύσεων. Η σύγχυσή τους είναι από τα συχνότερα λάθη.

Πρόβλημα	Ένδειξη	Λύση
Μη σταθερή διακύμανση	Σχήμα χοάνης· rolling SD $\propto$ rolling mean	Λογάριθμος ή Box-Cox
Μη σταθερός μέσος	Τάση· level shifts· ACF που φθίνει αργά	Differencing ή detrending

Η σειρά των πράξεων

Πρώτα σταθεροποίηση διακύμανσης (log/Box-Cox), μετά σταθεροποίηση μέσου (differencing). Ποτέ το αντίστροφο: το differencing μιας ετεροσκεδαστικής σειράς παράγει ακόμη πιο άσχημη σειρά.

6.1 Λογαριθμικός μετασχηματισμός

$$w_t = \log(Y_t), \text{ απαιτεί } Y_t > 0$$

Τι κάνει: (α) σταθεροποιεί διακύμανση που είναι αναλογική του επιπέδου· (β) μετατρέπει πολλαπλασιαστική εποχικότητα σε προσθετική· (γ) μετατρέπει εκθετική τάση σε γραμμική· (δ) δίνει συντελεστές με ερμηνεία ποσοστιαίας μεταβολής.

Ερμηνεία: $\Delta \log(Y_t) \approx$ ποσοστιαία μεταβολή. Για μικρές μεταβολές ($<10\%$) η προσέγγιση είναι πολύ καλή· για μεγάλες, η ακριβής σχέση είναι $100 \cdot (e^{\Delta \log Y} - 1)\%$.

6.2 Box-Cox

$$w_t = \begin{cases} \log(Y_t) & \text{αν } \lambda = 0 \\ (Y_t^\lambda - 1)/\lambda & \text{αν } \lambda \neq 0 \end{cases}$$

λ	Μετασχηματισμός	Πότε προκύπτει
1	Ουσιαστικά κανένας (γραμμική μετατόπιση)	Η διακύμανση είναι ήδη σταθερή
0,5	Τετραγωνική ρίζα	Δεδομένα μετρήματος (counts)· ήπια ετεροσκεδαστικότητα
0	Λογάριθμος	Διακύμανση αναλογική του επιπέδου — το πιο συχνό σε οικονομικά δεδομένα
-1	Αντίστροφο	Πολύ έντονη ετεροσκεδαστικότητα (σπάνιο)

Επιλογή λ : μεγιστοποίηση της log-likelihood (μέθοδος Guerrero ή προφίλ πιθανοφάνειας). Στην πράξη, αν το βέλτιστο λ είναι κοντά στο 0 ή στο 0,5, *στρογγυλοποίησε* — η ερμηνευσιμότητα αξίζει περισσότερο από το τρίτο δεκαδικό.

Back-transformation bias

Αν προβλέψεις σε $\log$ και μετά πάρεις $\exp()$, παίρνεις τη **διάμεσο**, όχι τον **μέσο** — συστηματική υποεκτίμηση. Η διόρθωση: $E[Y] \approx \exp(\hat{w}) \cdot (1 + \sigma^2/2)$. Τα διαστήματα πρόβλεψης, αντίθετα, μετασχηματίζονται σωστά με απλή $\exp()$ (τα ποσοστημόρια είναι αναλλοίωτα σε μονότονους μετασχηματισμούς). Οι σοβαρές βιβλιοθήκες (`fable`, `statsmodels` με ρητή ρύθμιση) το χειρίζονται — αλλά έλεγξέ το.

6.3 Differencing

$$\text{Πρώτη διαφορά: } \Delta Y_t = Y_t - Y_{t-1} = (1-L)Y_t$$

$$\text{Δεύτερη διαφορά: } \Delta^2 Y_t = \Delta(\Delta Y_t) = Y_t - 2Y_{t-1} + Y_{t-2} = (1-L)^2 Y_t$$

$$\text{Εποχική διαφορά (περίοδος } s): \Delta_s Y_t = Y_t - Y_{t-s} = (1-L^s)Y_t$$

$$\text{Για μηνιαία: } Y_t - Y_{t-12} \quad \cdot \quad \text{Για τριμηνιαία: } Y_t - Y_{t-4}$$

$$\text{Συνδυασμένη: } (1-L)(1-L^{12})Y_t = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$$

Ποια σειρά πρώτα;

Αν χρειάζεσαι και τα δύο, κάνε **πρώτα την εποχική διαφορά**. Πολύ συχνά αρκεί αυτή και μόνη της· η μη στασιμότητα «εξαφανίζεται» επειδή ήταν εποχικής προέλευσης. Μετά επανέλεγγε πριν προσθέσεις πρώτη διαφορά.

Πόσες διαφορές; Ο κανόνας των τριών ελέγχων

1. **Οπτικά**: η σειρά κυμαίνεται γύρω από σταθερό επίπεδο;
2. **Τεστ**: ADF και KPSS συμφωνούν σε στασιμότητα;
3. **ACF**: φθίνει γρήγορα; Δεν υπάρχει μεγάλο αρνητικό spike στο lag 1;

Πρόβλημα	Πώς το αναγνωρίζεις	Συνέπεια
Under-differencing	ACF φθίνει πολύ αργά, σχεδόν γραμμικά· PACF με spike κοντά στο 1 στο lag 1· τεστ δείχνουν μη στασιμότητα	Spurious συμπεράσματα, ασυνεπείς εκτιμήσεις, λάθος standard errors
Over-differencing	Έντονο αρνητικό spike στο ACF στο lag 1 (κοντά στο -0,5)· αυξημένη διακύμανση της διαφορισμένης σειράς σε σχέση με τη μη διαφορισμένη	Εισάγεται μη αντιστρέψιμη MA(1) με $\theta = -1$ · χειρότερες προβλέψεις· προβλήματα σύγκλισης στην εκτίμηση

Το απλούστερο διαγνωστικό για over-differencing

Σύγκρινε τη διακύμανση: $\text{Var}(Y)$, $\text{Var}(\Delta Y)$, $\text{Var}(\Delta^2 Y)$. Παίρνεις διαφορές όσο η διακύμανση **μειώνεται**. Μόλις αρχίσει να αυξάνεται, έχεις ήδη ξεπεράσει το βέλτιστο κατά μία.

6.4 Detrending

Παλινδρόμηση $Y_t = \beta_0 + \beta_1 t + u_t$ και εργασία με τα κατάλοιπα $\hat{u}_t$.

Πότε είναι σωστό	Πότε είναι λάθος
Σειρά trend-stationary (ADF με <code>ct</code> απορρίπτει την H_0). Θέλεις να διατηρήσεις την ερμηνευσιμότητα των επιπέδων. ITS όπου η τάση είναι μέρος του μοντέλου ενδιαφέροντος	Σειρά με στοχαστική τάση ($I(1)$) — το detrending δεν αφαιρεί την unit root και τα αποτελέσματα παραμένουν ψευδή

6.5 Γιατί ποτέ μηχανικά

Τέσσερις λόγοι

1. Το differencing καταστρέφει πληροφορία μακροχρόνιας σχέσης. Αν δύο σειρές είναι συνολοκληρωμένες, η παλινδρόμηση σε διαφορές πετάει ακριβώς την πληροφορία που σε ενδιαφέρει (βλ. VECM, Τεύχος Γ').
2. Αλλάζει το ερώτημα. Μοντέλο σε επίπεδα απαντά «πόση δαπάνη;»· σε διαφορές απαντά «πόση μεταβολή δαπάνης;». Δεν είναι το ίδιο ερώτημα.
3. Ένα structural break μιμείται unit root. Το ADF θα ζητήσει differencing εκεί που το σωστό είναι dummy μετατόπισης.
4. Τα ίδια τα τεστ έχουν χαμηλή ισχύ σε μικρά δείγματα. Με $T=60$ δεν διακρίνουν αξιόπιστα $\phi=1$ από $\phi=0,92$.

ΚΕΦΑΛΑΙΟ 7 — Αυτοσυσχέτιση: ACF και PACF

7.1 Οι δύο συναρτήσεις

ACF: $\rho(k) = \text{Corr}(Y_t, Y_{t-k})$ — η ολική συσχέτιση με το lag k

PACF: $\alpha(k) = \text{Corr}(Y_t, Y_{t-k} \mid Y_{t-1}, \dots, Y_{t-k+1})$ — η καθαρή συσχέτιση, αφού αφαιρεθεί η επίδραση των ενδιάμεσων υστερήσεων

Η διαίσθηση: Αν το σήμερα εξαρτάται από το χθες και το χθες από το προχθές, τότε το σήμερα συσχετίζεται με το προχθές *έμμεσα*. Το ACF βλέπει αυτή την έμμεση συσχέτιση· το PACF την αφαιρεί και δείχνει μόνο την άμεση.

Ζώνες σημαντικότητας: $\pm 1,96/\sqrt{T}$. Ράβδοι εντός των ζωνών θεωρούνται στατιστικά μη διακρίσιμες από το μηδέν. Προσοχή: με 40 lags, ~2 ράβδοι θα βγουν «σημαντικές» καθαρά από τύχη.

7.2 Ο πίνακας ταυτοποίησης (Box-Jenkins)

Μοντέλο	ACF	PACF	Οπτική εικόνα
AR(p)	Φθίνει σταδιακά (εκθετικά ή με αποσβεννύμενη ταλάντωση)	Μηδενίζεται απότομα μετά το lag p	PACF: p καθαρές ράβδοι και μετά τίποτα
MA(q)	Μηδενίζεται απότομα μετά το lag q	Φθίνει σταδιακά	ACF: q καθαρές ράβδοι και μετά τίποτα
ARMA(p,q)	Φθίνει σταδιακά	Φθίνει σταδιακά	Καμία καθαρή αποκοπή — χρειάζεται πληροφοριακά κριτήρια
Λευκός θόρυβος	Όλα εντός ζωνών	Όλα εντός ζωνών	Ο στόχος για τα κατάλοιπα
Μη στάσιμη	Πολύ αργή, σχεδόν γραμμική φθίση· παραμένει υψηλό σε μεγάλα lags	Κυρίαρχο spike στο lag 1 ≈ 1	Χρειάζεται differencing πριν από οτιδήποτε άλλο
Εποχικότητα	Κορυφές στα lags $s, 2s, 3s, \dots$	Κορυφή στο lag s (και ίσως $2s$)	Χρειάζεται εποχικός όρος (P, D, Q)

7.3 Γιατί ΔΕΝ επιλέγουμε μοντέλο μόνο από ACF/PACF

Έξι λόγοι

- Δειγματική αβεβαιότητα.** Το δειγματικό ACF έχει τη δική του διακύμανση· «καθαρές αποκοπές» σπάνια εμφανίζονται σε πραγματικά δεδομένα με $T < 100$.
- Πολλαπλοί έλεγχοι.** Κοιτάζοντας 40 lags, θα βρεις «σημαντικά» spikes τυχαία.
- Μεικτά μοντέλα.** Στα ARMA και οι δύο συναρτήσεις φθίνουν — η ταυτοποίηση είναι αδύνατη οπτικά.
- Εποχικά + μη εποχικά μπλέκουν.** Σε SARIMA, οι αλληλεπιδράσεις παράγουν spikes σε lags όπως $s-1, s+1$ που παραπλανούν.
- Outliers και breaks παραμορφώνουν το ACF** δραματικά.
- Το ACF είναι μέτρο γραμμικής εξάρτησης.** Μη γραμμικές δομές δεν εμφανίζονται.

Η σωστή διαδικασία

ACF/PACF → υποψήφια μοντέλα (2-5) → εκτίμηση όλων → σύγκριση με AICc → **residual diagnostics** (Ljung-Box) → **out-of-sample backtesting έναντι baseline** → τελική επιλογή. Το ACF/PACF είναι το πρώτο βήμα, όχι το τελευταίο.

7.4 Ljung-Box: ο ομαδικός έλεγχος

Αντί να κοιτάς κάθε ράβδο χωριστά, ελέγχεις όλες μαζί.

$$Q_{LB} = T(T+2) \sum_{k=1}^h r_k^2 / (T-k) \sim \chi^2_{(h-m)}$$

H₀	Οι πρώτες h αυτοσυσχετίσεις είναι από κοινού μηδέν → λευκός θόρυβος
H₁	Τουλάχιστον μία είναι μη μηδενική → υπάρχει εναπομείνισα δομή
p > 0,05	Καλά νέα: τα κατάλοιπα είναι συμβατά με λευκό θόρυβο
p < 0,05	Πρόβλημα: το μοντέλο άφησε δομή αναξιοποίητη → αναθεώρησε την προδιαγραφή

Επιλογή h: h = 10 για μη εποχικά, h = 2s για εποχικά. **Βαθμοί ελευθερίας:** αφάιρεσε m = p+q (τις εκτιμημένες παραμέτρους) όταν το εφαρμόζεις σε κατάλοιπα μοντέλου — αλλιώς το τεστ είναι υπερβολικά συντηρητικό.

ΚΕΦΑΛΑΙΟ 8 — Μοντέλα πρόβλεψης

8.1 Baselines — τα μοντέλα που πρέπει ΠΑΝΤΑ να νικήσεις

Κανένα «προχωρημένο» μοντέλο δεν έχει αξία αν δεν αποδεικνύεται καλύτερο από αυτά τα τέσσερα. Είναι δωρεάν, αστραπιαία, και εκπληκτικά δύσκολο να νικηθούν.

Μέθοδος	Εξίσωση πρόβλεψης	Λογική	Πότε είναι δύσκολα νικήσιμη
Mean	$\hat{y}_{T+h} = \bar{y} = (1/T)\sum y_t$	Όλες οι παρατηρήσεις μετρούν εξίσου	Στάσιμη σειρά χωρίς τάση ή δομή
Naive	$\hat{y}_{T+h} = y_T$	Το αύριο μοιάζει με το σήμερα	Random walk — βέλτιστη για χρηματοοικονομικές τιμές
Drift	$\hat{y}_{T+h} = y_T + h \cdot (y_T - y_1) / (T-1)$	Naive + η μέση ιστορική κλίση· ισοδύναμο με ευθεία από την πρώτη στην τελευταία παρατήρηση	Random walk with drift — μακροοικονομικές σειρές
Seasonal Naive	$\hat{y}_{T+h} = y_{T+h-ms}$ (η τιμή της ίδιας εποχής της τελευταίας διαθέσιμης περιόδου)	Ό,τι έγινε πέρυσι τον ίδιο μήνα	Ισχυρά εποχικές σειρές — αυτό είναι το benchmark που πρέπει να νικήσεις στη φαρμακευτική αγορά

Χρήση στο MASE

Το Mean Absolute Scaled Error (Τεύχος Δ') ορίζεται ως ο λόγος του MAE σου προς το MAE του naive (ή seasonal naive) στο training set. $MASE < 1$ σημαίνει «καλύτερο από naive». $MASE > 1$ σημαίνει ότι έχτισες κάτι πολύπλοκο για να κάνεις χειρότερη δουλειά από μια γραμμή κώδικα.

8.2 Εκθετική εξομάλυνση (Exponential Smoothing)

Η κεντρική ιδέα: οι πρόσφατες παρατηρήσεις μετρούν περισσότερο, με εκθετικά φθίνοντα βάρη.

SES — Simple Exponential Smoothing

$$\hat{y}_{t+1} = \alpha y_t + (1-\alpha)\hat{y}_t, \quad 0 < \alpha < 1$$

$$\text{Ισοδύναμα: } \hat{y}_{t+1} = \alpha y_t + \alpha(1-\alpha)y_{t-1} + \alpha(1-\alpha)^2 y_{t-2} + \dots$$

$$\text{Μορφή συνιστωσών: } l_t = \alpha y_t + (1-\alpha)l_{t-1}, \quad \hat{y}_{t+h} = l_t$$

Υποθέσεις	Καμία τάση, καμία εποχικότητα· το επίπεδο μεταβάλλεται αργά
Χρήση	Στάσιμες ή σχεδόν στάσιμες σειρές· βραχυπρόθεσμος ορίζοντας
Όχι όταν	Υπάρχει σαφής τάση ή εποχικότητα — θα υστερεί συστηματικά
+ / −	Μία μόνο παράμετρος, πολύ εύρωστο, ελάχιστα δεδομένα / Επίπεδη πρόβλεψη για κάθε h — αγνοεί κάθε δυναμική
Παράδειγμα	Μηνιαίες πωλήσεις ώριμου φαρμάκου χωρίς εποχικότητα, σε σταθερή αγορά

Holt — γραμμική τάση

$$\begin{aligned} \ell_t &= \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1}) \quad (\text{επίπεδο}) \\ b_t &= \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1} \quad (\text{κλίση}) \\ \hat{y}_{t+h} &= \ell_t + h \cdot b_t \end{aligned}$$

ΠΡΟΒΛΗΜΑ: η τάση προεκτείνεται γραμμικά επ' άπειρον. Σε ορίζοντα 24 μηνών αυτό παράγει συχνά παράλογες τιμές.

Holt με απόσβεση (damped trend)

$$\begin{aligned} \hat{y}_{t+h} &= \ell_t + (\varphi + \varphi^2 + \dots + \varphi^h)b_t, \quad 0 < \varphi < 1 \\ \text{Καθώς } h &\rightarrow \infty, \text{ η πρόβλεψη συγκλίνει σε } \ell_t + \varphi b_t / (1-\varphi) \end{aligned}$$

Εμπειρικό εύρημα που αξίζει να θυμάσαι

Στους μεγάλους διαγωνισμούς πρόβλεψης (M3, M4), η **damped trend** είναι από τις σταθερά κορυφαίες απλές μεθόδους. Οι πραγματικές τάσεις σχεδόν πάντα εξασθενούν· η υπόθεση απεριόριστης γραμμικής ανάπτυξης είναι η πιο συχνή αιτία καταστροφικών μεσοπρόθεσμων προβλέψεων. Τυπικό φ : 0,80–0,98.

Holt-Winters — τάση + εποχικότητα

Προσθετική εποχικότητα:

$$\begin{aligned} \ell_t &= \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\ b_t &= \beta^*(\ell_t - \ell_{t-1}) + (1-\beta^*)b_{t-1} \\ s_t &= \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)s_{t-m} \\ \hat{y}_{t+h} &= \ell_t + h \cdot b_t + s_{t+h-m(k+1)} \end{aligned}$$

$$\text{Πολλαπλασιαστική: } \hat{y}_{t+h} = (\ell_t + h \cdot b_t) \times s_{t+h-m(k+1)}$$

ΕΠΙΛΟΓΗ: προσθετική αν το εποχικό πλάτος είναι σταθερό· πολλαπλασιαστική αν μεγαλώνει με το επίπεδο. Για φαρμακευτικές πωλήσεις: σχεδόν πάντα **πολλαπλασιαστική**.

ETS — η πλήρης ταξινόμια

Το ETS (Error, Trend, Seasonal) δίνει στατιστικό θεμέλιο (state space μοντέλα) σε όλη την οικογένεια και επιτρέπει αυτόματη επιλογή μέσω AICc, καθώς και σωστά διαστήματα πρόβλεψης.

Συνιστώσα	Επιλογές
Error (E)	A = προσθετικό (σταθερή διακύμανση) · M = πολλαπλασιαστικό (διακύμανση $\propto$ επίπεδο)
Trend (T)	N = καμία · A = προσθετική · A _d = προσθετική με απόσβεση
Seasonal (S)	N = καμία · A = προσθετική · M = πολλαπλασιαστική

Παραδείγματα αντιστοίχισης: ETS(A,N,N) = SES · ETS(A,A,N) = Holt · ETS(A,A_d,N) = damped Holt · ETS(A,A,A) = προσθετικό Holt-Winters · **ETS(M,A_d,M)** = η πιο συχνή επιλογή για πραγματικές πωλήσεις.

Περιορισμοί ETS

Δεν δέχεται εξωγενείς μεταβλητές (χωρίς X). Δεν χειρίζεται structural breaks. Μερικοί συνδυασμοί (π.χ. πολλαπλασιαστική εποχικότητα με μηδενικά) είναι αριθμητικά ασταθείς. Για ITS ή για μοντέλα με predictors χρειάζεσαι ARIMA/regression.

8.3 Η οικογένεια ARIMA**AR(p) — Autoregressive**

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

ΛΟΓΙΚΗ: η σειρά εξηγείται από τις προηγούμενες τιμές της. **ΥΠΟΘΕΣΕΙΣ:** στασιμότητα (ρίζες $\phi(L)$ εκτός μοναδιαίου κύκλου), ε_t λευκός θόρυβος. **ΤΑΥΤΟΠΟΙΗΣΗ:** PACF μηδενίζεται μετά το p. **ΠΑΡΑΔΕΙΓΜΑ:** ποσοστό πληρότητας κλινών — η σημερινή τιμή εξαρτάται άμεσα από τη χθεσινή.

MA(q) — Moving Average

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

ΛΟΓΙΚΗ: η σειρά εξηγείται από τα προηγούμενα *σφάλματα* (shocks) — ένα shock επηρεάζει για q περιόδους και μετά σβήνει εντελώς. **ΥΠΟΘΕΣΕΙΣ:** πάντα στάσιμο· απαιτείται αντιστρεψιμότητα για μοναδική αναπαράσταση. **ΤΑΥΤΟΠΟΙΗΣΗ:** ACF μηδενίζεται μετά το q. **ΠΑΡΑΔΕΙΓΜΑ:** πωλήσεις μετά από προωθητική ενέργεια — η επίδραση διαρκεί 2-3 μήνες και εξαφανίζεται.

ARMA(p,q) και ARIMA(p,d,q)

$$\text{ARMA: } \phi(L)Y_t = c + \theta(L)\varepsilon_t$$

$$\text{ARIMA: } \phi(L)(1-L)^d Y_t = c + \theta(L)\varepsilon_t$$

Παράμετρος	Σημασία	Πώς την επιλέγεις
p	Αριθμός αυτοπαλίνδρομων όρων	PACF cutoff· επιβεβαίωση με AICc
d	Φορές differencing για στασιμότητα	ADF/KPSS· κανόνας διακύμανσης· σχεδόν πάντα 0, 1 ή 2
q	Αριθμός όρων κινητού μέσου	ACF cutoff· επιβεβαίωση με AICc

Ισοδυναμίες που ξεκαθαρίζουν τη λογική

ARIMA(0,1,0) = random walk · ARIMA(0,1,0) με σταθερά = random walk with drift · ARIMA(0,1,1) $\approx$ SES · ARIMA(0,2,2) $\approx$ Holt · ARIMA(1,0,0) = AR(1). Κάθε γραμμική exponential smoothing μέθοδος έχει ισοδύναμο ARIMA — αλλά οι πολλαπλασιαστικές ETS δεν έχουν.

SARIMA(p,d,q)(P,D,Q)_s

$$\Phi(L^s)\phi(L)(1-L^s)^D(1-L)^d Y_t = \Theta(L^s)\theta(L)\varepsilon_t$$

Παράμετρος	Ερμηνεία
P	Εποχικοί AR όροι: εξάρτηση από τον ίδιο μήνα προηγούμενων ετών (lag s, 2s...)
D	Εποχικές διαφορές. Σχεδόν πάντα 0 ή 1· ποτέ D>1
Q	Εποχικοί MA όροι: εξάρτηση από εποχικά shocks
s	Εποχική περίοδος: 12 (μηνιαία), 4 (τριμηνιαία), 7 (ημερήσια/εβδομαδιαίο μοτίβο)

Πρακτικός κανόνας: $d + D \leq 2$. Αν χρειάζεσαι περισσότερες διαφορές, κάτι άλλο πάει στραβά (πιθανά break ή μη λογαριθμισμένη εκθετική σειρά).

Το πιο συχνό SARIMA στην πράξη: $\text{SARIMA}(0,1,1)(0,1,1)_{12}$ — το «airline model» του Box-Jenkins. Είναι η πρώτη υποψηφιότητα για σχεδόν κάθε μηνιαία εποχική σειρά με τάση.

ARIMAX / SARIMAX — με εξωγενείς μεταβλητές

$$Y_t = \beta'X_t + \eta_t, \text{ όπου το } \eta_t \text{ ακολουθεί SARIMA}$$

Αυτή είναι η μορφή «δυναμικής παλινδρόμησης»: το X εξηγεί ό,τι μπορεί, και ο όρος σφάλματος η_t μοντελοποιείται ως SARIMA ώστε τα τελικά ε_t να είναι λευκός θόρυβος.

Ο κανόνας που ακυρώνει τα περισσότερα SARIMAX

Για να προβλέψεις το Y στον χρόνο $T+h$, χρειάζεσαι το X στον χρόνο $T+h$. Αν το X είναι άγνωστο στο μέλλον (π.χ. «θα προβλέψω πωλήσεις με βάση το ΑΕΠ»), τότε πρέπει πρώτα να προβλέψεις το ΑΕΠ — και εισάγεις τη δική του αβεβαιότητα, συνήθως μεγαλύτερη από το όφελος.

Επιτρεπτά X : ημερολογιακά (αργίες, εργάσιμες), γνωστές μελλοντικές αποφάσεις (ημερομηνία εφαρμογής πολιτικής, προγραμματισμένη προώθηση), υστερημένες μεταβλητές με $\text{lag} \geq h$.

Προβληματικά X : ταυτόχρονες μακροοικονομικές μεταβλητές, τιμές ανταγωνιστών, οτιδήποτε απαιτεί δική του πρόβλεψη.

Κρίσιμη χρήση για σένα: Το ITS είναι στην ουσία SARIMAX όπου τα X είναι οι μεταβλητές παρέμβασης (level dummy, slope term). Εκεί το X είναι απολύτως γνωστό — γι' αυτό δουλεύει. Πλήρης ανάπτυξη στο Τεύχος Γ'.

8.4 Συγκριτικός πίνακας επιλογής

Μοντέλο	Πότε ΝΑΙ	Πότε ΟΧΙ	Πλεονεκτήματα	Μειονεκτήματα
Seasonal Naive	Πάντα ως benchmark· ισχυρή σταθερή εποχικότητα	Ως τελικό μοντέλο όταν υπάρχει σαφής τάση	Μηδενικό κόστος· αδύνατο να υπερπροσαρμοστεί	Αγνοεί τάση και πρόσφατη πληροφορία
ETS	Καθαρή τάση/εποχικότητα· λίγα δεδομένα (≥ 2 πλήρεις κύκλοι)· αυτοματοποίηση σε πολλές σειρές	Χρειάζονται εξωγενείς μεταβλητές· υπάρχουν breaks· αιτιακό ερώτημα	Εύρωστο, γρήγορο, σωστά διαστήματα, ελάχιστο tuning	Χωρίς X · χωρίς ερμηνεία δυναμικής· χωρίς causal χρήση
ARIMA	Σύνθετη αυτοσυσχέτιση· ανάγκη διαγνωστικών· βάση για ITS	Πολύ μικρό δείγμα ($T < 30$)· έντονη μη γραμμικότητα· intermittent data	Θεωρητικά θεμελιωμένο· ευέλικτο· επεκτείνεται σε X	Απαιτεί στασιμότητα και κρίση· ευάλωτο σε breaks· δυσκολότερη αυτοματοποίηση
SARIMA	Μηνιαία/τριμηνιαία με ισχυρή εποχικότητα	Πολλαπλή εποχικότητα· $s > 24$ (π.χ. εβδομαδιαία με $s=52$)	Το πρότυπο για εποχικά οικονομικά δεδομένα	Πολλές παράμετροι· απαιτεί $\geq 3-4$ πλήρη έτη
SARIMAX	Γνωστά μελλοντικά X · ITS · ημερολογιακές επιδράσεις	Τα X απαιτούν δική τους πρόβλεψη	Συνδυάζει εξήγηση και πρόβλεψη· ερμηνεύσιμοι συντελεστές	Κίνδυνος ψευδούς σχέσης αν αγνοηθεί η στασιμότητα των X

8.5 Το ελάχιστο workflow σε κώδικα

```
import pandas as pd
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.stats.diagnostic import acorr_ljungbox

# 1. Baseline: seasonal naive
h = 12
snaive = y.shift(12).iloc[-h:]

# 2. Υποψήφιο μοντέλο (airline model σε logs)
import numpy as np
ly = np.log(y)
m = SARIMAX(ly, order=(0,1,1), seasonal_order=(0,1,1,12),
            trend='n').fit(dispatch=False)
print(m.summary())

# 3. Διαγνωστικά καταλοίπων – ΥΠΟΧΡΕΩΤΙΚΟ
print(acorr_ljungbox(m.resid, lags=[24], model_df=2))
m.plot_diagnostics(figsize=(10,7))

# 4. Πρόβλεψη με διαστήματα, back-transform
fc = m.get_forecast(steps=h)
mean_log = fc.predicted_mean
ci_log = fc.conf_int(alpha=0.05)
point = np.exp(mean_log) * (1 + m.params['sigma2']/2) # διόρθωση μεροληψίας
lower, upper = np.exp(ci_log.iloc[:,0]), np.exp(ci_log.iloc[:,1])
```

ΕΛΕΓΧΟΣ ΚΑΤΑΝΟΗΣΗΣ — Τεύχος Β´

Α. Ερμηνεία τεστ

1. ADF: $p = 0,32$ · KPSS: $p = 0,08$. Τι συμπεραίνεις και τι κάνεις;
2. ADF: $p = 0,01$ · KPSS: $p = 0,01$. Ποια είναι η πιθανότερη εξήγηση αυτής της αντίφασης και ποιο τεστ τρέχεις στη συνέχεια;
3. Γιατί το p-value του KPSS σε πολλές βιβλιοθήκες εμφανίζεται πάντα ως 0,01 ή 0,10 και ποτέ ενδιάμεσα;
4. Ljung-Box στα κατάλοιπα ενός SARIMA(1,1,1)(1,1,1)₁₂: Q(24) με $p = 0,003$. Τι σημαίνει και τι είναι λάθος αν το αγνοήσεις;

Β. Επιλογή μοντέλου

1. Μηνιαία σειρά, 84 παρατηρήσεις, ανοδική τάση, εποχικό πλάτος που μεγαλώνει με το επίπεδο, χωρίς breaks. Γράψε τα βήματα από τα raw δεδομένα ως το τελικό μοντέλο, με τη σειρά.
2. Το ACF μετά από πρώτη διαφορά δείχνει έντονο αρνητικό spike $-0,48$ στο lag 1 και η $\text{Var}(\Delta Y) > \text{Var}(Y)$. Τι έχει συμβεί;
3. Θέλεις να προβλέψεις μηνιαία φαρμακευτική δαπάνη 12 μήνες μπροστά και σκέφτεσαι να βάλεις ως regressor τον πληθωρισμό. Γιατί είναι προβληματικό και ποιες δύο εναλλακτικές έχεις;
4. Ποια είναι η διαφορά μεταξύ ETS(M,A_d,M) και SARIMA(0,1,1)(0,1,1)₁₂ ως προς το τι μπορούν να χειριστούν;

Γ. Κριτική σκέψη

1. Ένας συνάδελφος παρουσιάζει παλινδρόμηση «δημόσια φαρμακευτική δαπάνη ~ ΑΕΠ» με $R^2 = 0,96$, $p < 0,001$, $DW = 0,21$. Τι του απαντάς;
2. Το auto_arima επιλέγει SARIMA(2,1,3)(1,1,2)₁₂ με το χαμηλότερο AICc, αλλά το seasonal naive έχει μικρότερο RMSE σε rolling-origin backtesting. Ποιο διαλέγεις και γιατί;

Επόμενο βήμα

Το **Τεύχος Γ´** καλύπτει τα Μέρη 9-14 — το κομμάτι που αφορά πιο άμεσα τη δουλειά σου: cross-correlation και distributed lags, dynamic regression, ARDL, VAR/VARX, συνολοκλήρωση (Engle-Granger, Johansen) και VECM, Granger causality και γιατί δεν είναι αιτιότητα, ολόκληρο κεφάλαιο για **Interrupted Time Series** με πλήρη διαγνωστικά και εφαρμογή σε αλλαγή πολιτικής αποζημίωσης, structural breaks (Chow, CUSUM, Bai-Perron) και μοντέλα μεταβλητότητας (ARCH-LM, GARCH, EGARCH, GJR).