

ΕΓΧΕΙΡΙΔΙΟ ΕΚΠΑΙΔΕΥΣΗΣ

TIME SERIES ANALYSIS

FROM ZERO TO HERO

ΤΕΥΧΟΣ Γ΄

Πολυμεταβλητές σειρές · Συνολοκλήρωση · Αιτιότητα
Interrupted Time Series · Δομικές θραύσεις · Μεταβλητότητα

Μέρη 9-14 του πλήρους προγράμματος
Από την πρόβλεψη στην αιτιακή αποτίμηση πολιτικής
Περιλαμβάνει απαντήσεις ελέγχου Τεύχους Β΄
Αύγουστος 2026

ΑΠΑΝΤΗΣΕΙΣ — Έλεγχος κατανόησης Τεύχους Β΄

1. ADF $p=0,32$ · KPSS $p=0,08$.

ADF: δεν απορρίπτει → «μη στάσιμη». KPSS: δεν απορρίπτει → «στάσιμη». Είναι το **ασαφές κελί**: τα δεδομένα δεν αρκούν για να διακρίνουν. Μην αποφασίσεις μηχανικά. Κοίτα το ACF (αργή γραμμική φθίση → $I(1)$)· τρέξε PP και Zivot-Andrews· εξέτασε ARFIMA (κλασματική ολοκλήρωση)· και κάνε ανάλυση ευαισθησίας με και χωρίς differencing. Αν τα συμπεράσματα δεν αλλάζουν, το ζήτημα είναι πρακτικά αδιάφορο.

2. ADF $p=0,01$ · KPSS $p=0,01$ (αντίφαση).

Και τα δύο απορρίπτουν — λογικά ασύμβατο, άρα κάτι στη *μορφή* του μοντέλου είναι λάθος. Πιθανότερη αιτία: **δομική θραύση** ή μη μοντελοποιημένη ντετερμινιστική τάση, ή μεταβαλλόμενη διακύμανση. Επόμενα τεστ: Zivot-Andrews (unit root με έναν ενδογενή break), Bai-Perron (πολλαπλοί breaks), και επανάληψη ADF/KPSS με `regression='ct'`. Δοκίμασε επίσης log για σταθεροποίηση διακύμανσης.

3. Γιατί το p του KPSS «κολλάει» στο 0,01 και 0,10.

Το KPSS δεν έχει κλειστή μορφή p -value· οι βιβλιοθήκες παρεμβάλλουν από πίνακα κρίσιμων τιμών που καλύπτει μόνο το εύρος 0,01-0,10. Εκτός αυτού πλαφονάρεται. Πρακτικά: ανάφερε τη **στατιστική** και τις κρίσιμες τιμές, όχι μόνο το p .

4. Ljung-Box $Q(24)$ $p=0,003$.

Απορρίπτεται ο λευκός θόρυβος: τα κατάλοιπα έχουν εναπομείναισα δομή, άρα το μοντέλο *άφησε πληροφορία στο τραπέζι*. Αν το αγνοήσεις: (α) τα standard errors υποεκτιμώνται → ψευδώς σημαντικοί συντελεστές, (β) τα διαστήματα πρόβλεψης βγαίνουν πολύ στενά → υπερβολική εμπιστοσύνη, (γ) οι προβλέψεις είναι υποβέλτιστες. Κοίτα *πού* είναι τα spikes: στο lag 12 → ανεπαρκής εποχική δομή· στο lag 1-2 → αύξησε p ή q .

5. Πλήρες workflow (84 μηνιαία, τάση, αυξανόμενο εποχικό πλάτος).

(1) Data audit + raw/seasonal/subseries plots. (2) **Λογάριθμος** (το αυξανόμενο πλάτος το επιβάλλει) ή Box-Cox με εκτίμηση λ . (3) STL στο log για επιβεβαίωση δομής και F_T/F_S . (4) ADF/KPSS στο log με `ct`. (5) Εποχική διαφορά πρώτα ($D=1$)· επανέλεγχος· πρώτη διαφορά ($d=1$) μόνο αν χρειάζεται. (6) ACF/PACF της διαφορισμένης. (7) Υποψήφια: $airline(0,1,1)(0,1,1)_{12}$, $ETS(M,A_d,M)$, + 2-3 γειτονικά. (8) Σύγκριση AICc μόνο μεταξύ ίδιου d,D . (9) Ljung-Box + plot_diagnostics. (10) **Rolling-origin backtesting έναντι seasonal naive**. (11) Back-transform με διόρθωση μεροληψίας. (12) Διαστήματα πρόβλεψης και τεκμηρίωση υποθέσεων.

6. Αρνητικό spike $-0,48$ στο lag 1 και $Var(\Delta Y) > Var(Y)$.

Κλασικό **over-differencing**. Η σειρά ήταν ήδη στάσιμη (ή trend-stationary) και το differencing εισήγαγε μη αντιστρέψιμη $MA(1)$ με $\theta \approx -1$. Λύση: γύρνα σε $d=0$ και, αν υπάρχει τάση, βάλε τη ρητά ως regressor (`trend='t'`) ή κάνε detrending.

7. Πληθωρισμός ως regressor για πρόβλεψη 12 μηνών.

Πρόβλημα: ο πληθωρισμός του $T+12$ είναι *άγνωστος* τη στιγμή της πρόβλεψης. Θα χρειαζόταν δική του πρόβλεψη, της οποίας η αβεβαιότητα συνήθως υπερβαίνει το όφελος — και τα διαστήματα πρόβλεψης του SARIMAX δεν την ενσωματώνουν αν βάλεις point forecasts.

Εναλλακτικές: (α) **Υστερημένος** πληθωρισμός με $lag \geq 12$, ώστε να είναι γνωστός. (β) Καθαρά univariate SARIMA + **σεναριακή ανάλυση** (χαμηλό/κεντρικό/υψηλό μονοπάτι πληθωρισμού) — προτιμότερο για policy briefs. (γ) ARDL/VECM όπου προβλέπονται από κοινού και οι δύο σειρές, με ρητή αβεβαιότητα.

8. $ETS(M,A_d,M)$ vs $SARIMA(0,1,1)(0,1,1)_{12}$.

Το ETS χειρίζεται φυσικά *πολλαπλασιαστικό* σφάλμα και εποχικότητα και έχει απόσβεση τάσης — αλλά δεν δέχεται εξωγενείς μεταβλητές, δεν κάνει intervention analysis, δεν έχει διαγνωστικά ταυτοποίησης. Το SARIMA χειρίζεται ρητά στοχαστική τάση, επεκτείνεται σε SARIMAX (άρα και σε **ITS**), προσφέρει πλήρη διαγνωστικά — αλλά χρειάζεται λογάριθμο για να πιάσει πολλαπλασιαστική δομή και δεν έχει ενσωματωμένη απόσβεση.

9. $R^2=0,96$, $p<0,001$, $DW=0,21$.

Το $R^2 > DW$ είναι ο κανόνας-συναγεμμός για **ψευδή παλινδρόμηση**. Η απάντηση: «Πριν ερμηνεύσουμε τον συντελεστή, χρειαζόμαστε τεστ μοναδιαίας ρίζας και στις δύο σειρές. Αν είναι $I(1)$, το αποτέλεσμα είναι πιθανότατα τεχνούργημα κοινής τάσης. Ο σωστός δρόμος: έλεγχος συνολοκλήρωσης (Engle-Granger ή Johansen) και, αν υπάρχει, VECM/ARDL· αν δεν υπάρχει, παλινδρόμηση σε πρώτες διαφορές.»

10. Χαμηλότερο AICc vs καλύτερο backtest.

Επιλέγεις το seasonal naive — ή τουλάχιστον δεν επιλέγεις το πολύπλοκο SARIMA. Το AICc είναι in-sample κριτήριο και τιμωρεί την πολυπλοκότητα μόνο ασυμπτωτικά· η out-of-sample επίδοση είναι το κριτήριο που αντιστοιχεί στο πραγματικό ερώτημα. Πριν οριστικοποιήσεις: επιβεβαίωσε ότι το backtesting window είναι αρκετά μεγάλο ($\geq 12-24$ origins) και ότι δεν κυριαρχείται από μία ανώμαλη περίοδο. Αν το SARIMA(2,1,3)(1,1,2) χάνει από naive, σχεδόν βέβαια υπερπροσαρμόζει.

ΚΕΦΑΛΑΙΟ 9 — Πολυμεταβλητές χρονοσειρές

Μέχρι τώρα εξηγήσαμε το Y από το παρελθόν του. Τώρα προσθέτουμε άλλες σειρές. Το κέρδος είναι δυνητικά μεγάλο· ο κίνδυνος επίσης — κάθε επιπλέον μεταβλητή πολλαπλασιάζει τις παραμέτρους και τις ευκαιρίες για ψευδείς σχέσεις.

9.1 Ετεροσυσχέτιση (Cross-correlation, CCF)

$$\rho_{xy}(k) = \text{Corr}(X_{t-k}, Y_t), \quad k = \dots, -2, -1, 0, 1, 2, \dots$$

Ανάγνωση: σημαντική τιμή σε θετικό k σημαίνει ότι το X **προηγείται** του Y κατά k περιόδους (leading indicator). Σε αρνητικό k , το Y προηγείται του X .

Το CCF σε ακατέργαστα δεδομένα είναι σχεδόν πάντα παραπλανητικό

Αν και οι δύο σειρές έχουν τάση ή κοινή εποχικότητα, το CCF θα δείξει τεράστιες συσχετίσεις σε όλα τα lags — χωρίς καμία σχέση μεταξύ τους. Η σωστή διαδικασία είναι το **prewhitening**: (1) φτιάξε ARIMA για το X , (2) εφάρμοσε το ίδιο φίλτρο και στις δύο σειρές, (3) υπολόγισε το CCF στα φιλτραρισμένα κατάλοιπα. Μόνο τότε το CCF είναι ερμηνεύσιμο.

9.2 Distributed lags και δυναμική παλινδρόμηση

$$\text{Distributed Lag (DL): } Y_t = \alpha + \beta_0 X_t + \beta_1 X_{t-1} + \dots + \beta_q X_{t-q} + \varepsilon_t$$

$$\text{Dynamic regression: } Y_t = \beta' X_t + \eta_t, \quad \text{όπου } \eta_t \sim \text{ARIMA}$$

Ερμηνεία συντελεστών: β_0 = άμεση (impact) επίδραση· $\sum \beta_i$ = συνολική (long-run) επίδραση· το μοτίβο των β_i δείχνει πώς κατανέμεται η επίδραση στον χρόνο.

Πρόβλημα: με πολλά lags, τα X_{t-i} είναι έντονα συσχετισμένα μεταξύ τους (πολυσυγγραμμικότητα) και οι επιμέρους συντελεστές γίνονται ασταθείς. Λύσεις: περιορισμοί μορφής (πολυωνυμικά/Almon lags), ή ARDL που οικονομεί παραμέτρους μέσω υστερήσεων του Y .

9.3 ARDL — Autoregressive Distributed Lag

$$Y_t = \alpha + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=0}^q \beta_j X_{t-j} + \varepsilon_t$$

Το **ARDL(p,q)** είναι από τα πιο χρήσιμα και υποτιμημένα μοντέλα στην εφαρμοσμένη δουλειά.

Δυνατότητα	Γιατί έχει σημασία
Δέχεται μεικτή τάξη ολοκλήρωσης	Λειτουργεί με $I(0)$ και $I(1)$ μεταβλητές μαζί — δεν χρειάζεται να είναι όλες $I(1)$ όπως στο Johansen. Αλλά ποτέ $I(2)$.
Bounds test (Pesaran, Shin & Smith 2001)	Ελέγχει ύπαρξη μακροχρόνιας σχέσης χωρίς να χρειάζεται προκαταρκτική ταξινόμηση σε $I(0)/I(1)$
Καλή συμπεριφορά σε μικρά δείγματα	Κρίσιμο όταν έχεις 60–100 μηνιαίες παρατηρήσεις — δηλαδή σχεδόν πάντα σε ελληνικά δεδομένα υγείας
Δίνει ECM αναπαράσταση	Διαχωρίζει βραχυχρόνια δυναμική από μακροχρόνια ισορροπία σε ένα μοντέλο

Μακροχρόνιος πολλαπλασιαστής:

$$LR = (\sum_{j=0}^q \beta_j) / (1 - \sum_{i=1}^p \phi_i)$$

9.4 VAR — Vector Autoregression

Στο VAR όλες οι μεταβλητές είναι **ενδογενείς**: καθεμία εξηγείται από τις υστερήσεις όλων.

$$\mathbf{y}_t = \mathbf{c} + A_1 \mathbf{y}_{t-1} + A_2 \mathbf{y}_{t-2} + \dots + A_p \mathbf{y}_{t-p} + \boldsymbol{\varepsilon}_t$$

όπου $\mathbf{y}_t$ είναι διάνυσμα $K \times 1$ και κάθε A_i πίνακας $K \times K$

Η κατάρα των διαστάσεων

Αριθμός παραμέτρων = $K + pK^2$. Με $K=4$ μεταβλητές και $p=4$ lags: $4 + 4 \cdot 16 = \mathbf{68}$ παράμετροι. Με 84 μηνιαίες παρατηρήσεις είναι πρακτικά αδύνατο. Κανόνας επιβίωσης: $K \leq 3-4$, $p \leq 2-4$, $T \geq 10 \cdot (\text{παραμέτροι ανά εξίσωση})$. Εναλλακτικά: Bayesian VAR με Minnesota prior.

Τα τρία εργαλεία ανάλυσης ενός VAR

Εργαλείο	Τι απαντά	Προσοχή
Impulse Function (IRF)	Response Πώς αντιδρά το Y σε ένα shock μιας τυπικής απόκλισης στο X , στον χρόνο	Απαιτεί ταυτοποίηση (Cholesky) — η σειρά των μεταβλητών αλλάζει τα αποτελέσματα. Δήλωσέ τη και δικαιολόγησέ τη
Forecast Error Variance Decomposition	Πόσο % της αβεβαιότητας πρόβλεψης του Y οφείλεται σε κάθε shock	Ίδιο θέμα ταυτοποίησης
Granger causality	Αν οι υστερήσεις του X βελτιώνουν την πρόβλεψη του Y	Δεν είναι αιτιότητα (Κεφ. 11)

VARX: VAR με πρόσθετες πραγματικά *εξωγενείς* μεταβλητές (ημερολογιακές, dummies πολιτικής) που δεν εξηγούνται μέσα στο σύστημα.

9.5 Επιλογή αριθμού lags

Κριτήριο	Τύπος	Συμπεριφορά	Πότε το προτιμάς
AIC	$-2 \cdot \log L + 2k$	Επιλέγει μεγαλύτερα μοντέλα· δεν είναι συνεπές αλλά είναι αποδοτικό στην πρόβλεψη	Στόχος = πρόβλεψη
AICc	$AIC + 2k(k+1)/(T-k-1)$	Διόρθωση μικρού δείγματος· συγκλίνει στο AIC για μεγάλα T	Προεπιλογή όταν $T/k < 40$ — δηλαδή σχεδόν πάντα
BIC / SC	$-2 \cdot \log L + k \cdot \log(T)$	Αυστηρότερη ποινή· συνεπές (βρίσκει το «αληθινό» μοντέλο ασυμπτωτικά)· επιλέγει μικρότερα	Στόχος = ερμηνεία/δομή· αποφυγή υπερπαραμετροποίησης σε VAR
HQIC	$-2 \cdot \log L + 2k \cdot \log(\log T)$	Ενδιάμεσο	Συχνά αναφέρεται μαζί με τα άλλα σε VAR

Τρεις κανόνες που παραβιάζονται συνεχώς

1. Σύγκρινε AIC/BIC *μόνο* μεταξύ μοντέλων με το ίδιο d και D και το ίδιο δείγμα. Διαφορετικός βαθμός differencing → διαφορετική εξαρτημένη μεταβλητή → οι τιμές δεν είναι συγκρίσιμες.
2. Το χαμηλότερο AIC δεν εγγυάται καλύτερη πρόβλεψη. Είναι in-sample προσέγγιση της out-of-sample απόδοσης, όχι υποκατάστατό της.
3. Ό,τι κι αν πει το κριτήριο, τα κατάλοιπα πρέπει να περνούν Ljung-Box. Αν δεν περνούν, αύξησε lags ανεξάρτητα από το AIC.

ΚΕΦΑΛΑΙΟ 10 — Συνολοκλήρωση (Cointegration)

10.1 Η κεντρική ιδέα

Δύο σειρές μπορεί να είναι και οι δύο $I(1)$ — να περιπλανιούνται χωρίς μέσο — και όμως να μην απομακρύνονται ποτέ *η μία από την άλλη*. Υπάρχει ένας γραμμικός συνδυασμός τους που είναι στάσιμος. Αυτή είναι η συνολοκλήρωση.

$$X_t \sim I(1), Y_t \sim I(1), \text{ αλλά } z_t = Y_t - \beta X_t \sim I(0)$$

Το z_t είναι το **σφάλμα ισορροπίας**· το β είναι το **διάνυσμα συνολοκλήρωσης**

Η ΚΛΑΣΙΚΗ ΕΙΚΟΝΑ: ένας μεθυσμένος και ο σκύλος του. Καθένας χωριστά κάνει τυχαίο περίπατο — δεν μπορείς να προβλέψεις πού θα είναι. Αλλά ο λουρί τους κρατά κοντά: η *απόσταση* μεταξύ τους είναι στάσιμη.

ΟΙΚΟΝΟΜΙΚΟ ΝΟΗΜΑ: η συνολοκλήρωση εκφράζει **μακροχρόνια ισορροπία**. Οι σειρές μπορεί να αποκλίνουν βραχυπρόθεσμα, αλλά υπάρχει δύναμη επαναφοράς.

ΠΑΡΑΔΕΙΓΜΑ ΑΠΟ ΤΟΝ ΧΩΡΟ ΣΟΥ: δημόσια φαρμακευτική δαπάνη και συνολική δαπάνη υγείας. Και οι δύο $I(1)$. Αλλά ο λόγος τους (ή το spread των λογαρίθμων) παραμένει σε στενό εύρος επί δεκαετίες, γιατί υπάρχουν θεσμικοί μηχανισμοί (κλειστός προϋπολογισμός, clawback) που τον επαναφέρουν. Αυτή είναι συνολοκλήρωση με θεσμική εξήγηση.

10.2 Διόρθωση σφάλματος (Error Correction) — το θεώρημα αναπαράστασης

Θεώρημα Granger: αν οι μεταβλητές είναι συνολοκληρωμένες, τότε *υπάρχει* αναπαράσταση διόρθωσης σφάλματος — και αντιστρόφως.

$$\Delta Y_t = \alpha + \gamma(Y_{t-1} - \beta X_{t-1}) + \sum \delta_i \Delta Y_{t-i} + \sum \eta_j \Delta X_{t-j} + \varepsilon_t$$

Ο όρος σε παρένθεση είναι το σφάλμα ισορροπίας της προηγούμενης περιόδου

Ο συντελεστής γ	Ερμηνεία
$\gamma < 0$ και σημαντικός	Επιβεβαιώνει τη συνολοκλήρωση. Είναι η <i>ταχύτητα προσαρμογής</i> : το $ \gamma $ δείχνει το ποσοστό της απόκλισης που διορθώνεται σε μία περίοδο
$\gamma = -0,25$ (μηνιαία)	Το 25% της απόκλισης διορθώνεται κάθε μήνα· ο χρόνος ημιζωής της απόκλισης $\approx \log(0,5)/\log(1-0,25) \approx 2,4$ μήνες
$\gamma \approx 0$ ή μη σημαντικός	Δεν υπάρχει μηχανισμός επαναφοράς $\rightarrow$ πιθανόν δεν υπάρχει συνολοκλήρωση
$\gamma > 0$	Εκρηκτικό — λάθος προδιαγραφή

Γιατί το ECM είναι τόσο ελκυστικό

Σε ένα μοντέλο έχεις και τη βραχυχρόνια δυναμική (οι όροι Δ) και τη μακροχρόνια σχέση (ο όρος διόρθωσης) — χωρίς να θυσιάσεις τη μία για την άλλη, όπως συμβαίνει αν απλώς κάνεις differencing.

10.3 Τα δύο τεστ

Engle-Granger (δύο βημάτων)

1. Παλινδρόμηση OLS σε επίπεδα: $Y_t = \alpha + \beta X_t + z_t$
2. Έλεγχος στασιμότητας των καταλοίπων $\hat{z}_t$ με ADF, χρησιμοποιώντας **κρίσιμες τιμές MacKinnon** (όχι τις συνήθεις — τα $\hat{z}$ είναι εκτιμημένα)

H_0	Τα κατάλοιπα έχουν unit root → ΔΕΝ υπάρχει συνολοκλήρωση
H_1	Τα κατάλοιπα είναι στάσιμα → υπάρχει συνολοκλήρωση

Περιορισμοί: μόνο για δύο μεταβλητές (ένα διάνυσμα συνολοκλήρωσης)· τα αποτελέσματα εξαρτώνται από το ποια μεταβλητή βάσεις αριστερά· χαμηλή ισχύς σε μικρά δείγματα.

Johansen (μέγιστης πιθανοφάνειας)

Δουλεύει σε πλαίσιο VAR και εντοπίζει **πόσα** ανεξάρτητα διανύσματα συνολοκλήρωσης υπάρχουν (τάξη r του πίνακα Π).

Στατιστική	H_0	H_1
Trace	Το πολύ r διανύσματα συνολοκλήρωσης	Περισσότερα από r
Max-eigenvalue	Ακριβώς r διανύσματα	$r+1$ διανύσματα

Διαδικασία: ξεκινάς από $r=0$ · αν απορριφθεί, δοκιμάζεις $r=1$ · συνεχίζεις μέχρι να μην απορρίπτεται. Ο πρώτος μη απορριπτόμενος r είναι η εκτίμηση.

Τιμή r	Ερμηνεία
$r = 0$	Καμία συνολοκλήρωση → χρησιμοποίησε VAR σε διαφορές
$0 < r < K$	Συνολοκλήρωση → χρησιμοποίησε VECM με r διανύσματα
$r = K$	Όλες οι μεταβλητές ήταν ήδη στάσιμες → VAR σε επίπεδα

Ευαισθησίες του Johansen

Τα αποτελέσματα αλλάζουν σημαντικά με: (α) τον αριθμό lags του υποκείμενου VAR, (β) την υπόθεση για ντετερμινιστικούς όρους (5 εκδοχές: χωρίς σταθερά, περιορισμένη σταθερά, μη περιορισμένη, περιορισμένη τάση, μη περιορισμένη τάση), (γ) την ύπαρξη structural breaks. **Πάντα κάνε ανάλυση ευαισθησίας και δήλωσε τις επιλογές σου.** Ένα δημοσιευμένο VECM χωρίς αυτή τη δήλωση δεν είναι αναπαραγώγιμο.

10.4 VECM — Vector Error Correction Model

$$\Delta \mathbf{y}_t = \mathbf{\Pi} \mathbf{y}_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta \mathbf{y}_{t-i} + \boldsymbol{\varepsilon}_t$$

όπου $\mathbf{\Pi} = \boldsymbol{\alpha} \boldsymbol{\beta}'$, με $\boldsymbol{\beta}$ = διανύσματα συνολοκλήρωσης (μακροχρόνια σχέση) και $\boldsymbol{\alpha}$ = ταχύτητες προσαρμογής

Το VECM είναι VAR σε διαφορές συν τον όρο διόρθωσης σφάλματος. Χωρίς αυτόν τον όρο, το VAR σε διαφορές είναι λάθος προδιαγεγραμμένο (παραλείπει μεταβλητή).

10.5 Κανόνας απόφασης: VAR vs VECM vs ARDL

Κατάσταση	Επιλογή	Σκεπτικό
Όλες οι μεταβλητές I(0)	VAR σε επίπεδα	Δεν υπάρχει πρόβλημα ψευδούς παλινδρόμησης· κλασική ασυμπτωτική θεωρία ισχύει
Όλες I(1) , χωρίς συνολοκλήρωση	VAR σε πρώτες διαφορές	Το differencing λύνει τη στασιμότητα και δεν χάνεται μακροχρόνια πληροφορία, γιατί δεν υπάρχει
Όλες I(1) , με συνολοκλήρωση	VECM	Διατηρεί τη μακροχρόνια σχέση· το VAR σε διαφορές θα παρέλειπε τον όρο διόρθωσης
Μείγμα I(0) και I(1)	ARDL με bounds test	Το Johansen απαιτεί ομοιογενή τάξη· το ARDL δεν
Οποιαδήποτε I(2)	Επανεξέταση	Λογαρίθμισε· έλεγξε για breaks· το I(2) είναι σχεδόν πάντα ένδειξη προβλήματος, όχι πραγματικότητας
Μικρό δείγμα ($T < 80$), 2-3 μεταβλητές	ARDL	Καλύτερη συμπεριφορά σε μικρά δείγματα από το Johansen
Ένα σαφές Y, τα X πραγματικά εξωγενή	ARDL ή SARIMAX	Το VAR/VECM υποθέτει αμοιβαία ενδογένεια — αν δεν ισχύει, σπαταλάς παραμέτρους

ΚΕΦΑΛΑΙΟ 11 — Αιτιότητα

11.1 Οι τρεις έννοιες που δεν πρέπει να συγχέονται

Έννοια	Ερώτημα	Τι απαιτεί	Τι επιτρέπει να πεις
Συσχέτιση (association)	Κινούνται μαζί;	Τίποτα — μόνο δεδομένα	«Τα X και Y συσχετίζονται.» Τίποτα παραπάνω.
Πρόβλεψη (prediction)	Βοηθά το X να προβλέψω το Y;	Χρονική προτεραιότητα + out-of-sample επικύρωση	«Η γνώση του X βελτιώνει την πρόβλεψη του Y.» Χρήσιμο επιχειρησιακά, άχρηστο για policy.
Αιτιότητα (causality)	Αν παρέμβω στο X, θα αλλάξει το Y;	Αιτιακός σχεδιασμός : τυχαίο-ποίηση ή αξιόπιστη πηγή εξωγενούς μεταβολής + ελεγμένες υποθέσεις	«Η μεταβολή του X προκάλεσε μεταβολή στο Y κατά τόσο.»

Ο πρακτικός έλεγχος

Ρώτησε τον εαυτό σου: «Αν αύριο αλλάξω το X με απόφαση, τι θα συμβεί στο Y;» Αν το μοντέλο σου δεν μπορεί να απαντήσει σε αυτό, δεν είναι αιτιακό — όσο υψηλό κι αν είναι το R^2 , όσο μικρό κι αν είναι το p.

11.2 Granger causality

$$\text{Περιορισμένο: } Y_t = \alpha + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t$$

$$\text{Μη περιορισμένο: } Y_t = \alpha + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=1}^p \beta_j X_{t-j} + \varepsilon_t$$

H₀	$\beta_1 = \beta_2 = \dots = \beta_p = 0 \rightarrow$ το X δεν Granger-προκαλεί το Y
H₁	Τουλάχιστον ένα $\beta_j \neq 0 \rightarrow$ το X Granger-προκαλεί το Y
Στατιστική	F-test (ή Wald χ^2) σύγκρισης των δύο μοντέλων
Προϋπόθεση	Στασιμότητα. Σε I(1) σειρές το τεστ είναι άκυρο — χρησιμοποίησε διαφορές, ή τη διαδικασία Toda-Yamamoto (VAR σε επίπεδα με $p+d_{\max}$ lags) αν θέλεις να αποφύγεις προ-έλεγχο

Τι πραγματικά ελέγχει — και γιατί δεν είναι αιτιότητα

Το Granger causality ελέγχει **μία και μόνο πρόταση**: «η παρελθούσα πληροφορία του X μειώνει το σφάλμα πρόβλεψης του Y, δεδομένου του παρελθόντος του Y». Αυτό είναι δήλωση για *προβλεψιμότητα*, όχι για μηχανισμό. Ο ίδιος ο Granger το ονόμασε προσωρινή προτεραιότητα και όχι αιτιότητα.

Πηγή αποτυχίας	Παράδειγμα
Παραλειπόμενη κοινή αιτία	Ένας τρίτος παράγοντας Z επηρεάζει και τα δύο με διαφορετικά lags. Το X φαίνεται να «προκαλεί» το Y ενώ και τα δύο ακολουθούν το Z. Το bivariate Granger test δεν το βλέπει ποτέ.
Αντίστροφη αιτιότητα μέσω προσδοκιών	Οι επιχειρήσεις αυξάνουν αποθέματα πριν από αναμενόμενη αύξηση ζήτησης. Τα αποθέματα «Granger-προκαλούν» τις πωλήσεις, ενώ ο μηχανισμός είναι αντίστροφος.
Σφάλμα μέτρησης / συχνότητα	Αν η πραγματική αιτιακή σχέση συμβαίνει εντός του μήνα, μηνιαία δεδομένα δεν μπορούν να τη διακρίνουν από ταυτόχρονη συσχέτιση.
Χρονική συνάθροιση	Η ίδια σχέση μπορεί να δείξει Granger causality σε εβδομαδιαία δεδομένα και να εξαφανιστεί σε τριμηνιαία.

Πώς να το διατυπώνεις σωστά

✗ «Η αύξηση των επισκέψεων προκαλεί αύξηση της δαπάνης (Granger, $p < 0,01$).»

✓ «Οι υστερημένες τιμές των επισκέψεων βελτιώνουν στατιστικά σημαντικά την πρόβλεψη της δαπάνης (Granger causality test, $F=6,2$, $p < 0,01$). Αυτό είναι εύρημα προβλεψιμότητας· δεν τεκμηριώνει αιτιακή σχέση.»

11.3 Πότε χρησιμοποιείς ποιο αιτιακό σχέδιο

Μέθοδος	Πηγή ταυτοποίησης	Βασική υπόθεση	Πότε την επιλέγεις
Interrupted Time Series	Απότομη αλλαγή σε γνωστή χρονική στιγμή, σε μία ομάδα	Χωρίς την παρέμβαση, η προ-υπάρχουσα τάση θα συνεχιζόταν αμετάβλητη	Έχεις μία μονάδα (χώρα, σύστημα), πολλά χρονικά σημεία πριν και μετά, σαφή ημερομηνία
Controlled ITS	Ίδιο + σειρά ελέγχου	Παράλληλες τάσεις πριν την παρέμβαση	Υπάρχει συγκρίσιμη ομάδα που δεν επηρεάστηκε — πάντα προτιμότερο από απλό ITS
Difference-in-Differences	Ομάδα παρέμβασης vs ελέγχου, πριν vs μετά	Parallel trends: χωρίς την παρέμβαση οι δύο ομάδες θα εξελίσσονταν παράλληλα	Πολλές μονάδες, λίγα χρονικά σημεία· διαθέσιμη ομάδα ελέγχου
Synthetic Control	Σταθμισμένος συνδυασμός μονάδων ελέγχου που αναπαράγει την προ-παρέμβασης τροχιά	Καλή προ-παρέμβασης εφαρμογή· καμία μονάδα ελέγχου δεν επηρεάστηκε (no spillover)	Μία μονάδα παρέμβασης, πολλές δυνητικές ελέγχου (π.χ. μία περιφέρεια vs οι υπόλοιπες 12)
Regression Discontinuity	Κατώφλι σε συνεχή μεταβλητή	Οι μονάδες δεν χειραγωγούν τη θέση τους γύρω από το κατώφλι	Υπάρχει ρητό όριο (εισοδηματικό κριτήριο, ηλικία, τιμή αναφοράς)

ΚΕΦΑΛΑΙΟ 12 — Interrupted Time Series

Το ITS είναι το ισχυρότερο *οιονεί-πειραματικό* σχέδιο όταν έχεις μία μονάδα και σαφή χρονική τομή. Είναι το εργαλείο επιλογής για αποτίμηση πολιτικών υγείας, αλλαγών αποζημίωσης και θεραπευτικών οδηγιών.

12.1 Το βασικό μοντέλο

$$Y_t = \beta_0 + \beta_1 \cdot \text{Time}_t + \beta_2 \cdot \text{Intervention}_t + \beta_3 \cdot \text{TimeAfter}_t + \varepsilon_t$$

Μεταβλητή	Κωδικοποίηση	Παράδειγμα (παρέμβαση στον μήνα 37 από 84)
Time	1, 2, 3, ..., T (συνεχής χρόνος)	1, 2, ..., 36, 37, 38, ..., 84
Intervention	0 πριν, 1 από την παρέμβαση και μετά	0 (×36), μετά 1 (×48)
TimeAfter	0 πριν· 1, 2, 3... μετά (χρόνος από την παρέμβαση)	0 (×36), μετά 1, 2, ..., 48

12.2 Ερμηνεία των συντελεστών — το πιο σημαντικό σημείο του κεφαλαίου

Συντελεστής	Ονομασία	Ακριβής ερμηνεία
β_0	Baseline level	Το εκτιμώμενο επίπεδο του Y στην αρχή της περιόδου παρατήρησης (Time=0). Συνήθως δεν έχει ουσιαστικό ενδιαφέρον.
β_1	Baseline trend	Η μεταβολή του Y ανά περίοδο <i>πριν</i> την παρέμβαση. Απαντά: «πού πήγαινε ήδη το πράγμα;»
β_2	Immediate level change	Το άμεσο άλμα (πάνω ή κάτω) τη στιγμή της παρέμβασης, <i>πέραν</i> της προ-υπάρχουσας τάσης. Μετρά τη στιγμιαία επίδραση.
β_3	Slope change	Η μεταβολή στην κλίση. Δεν είναι η νέα κλίση. Η νέα κλίση είναι $\beta_1 + \beta_3$. Μετρά αν η πορεία άλλαξε ρυθμό.

Το λάθος #1 στα δημοσιευμένα ITS

Να αναφέρεται το β_3 ως «η τάση μετά την παρέμβαση». Είναι η *διαφορά* τάσης. Αν $\beta_1 = +2,0$ και $\beta_3 = -0,5$, η μετά-παρέμβασης τάση είναι $+1,5$ — δηλαδή η δαπάνη **συνεχίζει να αυξάνεται**, απλώς πιο αργά. Το να πεις «η πολιτική μείωσε τη δαπάνη» είναι λάθος· το σωστό είναι «επιβράδυνε τον ρυθμό αύξησης».

Τα τέσσερα πρότυπα αποτελεσμάτων

β_2	β_3	Ερμηνεία
Σημαντικό	Μη σημαντικό	Άμεση, μόνιμη μετατόπιση επιπέδου χωρίς αλλαγή πορείας. Τυπικό μιας εφάπαξ διοικητικής αλλαγής (π.χ. μείωση τιμών με υπουργική απόφαση).
Μη σημαντικό	Σημαντικό	Σταδιακή επίδραση που συσσωρεύεται. Τυπικό αλλαγών που απαιτούν προσαρμογή συμπεριφοράς (νέα θεραπευτική οδηγία, εκπαιδευτική παρέμβαση).
Σημαντικό	Σημαντικό	Άμεσο άλμα και αλλαγή πορείας. Το ισχυρότερο εύρημα — αλλά προσοχή στο πρόσσημο: μπορεί να είναι άλμα κάτω και μετά ανάκαμψη (προσωρινή επίδραση).
Μη σημαντικό	Μη σημαντικό	Καμία ανιχνεύσιμη επίδραση. Έλεγε την ισχύ πριν συμπεράνεις «δεν λειτούργησε» — απουσία απόδειξης $\neq$ απόδειξη απουσίας.

12.3 Επεκτάσεις που θα χρειαστείς

Περίοδος μετάβασης (phase-in)

Λίγες πολιτικές εφαρμόζονται μέσα σε μία ημέρα. Αν υπάρχει περίοδος προσαρμογής, **εξαίρεσε τους μήνες μετάβασης** από την ανάλυση (δήλωσέ το) ή μοντελοποίησε ρητά τρίτη περίοδο.

Επίδραση προσδοκίας (anticipation)

Αν η αλλαγή ανακοινώθηκε 3 μήνες πριν, η συμπεριφορά αλλάζει *πριν* την επίσημη ημερομηνία (αποθεματοποίηση, εσπευσμένη συνταγογράφηση). Χρησιμοποίησε την **ημερομηνία ανακοίνωσης**, όχι εφαρμογής — ή μόντελοποίησε και τις δύο.

Εποχικότητα

Υποχρεωτική σε μηνιαία δεδομένα υγείας. Επιλογές: (α) μηνιαία dummies (11 παράμετροι — ακριβό), (β) **αρμονικοί όροι** $\sin(2\pi kt/12)$, $\cos(2\pi kt/12)$ με $k=1,2$ (4 παράμετροι — προτιμότερο), (γ) SARIMA με εποχικούς όρους.

Πολλαπλές παρεμβάσεις

Αν συνέβησαν δύο πολιτικές κοντά χρονικά (π.χ. clawback και ταυτόχρονη ανατιμολόγηση), προσθέτεις ζεύγη (Intervention_k , TimeAfter_k) — αλλά αν απέχουν λιγότερο από ~12 περιόδους, οι επιδράσεις **δεν ταυτοποιούνται ξεχωριστά**. Πες το ρητά αντί να παρουσιάσεις εκτιμήσεις που δεν στέκουν.

Controlled ITS

$$Y_t = \beta_0 + \beta_1 T + \beta_2 I + \beta_3 TA + \beta_4 G + \beta_5 (G \times T) + \beta_6 (G \times I) + \beta_7 (G \times TA) + \varepsilon_t$$

Όπου $G = 1$ για την ομάδα παρέμβασης. Οι β_6 και β_7 είναι οι εκτιμήσεις επίδρασης «καθαρισμένες» από ό,τι συνέβη ταυτόχρονα και στις δύο ομάδες. **Αν έχεις σειρά ελέγχου, χρησιμοποίησέ τη.** Το απλό ITS δεν μπορεί να ξεχωρίσει την πολιτική από οποιοδήποτε άλλο γεγονός της ίδιας στιγμής.

12.4 Το πρόβλημα της αυτοσυσχέτισης — και οι λύσεις

Τα κατάλοιπα ενός ITS με OLS είναι σχεδόν πάντα αυτοσυσχετισμένα. Αν το αγνοήσεις: τα standard errors υποεκτιμώνται, τα διαστήματα εμπιστοσύνης είναι πολύ στενά και βρίσκεις «σημαντικές» επιδράσεις που δεν υπάρχουν.

Προσέγγιση	Τι κάνει	Πότε
Newey-West HAC	Διορθώνει μόνο τα standard errors, όχι τις εκτιμήσεις	Απλό, εύρωστο, καλή προεπιλογή για αναφορές· επιλογή lag $\approx T^{1/4}$
Prais-Winsten Cochrane-Orcutt	/ GLS που μοντελοποιεί AR(1) στα σφάλματα	Όταν η αυτοσυσχέτιση είναι κυρίως πρώτης τάξης
ARIMA με intervention (Box-Tiao)	Πλήρες SARIMAX: οι μεταβλητές παρέμβασης ως regressors, η υπόλοιπη δομή ως SARIMA	Η μεθοδολογικά καθαρότερη λύση. Επιτρέπει και εποχικότητα και σύνθετη δυναμική στο ίδιο πλαίσιο
GLS / GEE	Ρητή δομή συνδιακύμανσης	Όταν υπάρχουν πολλαπλές μονάδες (panel ITS)

12.5 Πλήρης λίστα απαιτούμενων ελέγχων

#	Έλεγχος	Τι επιβεβαιώνεις / τι κάνεις αν αποτύχει
1	Επαρκή σημεία	Ελάχιστο ~8-12 πριν και 8-12 μετά· ιδανικά ≥ 24 και στις δύο πλευρές. Με λιγότερα, η τάση δεν εκτιμάται αξιόπιστα και το ITS δεν πρέπει να επιχειρηθεί
2	Σαφής ημερομηνία	Η παρέμβαση πρέπει να έχει προσδιορισμένη στιγμή. Αν η εφαρμογή ήταν σταδιακή, δήλωσέ το και μοντελοποίησε phase-in
3	Σταθερότητα προ-τάσης	Γράφημα + έλεγχος γραμμικότητας της προ-περιόδου. Αν η προ-τάση δεν είναι σταθερή, η αντιπαραδειγματική προβολή είναι αναξιόπιστη
4	Ημερολόγιο συγχυτών	Κατέγραψε κάθε άλλο γεγονός στο παράθυρο (COVID, οικονομική κρίση, άλλη πολιτική, αλλαγή καταγραφής). Αυτό είναι η κύρια απειλή εγκυρότητας
5	Αυτοσυσχέτιση	Ljung-Box, Durbin-Watson, ACF/PACF καταλοίπων → διόρθωση (§12.4)
6	Εποχικότητα καταλοίπων	ACF στο lag 12· αν υπάρχει, πρόσθεσε αρμονικούς ή εποχικούς όρους
7	Ετεροσκεδαστικότητα	Breusch-Pagan / White· λύση: log-μετασχηματισμός ή εύρωστα SE
8	Ακραίες τιμές & μοχλός	Παρατηρήσεις κοντά στο σημείο τομής έχουν δυσανάλογη επιρροή — έλεγε Cook's distance
9	Placebo / ψευδής ημερομηνία	Τρέξε το ίδιο μοντέλο με πλασματική ημερομηνία παρέμβασης 12 μήνες νωρίτερα. Αν βρεις «σημαντική επίδραση», το μοντέλο σου πιάνει θόρυβο
10	Ανάλυση ευαισθησίας	Διαφορετικά παράθυρα, με/χωρίς μήνες μετάβασης, γραμμική vs μη γραμμική προ-τάση, με/χωρίς εποχικότητα. Τα συμπεράσματα πρέπει να αντέχουν
11	Σειρά ελέγχου	Αν υπάρχει, controlled ITS. Αν δεν υπάρχει, δήλωσέ το ως περιορισμό
12	Πρακτική σημασία	Ανάφερε το μέγεθος της επίδρασης σε ερμηνεύσιμες μονάδες (απόλυτη και σχετική διαφορά έναντι του αντιπαραδείγματος στους 12/24 μήνες), όχι μόνο p-values

12.6 Εφαρμογή: αλλαγή πολιτικής αποζημίωσης

Σενάριο: Τον Ιούνιο 2022 τίθεται σε ισχύ αλλαγή στον κατάλογο αποζημιούμενων φαρμάκων μιας θεραπευτικής κατηγορίας. Διαθέσιμα: μηνιαία δεδομένα δαπάνης, Ιαν 2018 – Δεκ 2024 (84 μήνες· 41 πριν, 43 μετά).

```
import numpy as np, pandas as pd, statsmodels.api as sm

df = df.sort_values('date').reset_index(drop=True)
df['Time'] = np.arange(1, len(df)+1)
df['Intervention'] = (df['date'] >= '2022-06-01').astype(int)
df['TimeAfter'] = np.where(df['Intervention']==1,
                           df['Time'] - df.loc[df['Intervention']==1, 'Time'].min() + 1, 0)

# Εποχικότητα με αρμονικούς (πιο οικονομικό από 11 dummies)
for k in (1, 2):
    df[f'sin{k}'] = np.sin(2*np.pi*k*df['Time']/12)
    df[f'cos{k}'] = np.cos(2*np.pi*k*df['Time']/12)

# COVID ως ρητός συγχυτής – MHN τον αφήσεις στα κατάλοιπα
df['covid'] = df['date'].between('2020-03-01', '2020-08-01').astype(int)

X = sm.add_constant(df[['Time', 'Intervention', 'TimeAfter',
                        'sin1', 'cos1', 'sin2', 'cos2', 'covid']])
y = np.log(df['expenditure']) # log → ποσοστιαία ερμηνεία

m = sm.OLS(y, X).fit(cov_type='HAC', cov_kws={'maxlags':4})
print(m.summary())

# Αντιπαράδειγμα: τι θα γινόταν χωρίς την παρέμβαση
Xc = X.copy(); Xc['Intervention'] = 0; Xc['TimeAfter'] = 0
counterfactual = np.exp(m.predict(Xc))
observed = df['expenditure']
print("Σωρευτική διαφορά 24 μηνών:",
      (observed - counterfactual).iloc[41:65].sum())
```

Παράδειγμα ανάγνωσης αποτελεσμάτων (σε logs, άρα ποσοστά):

Συντελεστής	Εκτίμηση	Διατύπωση για έκθεση
β_1 (Time)	+0,004	Πριν την παρέμβαση, η δαπάνη αυξανόταν κατά $\approx 0,4\%$ τον μήνα ($\approx 4,9\%$ ετησίως)
β_2 (Intervention)	-0,082	Άμεση μείωση επιπέδου $\approx 7,9\%$ [$100(e^{-0,082}-1)$] τον πρώτο μήνα εφαρμογής
β_3 (TimeAfter)	-0,002	Ο μηνιαίος ρυθμός μειώθηκε κατά 0,2 π.μ. → νέα τάση $\approx +0,2\%$ /μήνα. Η δαπάνη εξακολουθεί να αυξάνεται, με τον μισό ρυθμό.

Πώς παρουσιάζεται σωστά ένα ITS

Ένα γράφημα με: (α) τα παρατηρημένα σημεία, (β) την προσαρμοσμένη γραμμή πριν και μετά, (γ) την **αντιπαραδειγματική προβολή με διακεκομμένη γραμμή και ζώνη αβεβαιότητας**, (δ) κάθετη γραμμή στην ημερομηνία παρέμβασης. Η αντιπαραδειγματική ζώνη είναι το πιο πειστικό οπτικό στοιχείο — και το πιο συχνά παραλειπόμενο.

ΚΕΦΑΛΑΙΟ 13 — Δομικές Θραύσεις (Structural Breaks)

Μια δομική θραύση είναι σημείο όπου αλλάζει η ίδια η *σχέση* που μοντελοποιείς — όχι απλώς μια ακραία τιμή. Είναι από τις πιο υποτιμημένες απειλές: ένα μοντέλο εκτιμημένο σε δείγμα με αγνοημένο break δεν είναι απλώς ανακριβές, είναι **άκυρο**.

13.1 Τυπολογία

Τύπος	Τι αλλάζει	Παράδειγμα
Level shift	Η σταθερά — μόνιμη μετατόπιση επιπέδου	Μείωση τιμών με υπουργική απόφαση· αλλαγή ορισμού μεταβλητής
Slope shift	Η κλίση — αλλαγή ρυθμού	Επιτάχυνση διείσδυσης γενοσήμων μετά από κίνητρα συνταγογράφησης
Variance shift	Η μεταβλητότητα	Αύξηση αβεβαιότητας μετά την έναρξη κρίσης
Regime change	Ολόκληρη η δυναμική (όλοι οι συντελεστές)	Μετάβαση από περίοδο ανάπτυξης σε ύφεση· εκτίμηση με Markov-switching
Additive outlier	Μία μόνο παρατήρηση — δεν είναι break	Λάθος καταχώρισης· εφάπαξ γεγονός χωρίς συνέχεια

Η διάκριση που έχει σημασία

Additive outlier: μία τιμή εκτός γραμμής, η σειρά συνεχίζει κανονικά μετά. **Level shift (innovational):** η σειρά συνεχίζει σε *νέο* επίπεδο. Το πρώτο διορθώνεται με dummy μιας περιόδου· το δεύτερο με step dummy. Η λάθος επιλογή αλλοιώνει όλες τις εκτιμήσεις.

13.2 Chow test — γνωστό σημείο θραύσης

$$F = [(RSS_P - (RSS_1 + RSS_2))/k] / [(RSS_1 + RSS_2)/(T-2k)] \sim F(k, T-2k)$$

RSS_P = pooled· RSS_1, RSS_2 = υποπερίοδοι· k = αριθμός συντελεστών

H_0	Οι συντελεστές είναι ίδιοι στις δύο υποπεριόδους → καμία δομική θραύση
H_1	Οι συντελεστές διαφέρουν → υπάρχει θραύση στο δεδομένο σημείο
Περιορισμοί	Απαιτεί γνωστό εκ των προτέρων σημείο· επαρκείς παρατηρήσεις εκατέρωθεν· ομοσκεδαστικότητα. Αν διαλέξεις το σημείο κοιτώντας τα δεδομένα, το p-value είναι άκυρο (πρόβλημα πολλαπλών ελέγχων)

13.3 CUSUM και CUSUM of squares

Σωρευτικά αθροίσματα των τυποποιημένων recursive residuals. Δεν απαιτούν προκαθορισμένο σημείο.

Τεστ	Ανιχνεύει	Ανάγνωση
CUSUM	Συστηματικές μετατοπίσεις στους συντελεστές (κυρίως στον μέσο)	Αν η γραμμή βγει από τις ζώνες 5%, η παραμετρική σταθερότητα απορρίπτεται· το σημείο εξόδου υποδεικνύει πότε
CUSUMSQ	Αστάθεια διακύμανσης	Έξοδος από τις ζώνες → μεταβολή στη μεταβλητότητα· υποψία για ARCH

ΠΛΕΟΝΕΚΤΗΜΑ: εξαιρετικά για οπτική διάγνωση και για την έκθεση. **ΜΕΙΟΝΕΚΤΗΜΑ:** χαμηλή ισχύς — δεν εντοπίζουν μικρές ή σύντομες θραύσεις, και δεν δίνουν διάστημα εμπιστοσύνης για τη θέση.

13.4 Bai-Perron — πολλαπλές άγνωστες θραύσεις

Η σύγχρονη λύση. Εντοπίζει *ενδογενώς* τον αριθμό **και** τη θέση πολλαπλών θραύσεων ελαχιστοποιώντας το άθροισμα τετραγώνων σε όλες τις δυνατές διαμερίσεις (δυναμικός προγραμματισμός).

Στοιχείο	Περιγραφή
supF(k)	H_0 : καμία θραύση vs H_1 : k θραύσεις
supF(l+1 l)	Διαδοχικός έλεγχος: l θραύσεις vs l+1 — ο τρόπος επιλογής του αριθμού
Trimming (ε)	Ελάχιστο κλάσμα παρατηρήσεων ανά καθεστώς (τυπικά 0,15). Καθορίζει τον μέγιστο αριθμό θραύσεων
Έξοδος	Αριθμός θραύσεων, ημερομηνίες με διαστήματα εμπιστοσύνης , συντελεστές ανά καθεστώς

13.5 Πότε μια θραύση ακυρώνει το μοντέλο σου

Πέντε συνέπειες αγνοημένης θραύσης

- 1. Ψευδής unit root.** Το ADF έχει δραματικά μειωμένη ισχύ παρουσία break: μια στάσιμη σειρά με level shift φαίνεται I(1). Οδηγεί σε λανθασμένο differencing. (Λύση: Zivot-Andrews, Perron.)
- 2. Μεροληπτικές εκτιμήσεις.** Οι συντελεστές είναι σταθμισμένος μέσος δύο διαφορετικών καθεστώτων — δηλαδή δεν περιγράφουν κανένα από τα δύο.
- 3. Καταστροφικές προβλέψεις.** Το μοντέλο προεκτείνει σχέση που έπαψε να ισχύει.
- 4. Ψευδής συνολοκλήρωση** — ή, αντίθετα, αποτυχία εντοπισμού υπαρκτής.
- 5. Άκυρο ITS.** Αν υπάρχει θραύση κοντά στην παρέμβασή σου από άλλη αιτία, η εκτίμηση επίδρασης είναι αναξιόπιστη — και συνήθως δεν μπορείς να τις ξεχωρίσεις.

Πρακτική στρατηγική

Αν ξέρεις την αιτία (COVID, νόμος, αλλαγή καταγραφής): μοντελοποίησέ τη ρητά με dummy. Καλύτερο από κάθε αυτόματο τεστ.

Αν δεν την ξέρεις: Bai-Perron για εντοπισμό, μετά αναζήτησε την εξήγηση. Μια θραύση χωρίς πιθανή αιτία είναι συνήθως τεχνούργημα δεδομένων.

Αν η θραύση είναι πρόσφατη: σκέψου να εκτιμήσεις μόνο στο νέο καθεστώς, ακόμη κι αν χάσεις παρατηρήσεις. Λίγα σχετικά δεδομένα > πολλά άσχετα.

ΚΕΦΑΛΑΙΟ 14 — Μοντέλα μεταβλητότητας

14.1 Το φαινόμενο

Ετεροσκεδαστικότητα: η διακύμανση των σφαλμάτων δεν είναι σταθερή. **Volatility clustering:** η ειδική μορφή που εμφανίζεται σε χρονοσειρές — «μεγάλες μεταβολές ακολουθούνται από μεγάλες μεταβολές, μικρές από μικρές, ανεξαρτήτως προσήμου».

ΤΟ ΚΡΙΣΙΜΟ ΣΗΜΕΙΟ: η ίδια η σειρά μπορεί να είναι *μη προβλέψιμη* στον μέσο (random walk) και ταυτόχρονα **απολύτως προβλέψιμη στη διακύμανση**. Αυτή η ασυμμετρία είναι η ουσία των μοντέλων GARCH.

14.2 ARCH-LM — ο έλεγχος

Παλινδρόμισε τα τετραγωνισμένα κατάλοιπα στις υστερήσεις τους:

$$\hat{\varepsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\varepsilon}_{t-1}^2 + \dots + \alpha_q \hat{\varepsilon}_{t-q}^2 + v_t \quad LM = T \cdot R^2 \sim \chi^2(q)$$

H_0	$\alpha_1 = \dots = \alpha_q = 0 \rightarrow$ δεν υπάρχουν ARCH effects (ομοσκεδαστικότητα υπό συνθήκη)
H_1	Υπάρχουν ARCH effects
$p < 0,05$	Υπάρχει υπό συνθήκη ετεροσκεδαστικότητα $\rightarrow$ εξέτασε GARCH

Προϋπόθεση: εφαρμόζεται στα κατάλοιπα ενός *ήδη καλά προδιαγεγραμμένου* μοντέλου μέσου. Αν το ARIMA είναι λάθος, το ARCH-LM θα βγάλει ψευδώς θετικό.

14.3 Η οικογένεια

ARCH(q)

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0,1) \\ \sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2$$

ΠΡΟΒΛΗΜΑ: απαιτεί πολλά lags για να πιάσει τη μακρά μνήμη της μεταβλητότητας.

GARCH(p,q) — το πρότυπο

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Παράμετρος	Ερμηνεία
$\omega > 0$	Σταθερή βάση της διακύμανσης
α (ARCH)	Αντίδραση σε πρόσφατα shocks — πόσο «νευρική» είναι η αγορά
β (GARCH)	Επιμονή — πόσο διαρκεί η αυξημένη μεταβλητότητα
$\alpha + \beta$	Το πιο ενημερωτικό μέγεθος. Πρέπει < 1 για στασιμότητα. Τιμές 0,95–0,99 (τυπικές σε χρηματοοικονομικά) σημαίνουν πολύ αργή επαναφορά στη μακροχρόνια μεταβλητότητα. $\alpha + \beta = 1 \rightarrow$ IGARCH (μόνιμα shocks)
Μακροχρόνια διακύμανση	$\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$

Το GARCH(1,1) είναι σχεδόν πάντα αρκετό. Είναι ένα από τα πιο ανθεκτικά εμπειρικά ευρήματα στην οικονομετρία: πολύπλοκες προδιαγραφές σπάνια το ξεπερνούν out-of-sample.

EGARCH και GJR-GARCH — ασυμμετρία

Το βασικό GARCH υποθέτει ότι θετικά και αρνητικά shocks ίδιου μεγέθους έχουν την *ίδια* επίδραση στη μεταβλητότητα. Στην πραγματικότητα υπάρχει **leverage effect**: οι αρνητικές ειδήσεις αυξάνουν τη μεταβλητότητα περισσότερο.

Μοντέλο	Εξίσωση διακύμανσης	Χαρακτηριστικά
EGARCH	$\log \sigma_t^2 = \omega + \beta_1 \log \sigma_{t-1}^2 + \sum \alpha_i [z_{t-i} - E z] + \sum \gamma_i z_{t-i}$	Λογαριθμική μορφή $\rightarrow$ δεν χρειάζονται περιορισμοί θετικότητας· $\gamma < 0$ δείχνει leverage effect
GJR-GARCH	$\sigma_t^2 = \omega + (\alpha + \gamma \cdot I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ $I_{t-1} = 1$ αν $\varepsilon_{t-1} < 0$	Πιο διαισθητικό: $\gamma > 0$ σημαίνει ότι τα αρνητικά shocks έχουν επιπλέον επίδραση γ

14.4 Σε ποιες σειρές έχουν πραγματικό νόημα

✓ Έχει νόημα	✗ Συνήθως δεν έχει
Ημερήσιες/ενδοημερήσιες αποδόσεις μετοχών, δεικτών, συναλλάγματος Τιμές ενέργειας και εμπορευμάτων Επιτόκια σε περιόδους αστάθειας Οποιαδήποτε υψηλής συχνότητας σειρά με ορατά «κύματα» μεταβλητότητας	Μηνιαία φαρμακευτική δαπάνη ή πωλήσεις Νοσηλείες, συνταγές, επιδημιολογικά counts Μακροοικονομικές σειρές χαμηλής συχνότητας Οποιαδήποτε σειρά με $T < 200-300$

Ειλικρινής προειδοποίηση

Το GARCH απαιτεί εκατοντάδες παρατηρήσεις για αξιόπιστη εκτίμηση. Με 84 μηνιαία σημεία, ένα «σημαντικό» GARCH είναι σχεδόν σίγουρα υπερπροσαρμογή. Στη δουλειά σου, η ετεροσκεδαστικότητα λύνεται συνήθως με **λογαριθμικό μετασχηματισμό** ή **εύρωστα standard errors** — όχι με GARCH. Το κεφάλαιο αυτό υπάρχει για να αναγνωρίζεις πότε *δεν* το χρειάζεσαι, εξίσου με το πότε το χρειάζεσαι.

ΕΛΕΓΧΟΣ ΚΑΤΑΝΟΗΣΗΣ — Τεύχος Γ΄

A. Πολυμεταβλητά & συνολοκλήρωση

1. Έχεις τρεις σειρές: μία $I(0)$, δύο $I(1)$. Ποιο μοντέλο επιλέγεις και γιατί αποκλείεις το Johansen;
2. Johansen με trace test: $r=0$ απορρίπτεται, $r \leq 1$ δεν απορρίπτεται, $K=3$. Τι σημαίνει και τι εκτιμάς;
3. Σε VECM ο συντελεστής προσαρμογής είναι $\gamma = -0,08$ (μηνιαία δεδομένα). Πόσος είναι ο χρόνος ημιζωής μιας απόκλισης και τι σημαίνει πρακτικά;
4. Γιατί το CCF σε ακατέργαστες σειρές είναι παραπλανητικό και ποια είναι η διόρθωση;

B. Αιτιότητα & ITS

1. Σε ITS: $\beta_1 = +1,8$ μονάδες/μήνα, $\beta_2 = -12,4$, $\beta_3 = -2,1$, όλα σημαντικά. Περίγραψε με ακρίβεια τι συνέβη — και τι θα συμβεί σε 12 μήνες αν συνεχιστεί η τάση.
2. Ένα ITS δείχνει ισχυρή επίδραση πολιτικής που εφαρμόστηκε τον Μάρτιο 2020. Ποια είναι η προφανής απειλή εγκυρότητας και πώς την αντιμετωπίζεις;
3. Γιατί ένα placebo test με ψευδή ημερομηνία 12 μήνες νωρίτερα είναι χρήσιμο, και τι σημαίνει αν βγει «σημαντικό»;
4. Ποια είναι η ουσιαστική διαφορά μεταξύ απλού ITS και controlled ITS ως προς το τι μπορείς να ισχυριστείς;
5. Έχεις δύο πολιτικές που εφαρμόστηκαν με 4 μήνες διαφορά. Γιατί δεν μπορείς να εκτιμήσεις χωριστά τις επιδράσεις τους και τι γράφεις στην έκθεση;

Γ. Θραύσεις & μεταβλητότητα

1. Το ADF δεν απορρίπτει τη μοναδιαία ρίζα, αλλά το γράφημα δείχνει σαφή στάσιμη συμπεριφορά γύρω από δύο διαφορετικά επίπεδα. Τι συμβαίνει και ποιο τεστ τρέχεις;
2. Πότε είναι σωστό να πετάξεις τα δεδομένα πριν από μια δομική θραύση αντί να τη μοντελοποιήσεις;
3. Σε GARCH(1,1): $\alpha = 0,09$, $\beta = 0,89$. Υπολόγισε την επιμονή και σχολίασε. Τι θα σήμαινε $\alpha + \beta = 1,02$;
4. Ένας συνάδελφος προτείνει GARCH για μηνιαία δαπάνη ΕΟΠΥΥ (84 σημεία) επειδή «το ARCH-LM βγήκε σημαντικό». Τι του απαντάς;

Επόμενο βήμα

Το **Τεύχος Δ΄** καλύπτει τα Μέρη 15–20: ειδικές σειρές (Croston, SBA, TSB για intermittent demand· TBATS για πολλαπλή εποχικότητα· count και zero-inflated μοντέλα· high-frequency data), μετατροπή της πρόβλεψης σε πρόβλημα supervised learning με feature engineering και τους κινδύνους leakage, Random Forest/XGBoost/LightGBM/CatBoost, recursive vs direct forecasting, σύντομη επισκόπηση RNN/LSTM/GRU/TCN/Transformers και γιατί το deep learning δεν είναι αυτομάτως καλύτερο, time-aware validation (rolling origin, expanding/rolling window, walk-forward), όλες τις μετρικές (MAE, RMSE, MAPE, sMAPE, **MASE**, RMSSE) και πλαίσιο επιλογής μοντέλου.