

ΕΓΧΕΙΡΙΔΙΟ ΕΚΠΑΙΔΕΥΣΗΣ

TIME SERIES ANALYSIS

FROM ZERO TO HERO

ΤΕΥΧΟΣ Δ΄

Ειδικές σειρές · Machine Learning · Deep Learning

Επικύρωση · Μετρικές · Επιλογή μοντέλου

Μέρη 15-20 του πλήρους προγράμματος

Από το μοντέλο στην αποδεδειγμένη προβλεπτική ικανότητα

Περιλαμβάνει απαντήσεις ελέγχου Τεύχους Γ΄

Αύγουστος 2026

ΑΠΑΝΤΗΣΕΙΣ — Έλεγχος κατανόησης Τεύχους Γ΄

1. Μία $I(0)$, δύο $I(1)$.

ARDL με bounds test. Το Johansen απαιτεί ομοιογενή τάξη ολοκλήρωσης — σχεδιάστηκε για σύστημα $I(1)$ μεταβλητών και η παρουσία $I(0)$ αλλοιώνει τις κρίσιμες τιμές. Το ARDL δέχεται μείγμα $I(0)/I(1)$ (ποτέ $I(2)$) και δίνει και ECM αναπαράσταση. Εναλλακτικά, αν η $I(0)$ είναι πραγματικά εξωγενής, VECM στις δύο $I(1)$ με την $I(0)$ ως εξωγενή μεταβλητή.

2. $K=3$, $r=0$ απορρίπτεται, $r \leq 1$ δεν απορρίπτεται.

Η εκτίμηση είναι $r = 1$: ένα διάνυσμα συνολοκλήρωσης. Επειδή $0 < r < K$, το σωστό μοντέλο είναι **VECM με $r=1$** . Υπάρχει μία μακροχρόνια σχέση ισορροπίας μεταξύ των τριών μεταβλητών και δύο κοινές στοχαστικές τάσεις ($K-r = 2$).

3. $\gamma = -0,08$ σε μηνιαία δεδομένα.

Το 8% της απόκλισης διορθώνεται κάθε μήνα. Χρόνος ημιζωής $= \ln(0,5)/\ln(1-0,08) = -0,693/-0,0834 \approx 8,3$ μήνες. Πρακτικά: πολύ αργή προσαρμογή — χρειάζονται πάνω από δύο χρόνια για να απορροφηθεί σχεδόν πλήρως μια απόκλιση. Αυτό έχει άμεση σημασία για policy: μια παρέμβαση που εκτρέπει το σύστημα από την ισορροπία θα έχει διαρκή επίδραση για πολλά τρίμηνα.

4. CCF σε ακατέργαστες σειρές.

Η κοινή τάση ή/και εποχικότητα παράγει υψηλές συσχετίσεις σε όλα τα lags, ανεξάρτητα από πραγματική σχέση. Διόρθωση: **prewhitening** — προσαρμοσε ARIMA στο X , εφάρμοσε το ίδιο φίλτρο και στις δύο σειρές, και υπολόγισε το CCF στα φιλτραρισμένα κατάλοιπα.

5. $\beta_1 = +1,8$ · $\beta_2 = -12,4$ · $\beta_3 = -2,1$.

Πριν: αύξηση 1,8 μονάδες/μήνα. Τη στιγμή της παρέμβασης: άμεση πτώση 12,4 μονάδων. Η κλίση μειώθηκε κατά 2,1, άρα **η νέα κλίση είναι $1,8 - 2,1 = -0,3$ μονάδες/μήνα** — η πορεία αντιστρέφθηκε από ανοδική σε ελαφρώς καθοδική.

Στους 12 μήνες: παρατηρούμενο $= -12,4 + 12(-0,3) = -16,0$ έναντι της βάσης· αντιπαράδειγμα $= +12(1,8) = +21,6$. Συνολική εκτιμώμενη επίδραση $\approx 37,6$ μονάδες στους 12 μήνες. Αυτός ο αριθμός — όχι το p-value — είναι το εύρημα που ανακοινώνεις.

6. Πολιτική Μαρτίου 2020.

Πλήρης σύγχυση με την πανδημία: η ημερομηνία συμπίπτει με το μεγαλύτερο εξωγενές shock της περιόδου. Στο απλό ITS οι δύο επιδράσεις είναι **μη ταυτοποιήσιμες**. Αντιμετώπιση: (α) **controlled ITS** ή synthetic control με σειρά που επηρεάστηκε από COVID αλλά όχι από την πολιτική — η μόνη πραγματικά ισχυρή λύση· (β) ρητό COVID dummy με μεγάλη περίοδο παρακολούθησης μετά· (γ) ανάλυση ευαισθησίας εξαιρώντας Μαρ-Αυγ 2020· (δ) αν τίποτα δεν λειτουργεί, *δήλωσε ότι η επίδραση δεν μπορεί να απομονωθεί*. Αυτή είναι έγκυρη επιστημονική απάντηση.

7. Placebo test.

Τρέχεις το ίδιο μοντέλο με ψευδή ημερομηνία εκεί που δεν συνέβη τίποτα. Αν βγει «σημαντική επίδραση», το μοντέλο ανιχνεύει **θόρυβο ή μη γραμμικότητα της προ-τάσης**, όχι πραγματική παρέμβαση — άρα το κύριο εύρημά σου δεν είναι αξιόπιστο. Είναι ο φθηνότερος και πιο πειστικός έλεγχος ευρωστίας που μπορείς να προσθέσεις σε μια έκθεση.

8. ITS vs controlled ITS.

Το απλό ITS συγκρίνει την ομάδα με *τον εαυτό της* — δεν μπορεί να ξεχωρίσει την πολιτική από οτιδήποτε άλλο συνέβη ταυτόχρονα (εποχική έξαρση, οικονομική συγκυρία, άλλη ρύθμιση). Το controlled ITS αφαιρεί ό,τι επηρέασε και την ομάδα ελέγχου, οπότε ο ισχυρισμός γίνεται: «η επίδραση δεν οφείλεται σε κοινούς χρονικούς παράγοντες». Παραμένει η υπόθεση παράλληλων προ-τάσεων, την οποία πρέπει να ελέγξεις γραφικά και στατιστικά.

9. Δύο πολιτικές με 4 μήνες διαφορά.

Οι μεταβλητές παρέμβασης είναι σχεδόν τέλεια συγγραμμικές: με μόλις 4 σημεία που τις διακρίνουν, οι επιμέρους συντελεστές έχουν τεράστια standard errors και ασταθή πρόσημα. Στην έκθεση: «Λόγω της χρονικής εγγύτητας των δύο μέτρων (4 μήνες), οι επιδράσεις τους δεν είναι στατιστικά ταυτοποιήσιμες χωριστά. Αναφέρουμε τη **συνδυασμένη** επίδραση της δέσμης μέτρων.» Είναι πιο έντιμο και πιο χρήσιμο από ψευδοακριβείς χωριστές εκτιμήσεις.

10. ADF δεν απορρίπτει, αλλά η σειρά είναι στάσιμη γύρω από δύο επίπεδα.

Κλασική περίπτωση όπου η **δομική θραύση μιμείται μοναδιαία ρίζα**: το ADF έχει δραματικά μειωμένη ισχύ παρουσία level shift. Τρέξε **Zivot-Andrews** (unit root με έναν ενδογενή break) ή Perron test με γνωστό break· επιβεβαίωσε τη θέση με Bai-Perron και μοντελοποίησε με step dummy αντί για differencing.

11. Πότε πετάς τα προ-θραύσης δεδομένα.

Όταν (α) ο μηχανισμός άλλαξε ουσιαστικά και τα παλιά δεδομένα δεν περιέχουν πληροφορία για το νέο καθεστώς (αλλαγή θεσμικού πλαισίου, αλλαγή ορισμού μεταβλητής), και (β) υπάρχουν αρκετές παρατηρήσεις μετά τη θραύση για αξιόπιστη εκτίμηση. Αν το (β) δεν ισχύει, μοντελοποίησε τη θραύση με dummy και κράτησε όλα τα δεδομένα. Κανόνας: λίγα σχετικά δεδομένα > πολλά άσχετα, αλλά μόνο εφόσον τα «λίγα» επαρκούν.

12. GARCH(1,1) με $\alpha=0,09$, $\beta=0,89$.

Επιμονή $\alpha+\beta = 0,98$ — πολύ υψηλή αλλά <1, άρα στάσιμη. Χρόνος ημιζωής shock μεταβλητότητας = $\ln(0,5)/\ln(0,98) \approx 34$ **περίοδοι**: μια έξαρση μεταβλητότητας διαρκεί πολύ. Αν $\alpha+\beta = 1,02 > 1$, η υπό συνθήκη διακύμανση είναι **εκρηκτική** — δεν υπάρχει πεπερασμένη μακροχρόνια διακύμανση. Δεν το ερμηνεύεις· το θεωρείς ένδειξη λάθους προδιαγραφής (αγνοημένο structural break στη διακύμανση, ακραίες τιμές, λάθος μοντέλο μέσου).

13. GARCH για μηνιαία δαπάνη ΕΟΠΥΥ (84 σημεία).

Τρία επιχειρήματα: (1) **Μέγεθος δείγματος** — το GARCH χρειάζεται εκατοντάδες παρατηρήσεις· με 84 οι εκτιμήσεις είναι αναξιόπιστες και συνήθως στα όρια της στασιμότητας. (2) **Ψευδώς θετικό ARCH-LM** — με 2-3 ακραίες τιμές (COVID, εφάπαξ πληρωμές) ή αγνοημένο level shift, το τεστ βγαίνει σημαντικό χωρίς πραγματικό volatility clustering. (3) **Δεν υπάρχει ερώτημα που να το χρειάζεται** — δεν τιμολογείς δικαιώματα προαίρεσης· θέλεις πρόβλεψη επιπέδου. Λύση: log-μετασχηματισμός για σταθεροποίηση διακύμανσης και εύρωστα (HAC) standard errors.

ΚΕΦΑΛΑΙΟ 15 — Ειδικές χρονοσειρές

Υπάρχουν κατηγορίες σειρών όπου τα ARIMA/ETS δεν είναι απλώς υποβέλτιστα — είναι *λάθος εργασία*, γιατί παραβιάζονται οι θεμελιώδεις υποθέσεις τους.

15.1 Διακοπτόμενη ζήτηση (Intermittent demand)

ΟΡΙΣΜΟΣ: σειρά με πολλά μηδενικά και σποραδικές θετικές τιμές. Τυπικό: ανταλλακτικά, σπάνια φάρμακα, βραδυκίνητοι κωδικοί φαρμακείου.

Γιατί το ARIMA αποτυγχάνει εδώ

Η κατανομή δεν είναι κατά προσέγγιση κανονική (έχει «τοίχο» στο μηδέν)· η πρόβλεψη 0,3 κουτιά είναι μη ερμηνεύσιμη· τα διαστήματα πρόβλεψης βγαίνουν αρνητικά· και το ουσιαστικό ερώτημα δεν είναι «πόσα θα πουληθούν» αλλά «**πόσα πρέπει να έχω για να μην μείνω χωρίς**» — ερώτημα κατανομής, όχι σημειακής πρόβλεψης.

Ταξινόμηση Syntetos-Boylan-Croston

Δύο μεγέθη: **ADI** (μέσο διάστημα μεταξύ ζητήσεων) και **CV²** (τετράγωνο του συντελεστή μεταβλητότητας των μεγεθών ζήτησης).

	CV ² ≤ 0,49	CV ² > 0,49
ADI < 1,32	Smooth — κανονική ζήτηση → ETS / ARIMA	Erratic — τακτική αλλά ασταθής → ETS σε log· έμφαση σε διαστήματα
ADI ≥ 1,32	Intermittent — αραιή, σταθερά μεγέθη → Croston / SBA	Lumpy — αραιή και ασταθής → SBA / TSB· η δυσκολότερη κατηγορία

Croston (1972)

Η ιδέα: χώρισε τη σειρά σε δύο ξεχωριστές σειρές και εξομάλυνε κάθε μία με SES *μόνο όταν εμφανίζεται ζήτηση*.

z_t = μέγεθος ζήτησης (μόνο μη μηδενικές) · p_t = διάστημα μεταξύ ζητήσεων

$$\hat{z}_t = \alpha z_t + (1-\alpha)\hat{z}_{t-1}, \quad \hat{p}_t = \alpha p_t + (1-\alpha)\hat{p}_{t-1}$$

Πρόβλεψη ανά περίοδο: $\hat{y} = \hat{z}_t / \hat{p}_t$

Παραλλαγή	Τι διορθώνει	Τύπος / χαρακτηριστικό
Croston	—	Η αρχική μέθοδος· μεροληπτική προς τα πάνω (ο λόγος δύο εκτιμητών δεν είναι αμερόληπτος εκτιμητής του λόγου)
SBA (Syntetos-Boylan Approximation)	Τη μεροληψία του Croston	$\hat{y} = (1 - \alpha/2) \cdot (\hat{z}/\hat{\beta})$. Πολλαπλασιαστική διόρθωση· συνήθως η καλύτερη επιλογή στην πράξη
TSB (Teunter-Syntetos-Babai)	Την απαξίωση προϊόντος	Ενημερώνει την πιθανότητα ζήτησης σε κάθε περίοδο, όχι μόνο όταν υπάρχει ζήτηση. Άρα η πρόβλεψη μειώνεται όταν το προϊόν σταματά να κινείται — κρίσιμο για καταργούμενους κωδικούς

Πρακτικό συμπέρασμα για φαρμακείο

Για βραδυκίνητους κωδικούς χρησιμοποίησε **SBA** για ενεργά προϊόντα και **TSB** όταν υπάρχει κίνδυνος απαξίωσης. Και κυρίως: μην αξιολογείς με MAPE (διαιρεί με μηδενικά) αλλά με MASE ή, ακόμη καλύτερα, με **επίτευξη στόχου service level** — το μέγεθος που πράγματι σε ενδιαφέρει.

15.2 Πολλαπλή εποχικότητα

Ημερήσια δεδομένα με εβδομαδιαίο ($s=7$) και ετήσιο ($s=365,25$) μοτίβο. Το SARIMA δέχεται μία μόνο εποχική περίοδο και καταρρέει με $s>24$ (πάρα πολλές παράμετροι).

Μέθοδος	Λογική	Πότε
TBATS	Trigonometric seasonality, Box-cox, ARMA errors, Trend, Seasonal. Αναπαριστά κάθε εποχικότητα με λίγους αρμονικούς όρους αντί για s παραμέτρους	2-3 εποχικότητες, μη αέριες περιόδους (365,25), αργή εκτέλεση αλλά αξιόπιστο
MSTL	Διαδοχική STL για κάθε εποχικότητα, μετά ETS/ARIMA στο υπόλοιπο	Ταχύτερο, πιο διαφανές, εύκολη οπτικοποίηση συνιστωσών
Dynamic harmonic regression	Fourier όροι ως regressors σε ARIMA: $\sin/\cos(2\pi kt/s)$ για κάθε s	Η πιο ευέλικτη λύση. Δέχεται και εξωγενείς μεταβλητές· ο αριθμός αρμονικών K επιλέγεται με AICc
Prophet	Προσθετικό μοντέλο με piecewise τάση, Fourier εποχικότητα, αργίες	Γρήγορο, ανθεκτικό σε κενά, εύκολο· αλλά συχνά υπολείπεται σε ακρίβεια — χρήσιμο ως baseline, όχι ως τελική λήξη

15.3 Σειρές μετρήματος (Count time series)

Μοντέλο	Πότε	Σημειώσεις
Poisson GLM	Μετρήματα με $\text{Var} \approx \text{Mean}$	Σπάνια ισχύει σε πραγματικά δεδομένα υγείας
Negative Binomial	Υπερδιασπορά ($\text{Var} > \text{Mean}$)	Η προεπιλογή για νοσηλείες, κρούσματα, συνταγές. Έλεγε με τεστ υπερδιασποράς
Zero-inflated (ZIP / ZINB)	Περισσότερα μηδενικά από όσα προβλέπει το μοντέλο	Υποθέτει δύο διεργασίες: μία που παράγει «δομικά» μηδενικά και μία που παράγει μετρήματα. Χρειάζεται θεωρητική δικαιολόγηση, όχι μόνο στατιστική
Hurdle	Ίδιο πρόβλημα, διαφορετική λογική	Πρώτα «θα υπάρξει ζήτηση;», μετά «πόση;». Συχνά πιο ερμηνεύσιμο από ZINB
INGARCH / GLARMA	Counts με αυτοσυσχέτιση	Συνδυάζει κατανομή μετρήματος με δυναμική χρονοσειράς — το σωστό εργαλείο για επιδημιολογική επιτήρηση

Στοιχεία που χρειάζεσαι πάντα σε αυτά τα μοντέλα: $\text{offset} = \log(\text{πληθυσμός})$ ή $\log(\text{ημέρες})$ για να μοντελοποιείς *ρυθμούς*, αρμονικούς όρους για εποχικότητα, και χρονική τάση.

15.4 Δεδομένα υψηλής συχνότητας

Ωριαία, λεπτού ή tick-level δεδομένα. Ιδιαιτερότητες: τεράστιο T , πολλαπλή εποχικότητα, ημερολογιακά κενά (αργίες, κλειστές αγορές), microstructure noise, και συχνά μη ισοδιαστημικές παρατηρήσεις.

Πρακτικές: συνάθροιση σε χαμηλότερη συχνότητα όταν το ερώτημα το επιτρέπει (συνήθως το επιτρέπει)· dynamic harmonic regression για πολλαπλή εποχικότητα· realized volatility αντί για GARCH· και ML μοντέλα, όπου το μεγάλο T επιτρέπει επιτέλους να αποδώσουν.

15.5 Πότε ΔΕΝ είναι κατάλληλα τα κλασικά ARIMA/ETS — σύνοψη

Κατάσταση	Γιατί αποτυγχάνουν	Αντ' αυτού
Πολλά μηδενικά / intermittent	Υπόθεση συνεχούς κανονικής κατανομής	Croston / SBA / TSB· hurdle μοντέλα
Μικροί ακέραιοι αριθμοί	Αρνητικές και μη ακέραιες προβλέψεις	Poisson / NB / INGARCH
Πολλαπλή ή μη ακέραια εποχικότητα	Ένα μόνο s · έκρηξη παραμέτρων για $s > 24$	TBATS / MSTL / Fourier + ARIMA
Ισχυρή μη γραμμικότητα, κατώφλια	Γραμμική δομή	Threshold AR, Markov-switching, ML
Χιλιάδες σχετιζόμενες σειρές	Δεν μοιράζονται πληροφορία μεταξύ σειρών	Global ML μοντέλα (Κεφ. 16), ιεραρχική συμπίλιωση
Πολύ σύντομες σειρές ($T < 20$)	Δεν επαρκούν για εκτίμηση	Baselines· judgmental forecasting· δανεισμός από όμοιες σειρές

ΚΕΦΑΛΑΙΟ 16 — Machine Learning για χρονοσειρές

16.1 Η μετατροπή σε πρόβλημα supervised learning

Τα μοντέλα ML δεν «καταλαβαίνουν» τον χρόνο. Χρειάζονται πίνακα $X \rightarrow y$. Η δουλειά μας είναι να μετατρέψουμε τη χρονική δομή σε στήλες.

Αρχική σειρά: $y_1, y_2, y_3, \dots, y_T$

Μετά τη μετατροπή (window = 3):

$[y_1, y_2, y_3] \rightarrow y_4 \cdot [y_2, y_3, y_4] \rightarrow y_5 \cdot [y_3, y_4, y_5] \rightarrow y_6 \cdot \dots$

Αυτή η μετατροπή ονομάζεται **sliding window** ή **embedding**. Από εκεί και πέρα, οποιοσδήποτε αλγόριθμος regression μπορεί να εφαρμοστεί — με έναν κρίσιμο περιορισμό: **η σειρά των γραμμών δεν πρέπει ποτέ να ανακατευτεί κατά την επικύρωση**.

16.2 Feature engineering

Εδώ κερδίζεται ή χάνεται το παιχνίδι. Ένα LightGBM με καλά χαρακτηριστικά νικά ένα LSTM με φτωχά.

Κατηγορία	Χαρακτηριστικά	Σημειώσεις
Υστερήσεις	lag 1, 2, 3· lag 7 (εβδομαδιαία)· lag 12, 24 (μηνιαία εποχικότητα)· lag 365	Ο πυρήνας. Επίλεξε με βάση ACF/PACF και θεσμική γνώση, όχι εξαντλητικά
Κυλιόμενα στατιστικά	rolling mean/median (3, 6, 12)· rolling SD· rolling min/max· expanding mean	Πάντα με .shift(1) πρώτα — αλλιώς περιλαμβάνουν την τρέχουσα τιμή (leakage)
Ημερολογιακά	μήνας, τρίμηνο, ημέρα εβδομάδας, ημέρα μήνα, εβδομάδα έτους, εργάσιμες ημέρες, αργίες, Πάσχα	Κυκλική κωδικοποίηση για συνέχεια: $\sin(2\pi t/12)$, $\cos(2\pi t/12)$ αντί για ακέραιο μήνα
Τάση	χρονικός δείκτης $t \cdot t^2$ · χρόνος από την έναρξη	Τα δέντρα δεν μπορούν να προεκτείνουν τάση — βλ. §16.5
Επιχειρησιακά	τιμή, promo flag, εκπτώσεις, ανταγωνιστές, απόθεμα, καιρός	Μόνο αν είναι γνωστά στον χρόνο πρόβλεψης
Διαφορές	$y_{t-1} - y_{t-2}$ · ρυθμός μεταβολής· λόγος προς rolling mean	Βοηθούν τα δέντρα να «δουν» δυναμική που δεν πιάνουν από επίπεδα

16.3 Data leakage — η θανάσιμη παγίδα

Ορισμός

Leakage είναι η χρήση, κατά την εκπαίδευση, οποιασδήποτε πληροφορίας που *δεν θα ήταν διαθέσιμη* τη στιγμή της πραγματικής πρόβλεψης. Το αποτέλεσμα: εντυπωσιακή επίδοση στο test set και πλήρης αποτυχία στην παραγωγή.

Μορφή leakage	Πώς συμβαίνει	Πρόληψη
Κεντραρισμένα παράθυρα	<code>rolling(center=True)</code> ή <code>rolling</code> χωρίς <code>shift</code> — περιλαμβάνει τη σημερινή τιμή	Πάντα <code>y.shift(1).rolling(k)</code>
Κλιμάκωση σε όλο το dataset	<code>StandardScaler fit</code> στο σύνολο πριν τον διαχωρισμό — ο μέσος του test διαρρέει	Fit μόνο στο train· transform στο test
Συμπλήρωση κενών	Interpolation ή <code>ffill/bfill</code> πριν τον διαχωρισμό· <code>bfill</code> είναι πάντα leakage	Μόνο forward-looking μέθοδοι, εντός train
Επιλογή χαρακτηριστικών	Επιλογή features με βάση συσχέτιση σε όλο το dataset	Εντός του training fold μόνο
Ταυτόχρονοι regressors	Χρήση X_t για πρόβλεψη y_t όταν το X δεν είναι γνωστό εκ των προτέρων	Χρησιμοποίησε X_{t-h} ή μόνο πραγματικά γνωστά μελλοντικά
Target encoding	Κωδικοποίηση κατηγοριών με τον μέσο του target σε όλο το dataset	Out-of-fold encoding με χρονικό διαχωρισμό

Ο έλεγχος διαθεσιμότητας

Για κάθε χαρακτηριστικό ρώτησε: «Αν βρισκόμουν στην ημερομηνία T και ήθελα να προβλέψω το $T+h$, θα είχα αυτή την τιμή στα χέρια μου;» Αν η απάντηση είναι όχι — ή «θα την είχα, αλλά με καθυστέρηση 2 μηνών» — το χαρακτηριστικό είναι άκυρο ή πρέπει να μετατοπιστεί. Στα δεδομένα ΕΟΠΥΥ, για παράδειγμα, η οριστικοποίηση της δαπάνης έρχεται μήνες μετά· η *πρώτη* εκτίμηση είναι το μόνο που έχεις σε πραγματικό χρόνο.

16.4 Recursive vs Direct forecasting

	Recursive (iterative)	Direct
Λογική	Ένα μοντέλο για $h=1$ · η πρόβλεψη τροφοδοτείται ως είσοδος για $h=2$, κ.ο.κ.	Ξεχωριστό μοντέλο για κάθε ορίζοντα: f_1 για $h=1$, f_2 για $h=2$, ...
Πλεονεκτήματα	Ένα μοντέλο· αξιοποιεί όλα τα δεδομένα· φυσικό για μακρύ ορίζοντα	Καμία συσσώρευση σφάλματος· κάθε μοντέλο βελτιστοποιεί τον δικό του ορίζοντα
Μειονεκτήματα	Συσσώρευση σφάλματος — τα λάθη πολλαπλασιάζονται· μεροληψία σε μακρύ h	h μοντέλα προς εκπαίδευση/συντήρηση· λιγότερα δεδομένα ανά μοντέλο· ασυνεπείς τροχιές
Πότε	Μικρό h · σταθερή δυναμική· περιορισμένοι πόροι	Μεγάλο h · όταν η ακρίβεια σε συγκεκριμένο ορίζοντα είναι κρίσιμη

Τρίτη επιλογή: Multi-output — ένα μοντέλο που προβλέπει και τους h ορίζοντες ταυτόχρονα. Συνηθισμένο στα νευρωνικά δίκτυα· διατηρεί συνέπεια στην τροχιά.

16.5 Οι αλγόριθμοι

Αλγόριθμος	Χαρακτηριστικά	Δυνατά σημεία	Αδυναμίες
Random Forest	Bagging δέντρων, τυχαία υποσύνολα χαρακτηριστικών	Εύρωστο, λίγο tuning, καλή βάση σύγκρισης	Συνήθως υπολείπεται των boosting μεθόδων· βαρύ σε μνήμη
XGBoost	Gradient boosting με κανονικοποίηση	Πολύ ακριβές, ώριμο, καλή τεκμηρίωση	Πολλές υπερπαραμέτροι· αργό σε πολύ μεγάλα δεδομένα
LightGBM	Leaf-wise growth, histogram binning	Πολύ γρήγορο· η προεπιλογή για global forecasting σε χιλιάδες σειρές	Επιρρεπές σε overfitting με μικρά δεδομένα· χρειάζεται προσοχή στο num_leaves
CatBoost	Ordered boosting, εγγενής χειρισμός κατηγορικών	Άριστο με πολλές κατηγορίες (SKU, κατάσταση, κατηγορία ATC)· λιγότερο tuning	Αργότερη εκπαίδευση

Ο κρίσιμος περιορισμός των δέντρων

Τα δέντρα **δεν προεκτείνουν**. Προβλέπουν μόνο τιμές που έχουν δει στο training set. Σε σειρά με ανοδική τάση, το μοντέλο θα «κολλήσει» στο ανώτατο ιστορικό επίπεδο και θα υποεκτιμά συστηματικά.

Λύσεις: (α) εκπαίδευση σε διαφορές ή σε λόγους αντί για επίπεδα· (β) αφαίρεση τάσης πριν και επαναφορά μετά· (γ) υβριδικό: γραμμικό μοντέλο για την τάση + ML για τα κατάλοιπα.

16.6 Global vs Local μοντέλα

	Local (ένα μοντέλο ανά σειρά)	Global (ένα μοντέλο για όλες)
Παράδειγμα	ARIMA ανά SKU	LightGBM σε όλα τα SKU μαζί, με ID ως χαρακτηριστικό
Πλεονέκτημα	Εξατομικευμένο· ερμηνεύσιμο	Μοιράζεται πληροφορία μεταξύ σειρών — σωτήριο για σύντομες ή θορυβώδεις σειρές· ένα μοντέλο προς συντήρηση
Πότε	Λίγες, σημαντικές σειρές με ιδιαίτερη δυναμική	Εκατοντάδες/χιλιάδες ομοειδείς σειρές — ο λόγος που τα ML μοντέλα κέρδισαν τον διαγωνισμό M5

Τι δείχνουν τα εμπειρικά ευρήματα (M4, M5)

Σε λίγες μεμονωμένες σειρές, τα στατιστικά μοντέλα (ETS, ARIMA, θ-method) παραμένουν εξαιρετικά ανταγωνιστικά και συχνά καλύτερα. Τα ML μοντέλα κυριαρχούν όταν υπάρχουν **πολλές σχετιζόμενες** σειρές και άφθονα εξωγενή χαρακτηριστικά. Οι νικητές και των δύο διαγωνισμών ήταν **υβριδικά ή σύνθετα (ensembles)**, όχι καθαρά ML ούτε καθαρά στατιστικά.

ΚΕΦΑΛΑΙΟ 17 — Deep Learning

17.1 Οι αρχιτεκτονικές

Αρχιτεκτονική	Λογική	Δυνατά σημεία	Αδυναμίες
RNN	Κρυφή κατάσταση που ενημερώνεται σε κάθε βήμα· «μνήμη»	Φυσική αναπαράσταση ακολουθίας	Vanishing gradients — δεν μαθαίνει μακρές εξαρτήσεις. Σπάνια χρησιμοποιείται πλέον
LSTM	Πύλες (input/forget/output) που ελέγχουν τι διατηρείται	Μακρά μνήμη· το πρότυπο για χρόνια	Πολλές παράμετροι· αργή εκπαίδευση· χρειάζεται πολλά δεδομένα
GRU	Απλοποιημένο LSTM με δύο πύλες	Ταχύτερο, λιγότερες παράμετροι, συχνά ισοδύναμη επίδοση	Ίδιοι θεμελιώδεις περιορισμοί
Temporal CNN	Αιτιακές (causal) διασταλμένες συνελίξεις	Παραλληλοποιήσιμο· πολύ γρήγορο· σταθερό receptive field	Λιγότερο ευέλικτο σε μεταβλητό μήκος ακολουθίας
Transformers	Self-attention — κάθε χρονικό σημείο «κοιτά» όλα τα άλλα	Μακρές εξαρτήσεις· κλιμακώνεται με δεδομένα	Τεράστιες απαιτήσεις δεδομένων· η αποδοτικότητά τους στις χρονοσειρές αμφισβητείται
TFT (Temporal Fusion Transformer)	Συνδυάζει LSTM encoder, attention, variable selection· διαχωρίζει στατικά / γνωστά μελλοντικά / παρατηρούμενα χαρακτηριστικά	Ερμηνευσιμότητα (attention weights, feature importance)· quantile forecasts· χειρίζεται ρητά τα γνωστά μελλοντικά X	Πολύπλοκο· απαιτεί σημαντικά δεδομένα και tuning

Ειδικά μοντέλα πρόβλεψης που αξίζει να ξέρεις: *N-BEATS* και *N-HiTS* (καθαρά feed-forward με βάσεις τάσης/εποχικότητας — ισχυρή επίδοση σε benchmarks), *DeepAR* (πιθανοτικές προβλέψεις, autoregressive RNN, καλό για πολλές σχετιζόμενες σειρές).

17.2 Γιατί το deep learning δεν είναι αυτομάτως καλύτερο

Λόγος	Εξήγηση
Μέγεθος δεδομένων	Ένα LSTM με 50.000 παραμέτρους σε 84 μηνιαίες παρατηρήσεις είναι εγγυημένη υπερπροσαρμογή. Το DL χρειάζεται χιλιάδες παρατηρήσεις — ή πολλές σειρές για από κοινού εκπαίδευση
Λόγος σήματος προς θόρυβο	Οι οικονομικές και υγειονομικές σειρές έχουν χαμηλό SNR. Η επιπλέον χωρητικότητα μαθαίνει θόρυβο, όχι σήμα
Μη στασιμότητα	Το DL δεν λύνει το πρόβλημα της μη στασιμότητας — απλώς το κρύβει. Η προεπεξεργασία παραμένει απαραίτητη
Ερμηνευσιμότητα	Σε policy contexts πρέπει να εξηγήσεις γιατί. Ένα ITS με τέσσερις συντελεστές πείθει· ένα LSTM όχι
Κόστος συντήρησης	Επανεκπαίδευση, παρακολούθηση drift, εξάρτηση από υποδομή. Ένα ETS τρέχει σε δευτερόλεπτα οπουδήποτε
Εμπειρικά αποτελέσματα	Στον M4, οι καθαρές μέθοδοι DL υπολείφθηκαν των απλών στατιστικών. Ο νικητής ήταν υβριδικό (ES-RNN). Στον M5 κυριάρχησε το LightGBM, όχι τα νευρωνικά

Πρακτικός κανόνας κλιμάκωσης

T < 100, μία σειρά → ETS/ARIMA. Τελεία.

T = 100-1.000, μία σειρά → ARIMA/SARIMAX· δοκίμασε gradient boosting μόνο αν υπάρχουν πλούσια εξωγενή χαρακτηριστικά.

Πολλές σειρές (>100) → global LightGBM· εδώ αρχίζει το πραγματικό όφελος του ML.

Πολλές σειρές, μεγάλο ιστορικό, πλούσια metadata → εξέτασε TFT/N-HiTS/DeepAR — αλλά πάντα με στατιστικό baseline δίπλα.

ΚΕΦΑΛΑΙΟ 18 — Επικύρωση μοντέλου

18.1 Γιατί ΠΟΤΕ τυχαίος διαχωρισμός

Τρεις λόγοι που ο random split είναι καταστροφικός

- 1. Leakage από το μέλλον.** Αν το training set περιέχει τον Ιούνιο 2024 και το test τον Μάρτιο 2024, το μοντέλο «είδε» το μέλλον. Η επίδοση που μετράς δεν αντιστοιχεί σε καμία πραγματική συνθήκη χρήσης.
- 2. Παραβίαση της χρονικής εξάρτησης.** Γειτονικές παρατηρήσεις είναι έντονα συσχετισμένες· αν y_t είναι στο train και y_{t+1} στο test, το test είναι σχεδόν αντίγραφο του train.
- 3. Λάθος ερώτημα.** Η πρόβλεψη αφορά άγνωστο μέλλον. Ο τυχαίος διαχωρισμός μετρά παρεμβολή (interpolation), όχι προεκβολή (extrapolation) — εντελώς διαφορετικό και πολύ ευκολότερο πρόβλημα.

18.2 Χρονολογικός διαχωρισμός

[----- TRAIN -----][--- TEST ---]
 $t = 1 \dots T-h$ $t = T-h+1 \dots T$

Το ελάχιστο αποδεκτό. Το test set πρέπει να είναι τουλάχιστον τόσο μακρύ όσο ο ορίζοντας που σε ενδιαφέρει, και ιδανικά να καλύπτει έναν πλήρη εποχικό κύκλο.

Περιορισμός: ένα μόνο test window. Αν ο τελευταίος χρόνος ήταν ασυνήθιστος, η αξιολόγηση είναι παραπλανητική.

18.3 Rolling forecasting origin (time-series cross-validation)

Η μέθοδος αναφοράς. Επαναλαμβάνεις τη διαδικασία μετακινώντας το «σημείο του τώρα» προς τα εμπρός.

Expanding window (το training μεγαλώνει): [TRAIN---][T] · [TRAIN---][T] · [TRAIN---][T] · [TRAIN---][T] · Rolling window (σταθερό μήκος training): [TRAIN---][T] · [TRAIN---][T] · [TRAIN---][T] · [TRAIN---][T] ·

	Expanding window	Rolling (sliding) window
Training set	Μεγαλώνει σε κάθε βήμα	Σταθερό μήκος· «ξεχνά» παλιά δεδομένα
Πλεονέκτημα	Χρησιμοποιεί όλη τη διαθέσιμη πληροφορία· καλύτερο για σταθερές διαδικασίες	Προσαρμόζεται σε αλλαγές καθεστώτος· αντικατοπτρίζει τη ρεαλιστική πρακτική επανεκπαίδευσης
Πότε	Σταθερή δομή· περιορισμένα δεδομένα	Ύπαρξη structural breaks ή concept drift · άφθονα δεδομένα

Walk-forward validation: ο γενικός όρος για τη διαδικασία «εκπαίδευσε → πρόβλεψε h → μετακίνησε → επανάλαβε». Η καθαρότερη προσομοίωση της πραγματικής λειτουργίας.

Λεπτομέρειες που έχουν σημασία

Παράμετρος	Καθοδήγηση
Αριθμός origins	Τουλάχιστον 12-24 για μηνιαία δεδομένα. Με λιγότερα, η εκτίμηση σφάλματος είναι πολύ θορυβώδης για σύγκριση μοντέλων
Ορίζοντας h	Ο πραγματικός ορίζοντας απόφασης. Αν παραγγέλνεις 3 μήνες μπροστά, αξιολόγησε στο h=3 — όχι στο h=1
Επανεκτίμηση μετρώων	παρα- Ιδανικά σε κάθε origin (ακριβό αλλά σωστό). Εναλλακτικά, κάθε k βήματα με ρητή δήλωση
Gap / embargo	Αν τα δεδομένα οριστικοποιούνται με καθυστέρηση (όπως η δαπάνη ΕΟΠΥΥ), άφησε κενό μεταξύ train και test που αντιστοιχεί στην πραγματική καθυστέρηση
Ανάλυση ανά ορίζοντα	Ανάφερε το σφάλμα χωριστά για h=1, 2, ..., H. Ένα μοντέλο μπορεί να είναι άριστο στο h=1 και άθλιο στο h=12

```

from sklearn.model_selection import TimeSeriesSplit # expanding
tscv = TimeSeriesSplit(n_splits=12, test_size=1, gap=0)

# Χειροκίνητο rolling-origin με επανεκτίμηση – ο σωστός τρόπος
errors = []
for origin in range(len(y) - n_test, len(y) - h + 1):
    train = y.iloc[:origin]
    test = y.iloc[origin:origin + h]
    model = SARIMAX(np.log(train), order=(0,1,1),
                    seasonal_order=(0,1,1,12)).fit(dispatch=False)
    fc = np.exp(model.forecast(h))
    errors.append(np.abs(test.values - fc.values))

import numpy as np
mae_by_h = np.mean(np.array(errors), axis=0) # σφάλμα ανά ορίζοντα

```

ΚΕΦΑΛΑΙΟ 19 — Μετρικές πρόβλεψης

Έστω $e_t = y_t - \hat{y}_t$ το σφάλμα πρόβλεψης.

19.1 Μετρικές εξαρτώμενες από την κλίμακα

Μετρική	Τύπος	Τι μετρά	Πλεονεκτήματα	Μειονεκτήματα
MAE	$\text{mean}(e_t)$	Μέσο απόλυτο σφάλμα στις μονάδες των δεδομένων	Άμεσα ερμηνεύσιμο· εύρωστο σε ακραίες τιμές· βελτιστοποιείται από τη διάμεσο	Δεν συγκρίνεται μεταξύ σειρών διαφορετικής κλίμακας
MSE	$\text{mean}(e_t^2)$	Μέσο τετραγωνικό σφάλμα	Μαθηματικά βολικό· ποιή στα μεγάλα σφάλματα	Μονάδες στο τετράγωνο — μη ερμηνεύσιμο· πολύ ευαίσθητο σε outliers
RMSE	$\sqrt{\text{mean}(e_t^2)}$	Ίδιες μονάδες με τα δεδομένα	Το πιο κοινό· βελτιστοποιείται από τον μέσο· κατάλληλο αν τα μεγάλα σφάλματα κοστίζουν δυσανάλογα	Ευαίσθητο σε ακραίες τιμές· δεν συγκρίνεται μεταξύ σειρών

MAE ή RMSE; Το ερώτημα δεν είναι στατιστικό αλλά επιχειρησιακό

Αν το κόστος του σφάλματος είναι γραμμικό (κάθε επιπλέον κουτί στο ράφι κοστίζει το ίδιο) → βελτιστοποίησε MAE. Αν είναι κυρτό (μια μεγάλη έλλειψη κοστίζει δυσανάλογα περισσότερο από πολλές μικρές) → RMSE. Και πρόσεξε: ένα μοντέλο εκπαιδευμένο για MSE και αξιολογούμενο με MAE είναι εσωτερικά ασυνεπές.

19.2 Ποσοστιαίες μετρικές

Μετρική	Τύπος	Πλεονεκτήματα	Μειονεκτήματα
MAPE	$100 \cdot \text{mean}(e_t/y_t)$	Διασητικό· ανεξάρτητο κλίμακας· το προτιμά η διοίκηση	Απροσδιόριστο για $y_t=0$ · εκρήγνυται για μικρά y · ασύμμετρο — τιμωρεί περισσότερο την υπερεκτίμηση από την υποεκτίμηση, οδηγώντας σε συστηματικά συντηρητικές προβλέψεις
sMAPE	$200 \cdot \text{mean}(e_t /(y_t + \hat{y}_t))$	Φραγμένο· «συμμετρικό» κατ' όνομα	Δεν είναι πραγματικά συμμετρικό· ασταθές όταν $y+\hat{y} \approx 0$ · δύσκολα ερμηνεύσιμο

Η ασυμμετρία του MAPE — με αριθμούς

Πραγματική τιμή 100. Πρόβλεψη 150 → MAPE = 50%. Πρόβλεψη 50 → MAPE = 50%. Φαίνεται συμμετρικό. Αλλά: το MAPE έχει ανώτατο όριο 100% για υποεκτίμηση ($\hat{y}=0$ δίνει 100%) ενώ η υπερεκτίμηση είναι απεριόριστη. Άρα ένα μοντέλο που βελτιστοποιεί το MAPE μαθαίνει να προβλέπει χαμηλά. Σε διαχείριση αποθέματος αυτό σημαίνει συστηματικές ελλείψεις.

19.3 Κλιμακωμένες μετρικές — οι σωστές για σύγκριση

MASE (Mean Absolute Scaled Error)

$$\text{MASE} = \text{mean}(|e_t|) / \text{MAE του naive στο training set}$$

$$\text{Μη εποχικά: παρονομαστής} = (1/(T-1)) \cdot \sum_{t=2}^T |y_t - y_{t-1}|$$

$$\text{Εποχικά: παρονομαστής} = (1/(T-s)) \cdot \sum_{t=s+1}^T |y_t - y_{t-s}|$$

Τιμή MASE	Ερμηνεία
< 1	Το μοντέλο είναι καλύτερο από το naive/seasonal naive benchmark
= 1	Ισοδύναμο με το naive — δεν προσέφερε τίποτα
> 1	Χειρότερο από το naive. Ό,τι κι αν λένε τα υπόλοιπα, το μοντέλο απέτυχε
π.χ. 0,65	Το σφάλμα είναι 65% του σφάλματος του naive — δηλαδή 35% βελτίωση

Γιατί το MASE είναι η καλύτερη μετρική γενικής χρήσης

(1) **Ανεξάρτητο κλίμακας** — συγκρίνεις σειρές με εντελώς διαφορετικά μεγέθη. (2) **Ορίζεται πάντα**, ακόμη και με μηδενικά — σε αντίθεση με το MAPE· γι' αυτό είναι η μετρική επιλογής για intermittent demand. (3) **Συμμετρικό**. (4) **Έχει ενσωματωμένο νόημα**: η τιμή 1 είναι φυσικό κατώφλι που απαντά αμέσως στο ερώτημα «άξιζε η προσπάθεια;». (5) Ο παρονομαστής υπολογίζεται στο *training set*, άρα είναι σταθερός και δεν επηρεάζεται από το test window.

RMSSE

$$\text{RMSSE} = \sqrt{[\text{mean}(e_t^2) / \text{mean}((y_t - y_{t-s})^2)]}$$

Το τετραγωνικό ανάλογο του MASE. Ήταν η επίσημη μετρική του διαγωνισμού **M5**. Προτίμησέ το όταν τα μεγάλα σφάλματα κοστίζουν δυσανάλογα.

19.4 Πίνακας επιλογής μετρικής

Κατάσταση	Μετρική	Γιατί
Μία σειρά, αναφορά σε μη τεχνικό κοινό	MAE + MAPE	Ερμηνεύσιμα· αλλά ανάφερε και MASE για ειλικρίνεια
Σύγκριση μοντέλων στην ίδια σειρά	MASE ή RMSE	Το MASE δίνει άμεσα το «καλύτερο από naive;»
Σύγκριση πολλών σειρών διαφορετικής κλίμακας	MASE ή RMSSE	Οι μόνες που αθροίζονται με νόημα
Intermittent demand (μηδενικά)	MASE · service level	Το MAPE δεν ορίζεται
Μεγάλα σφάλματα κοστίζουν δυσανάλογα	RMSE / RMSSE	Τετραγωνική ποινή
Πιθανοτικές προβλέψεις	Pinball loss (quantile), CRPS, coverage	Οι σημειακές μετρικές αγνοούν την αβεβαιότητα

ΚΕΦΑΛΑΙΟ 20 — Επιλογή μοντέλου

20.1 Οι τρεις διαφορετικές έννοιες

Έννοια	Τι μετρά	Τι ΔΕΝ σου λέει
Goodness of fit (R^2 , log-likelihood)	Πόσο καλά το μοντέλο περιγράφει τα δεδομένα που είδε	Τίποτα για την πρόβλεψη. Αυξάνεται μονότονα με κάθε επιπλέον παράμετρο
Πληροφοριακά κριτήρια (AIC, AICc, BIC)	Fit με ποινή πολυπλοκότητας — εκτίμηση της out-of-sample απόδοσης	Είναι ασυμπτωτική προσέγγιση, όχι μέτρηση. Δεν αντικαθιστά το backtesting
Out-of-sample ακρίβεια (MASE, RMSE σε backtest)	Πραγματική επίδοση σε δεδομένα που δεν είδε	Εξαρτάται από το test window· θορυβώδης με λίγα origins

Το χαμηλότερο AIC ΔΕΝ εγγυάται το καλύτερο forecast

Τέσσερις λόγοι: (1) Το AIC βελτιστοποιεί την *ένα-βήμα-μπροστά* in-sample πρόβλεψη — αν σε ενδιαφέρει $h=12$, το κριτήριο δεν αντιστοιχεί στον στόχο. (2) Είναι ασυμπτωτικό· με $T=84$ η προσέγγιση είναι χονδροειδής (γι' αυτό AICc). (3) Δεν βλέπει structural breaks ή concept drift. (4) Δεν συγκρίνεται μεταξύ μοντέλων με διαφορετικό d/D ή διαφορετικό δείγμα.

Χρήση: AICc για να φιλτράρεις από 20 υποψήφια σε 3-5. Backtesting για να επιλέξεις ανάμεσά τους.

20.2 Πλαίσιο απόφασης επιλογής μοντέλου

#	Βήμα	Κριτήριο επιτυχίας / πότε γυρνάς πίσω
1	Όρισε τον στόχο	Πρόβλεψη ή αιτιακή αποτίμηση; Ποιος ορίζοντας h ; Ποια μετρική αντιστοιχεί στο κόστος σφάλματος; Χωρίς αυτά, κάθε σύγκριση είναι αυθαίρετη
2	Όρισε τα baselines	Naive, seasonal naive, drift. Αν το τελικό μοντέλο δεν τα νικά, δεν έχεις μοντέλο
3	Διάγνωση σειράς	Τάση, εποχικότητα, στασιμότητα, breaks, ακραίες τιμές, τύπος δεδομένων (counts; intermittent;)
4	Υποψήφια μοντέλα	3-6 μοντέλα, όχι 50. Επιλογή με βάση τη διάγνωση, όχι εξαντλητική αναζήτηση
5	Φιλτράρισμα με AICc	Μόνο μεταξύ μοντέλων με ίδιο d , D και ίδιο δείγμα
6	Διαγνωστικά καταλοίπων	Ljung-Box, ACF, ετεροσκεδαστικότητα, κανονικότητα. Μοντέλο που αποτυγχάνει εδώ αποκλείεται , όσο καλό κι αν είναι το AICc
7	Rolling-origin backtesting	≥ 12 origins· ανάλυση ανά ορίζοντα· MASE έναντι baseline
8	Έλεγχος ευστάθειας	Είναι το καλύτερο μοντέλο σταθερά καλύτερο, ή κερδίζει λόγω 1-2 origins; Diebold-Mariano test για στατιστική σύγκριση σφαλμάτων
9	Απλότητα ως tie-breaker	Σε ισοδύναμη επίδοση, επέλεξε το απλούστερο. Είναι πιο εύρωστο σε αλλαγές και πιο εύκολο να το υπερασπιστείς
10	Διαστήματα πρόβλεψης	Έλεγχε την κάλυψη: το 80% διάστημα πρέπει να περιέχει ~80% των πραγματικών τιμών στο backtest
11	Παρακολούθηση	Ορισμός κατωφλίων σφάλματος για επανεξέταση· έλεγχος για drift

Ensembles — η πιο υποτιμημένη τεχνική

Ο απλός μέσος όρος των προβλέψεων 3-4 διαφορετικών μοντέλων είναι σχεδόν πάντα καλύτερος από το καλύτερο μεμονωμένο μοντέλο, και σαφώς πιο εύρωστος. Ο λόγος: τα σφάλματα διαφορετικών μοντέλων δεν είναι τέλεια συσχετισμένα και εν μέρει αλληλοαναιρούνται. Είναι εμπειρικό εύρημα που επιβεβαιώνεται σε κάθε διαγωνισμό πρόβλεψης εδώ και 40 χρόνια. Αν έχεις χρόνο για ένα μόνο «κόλπο», αυτό είναι.

ΕΛΕΓΧΟΣ ΚΑΤΑΝΟΗΣΗΣ — Τεύχος Δ´

A. Ειδικές σειρές

1. Κωδικός φαρμακείου με $ADI = 2,8$ και $CV^2 = 0,9$. Σε ποια κατηγορία ανήκει, ποια μέθοδο επιλέγεις και με ποια μετρική την αξιολογείς;
2. Γιατί η μέθοδος Croston είναι μεροληπτική και πώς το διορθώνει η SBA;
3. Έχεις ημερήσιες πωλήσεις με εβδομαδιαίο και ετήσιο μοτίβο. Γιατί αποτυγχάνει το SARIMA και ποιες δύο εναλλακτικές έχεις;
4. Πότε δικαιολογείται zero-inflated μοντέλο αντί για απλό Negative Binomial;

B. ML & επικύρωση

1. Δημιουργείς χαρακτηριστικό `rolling_mean_3 = y.rolling(3).mean()`. Τι είναι λάθος και πώς το διορθώνεις;
2. Ένα LightGBM δίνει άριστο backtest σε σειρά με ανοδική τάση, αλλά οι προβλέψεις 12 μηνών «επιπεδώνονται». Εξήγησε γιατί και δώσε δύο λύσεις.
3. Πότε προτιμάς direct αντί για recursive forecasting;
4. Γιατί ένας τυχαίος 80/20 split σε χρονοσειρά μπορεί να δώσει $R^2 = 0,98$ και το μοντέλο να είναι άχρηστο;
5. Έχεις 3 σειρές με 90 μηνιαία σημεία η καθεμία. Ένας συνάδελφος προτείνει LSTM. Τι απαντάς και τι προτείνεις;

Γ. Μετρικές & επιλογή

1. Μοντέλο A: $MAPE = 12\%$, $MASE = 1,15$. Μοντέλο B: $MAPE = 18\%$, $MASE = 0,82$. Ποιο επιλέγεις και γιατί;
2. Γιατί το MAPE οδηγεί συστηματικά σε υποεκτίμηση και τι συνέπεια έχει αυτό στη διαχείριση αποθέματος;
3. Το AICc επιλέγει το μοντέλο X αλλά το Ljung-Box στα κατάλοιπά του δίνει $p = 0,001$. Τι κάνεις;
4. Στο backtest, το 80% διάστημα πρόβλεψης περιέχει μόνο το 55% των πραγματικών τιμών. Τι σημαίνει και ποιες τρεις πιθανές αιτίες εξετάζεις;

Επόμενο βήμα

Το **Τεύχος Ε´** καλύπτει τα Μέρη 21-26: πλήρη διαγνωστικά καταλοίπων με H_0/H_1 κάθε ελέγχου και ερμηνεία κάθε πιθανού αποτελέσματος, αβεβαιότητα και διαστήματα πρόβλεψης, το κεφάλαιο «Τα 20 μεγαλύτερα λάθη στις χρονοσειρές» με τη δομή Λάθος → Γιατί → Διόρθωση, το πλήρες **decision tree** επιλογής μοντέλου, το **Master Checklist** A-O για κάθε πραγματικό dataset, και **πέντε ολοκληρωμένα case studies** (πωλήσεις φαρμάκου, φαρμακευτική δαπάνη, υοσηλείες, αλλαγή reimbursement policy, πληθωρισμός & δαπάνη) με πλήρη ροή από το πρόβλημα ως την ερμηνεία.