

ΕΓΧΕΙΡΙΔΙΟ ΕΚΠΑΙΔΕΥΣΗΣ

TIME SERIES ANALYSIS

FROM ZERO TO HERO

ΤΕΥΧΟΣ Ε΄

Διαγνωστικά · Αβεβαιότητα · Τα 20 λάθη
Decision Tree · Master Checklist · Case Studies

Μέρη 21-26 του πλήρους προγράμματος
Το πρακτικό τεύχος: από τη θεωρία στην εκτέλεση
Περιλαμβάνει απαντήσεις ελέγχου Τεύχους Δ΄
Αύγουστος 2026

ΑΠΑΝΤΗΣΕΙΣ — Έλεγχος κατανόησης Τεύχους Δ΄

1. $ADI=2,8 \cdot CV^2=0,9$.

$ADI \geq 1,32$ και $CV^2 > 0,49 \rightarrow$ κατηγορία **Lumpy** — η δυσκολότερη. Μέθοδος: **SBA** (ή TSB αν υπάρχει κίνδυνος απαξίωσης του κωδικού). Αξιολόγηση με **MASE** — το MAPE δεν ορίζεται λόγω μηδενικών — και κυρίως με *επίτευξη στόχου service level*, που είναι το μέγεθος που πράγματι σε ενδιαφέρει επιχειρησιακά.

2. Μεροληψία Croston.

Η πρόβλεψη είναι ο λόγος δύο εκτιμητών, $\hat{z}/\hat{\rho}$. Ο λόγος αμερόληπτων εκτιμητών *δεν* είναι αμερόληπτος εκτιμητής του λόγου (ανισότητα Jensen), και η μεροληψία είναι προς τα **πάνω** — υπερεκτίμηση ζήτησης, άρα υπερβολικό απόθεμα. Η **SBA** εφαρμόζει πολλαπλασιαστική διόρθωση $(1 - \alpha/2)$ που την εξουδετερώνει σχεδόν πλήρως.

3. Ημερήσια με εβδομαδιαίο + ετήσιο μοτίβο.

Το SARIMA δέχεται *μία* εποχική περίοδο, και για $s=365$ θα απαιτούσε αδύνατο αριθμό παραμέτρων. Εναλλακτικές: (α) **Dynamic harmonic regression** — Fourier όροι για κάθε περίοδο ως regressors σε ARIMA, με τον αριθμό αρμονικών να επιλέγεται με AICc (η πιο ευέλικτη, δέχεται και εξωγενή). (β) **TBATS** ή **MSTL**. Το Prophet είναι αποδεκτό ως γρήγορο baseline.

4. Πότε zero-inflated αντί για NB.

Όταν υπάρχει *θεωρητικός* λόγος να πιστεύεις σε δύο διακριτές διεργασίες: μια που παράγει «δομικά» μηδενικά (π.χ. το φάρμακο δεν ήταν καν διαθέσιμο, το τμήμα ήταν κλειστό) και μια που παράγει μετρήματα. Αν τα μηδενικά είναι απλώς αποτέλεσμα χαμηλού ρυθμού, το NB τα χειρίζεται μια χαρά. Στατιστικό κριτήριο (Vuong test) βοηθά, αλλά δεν αντικαθιστά τη θεωρητική δικαιολόγηση.

5. `y.rolling(3).mean()`.

Περιλαμβάνει την **τρέχουσα** τιμή y_t — δηλαδή το ίδιο το target διαρρέει στο χαρακτηριστικό. Το μοντέλο θα δείξει εξαιρετική επίδοση και θα αποτύχει πλήρως στην παραγωγή. Σωστό: `y.shift(1).rolling(3).mean()`.

6. LightGBM που «επιπεδώνεται».

Τα δέντρα κάνουν τμηματικά σταθερές προβλέψεις — **δεν προεκτείνουν** εκτός του εύρους τιμών που είδαν. Σε ανοδική σειρά, «κολλάνε» στο ανώτατο ιστορικό επίπεδο. Λύσεις: (α) εκπαίδευση σε *διαφορές* ή λόγους αντί για επίπεδα. (β) **υβριδικό**: γραμμικό μοντέλο ή ETS για την τάση, ML για τα κατάλοιπα, και άθροιση.

7. Direct αντί για recursive.

Όταν ο ορίζοντας είναι μεγάλος (η συσσώρευση σφάλματος στο recursive γίνεται κυρίαρχη), όταν η ακρίβεια σε συγκεκριμένο ορίζοντα είναι επιχειρησιακά κρίσιμη (π.χ. μόνο το $h=3$ μετράει για την παραγγελία), και όταν έχεις αρκετά δεδομένα για να εκπαιδεύσεις *h* ξεχωριστά μοντέλα.

8. Τυχαίος 80/20 με $R^2=0,98$.

Το test set περιέχει σημεία που «περιβάλλονται» χρονικά από σημεία του train. Το μοντέλο κάνει *παρεμβολή* ανάμεσα σε γνωστές τιμές — τετριμμένα εύκολο σε αυτοσυσχετισμένη σειρά. Η πραγματική δουλειά είναι *προεκβολή* σε άγνωστο μέλλον, που είναι εντελώς διαφορετικό και πολύ δυσκολότερο πρόβλημα. Το $R^2=0,98$ δεν λέει τίποτα γι' αυτό.

9. Τρεις σειρές × 90 σημεία, πρόταση για LSTM.

270 συνολικές παρατηρήσεις έναντι δεκάδων χιλιάδων παραμέτρων: εγγυημένη υπερπροσαρμογή. Πρόταση: ETS/SARIMA ανά σειρά ως βάση· αν οι τρεις σειρές σχετίζονται, VAR ή ARDL· αν υπάρχουν εξωγενή χαρακτηριστικά, SARIMAX. Και οπωσδήποτε seasonal naive ως benchmark. Αν κάποιος επιμένει για DL, ζήτησέ του να νικήσει πρώτα το seasonal naive σε rolling-origin backtest.

10. A: MAPE 12%, MASE 1,15 · B: MAPE 18%, MASE 0,82.

Επιλέγεις το Β. Το MASE = 1,15 του Α σημαίνει ότι είναι *χειρότερο από το naive benchmark* — δηλαδή δεν έχει καμία αξία, όσο εντυπωσιακό κι αν φαίνεται το 12%. Το Β με MASE = 0,82 δίνει 18% βελτίωση έναντι του naive. Το χαμηλότερο MAPE του Α είναι πιθανότατα τεχνούργημα της κλίμακας ή της ασυμμετρίας του MAPE.

11. Ασυμμετρία MAPE.

Η υποεκτίμηση έχει ανώτατο σφάλμα 100% ($\hat{y}=0$), ενώ η υπερεκτίμηση είναι απεριόριστη. Άρα η βελτιστοποίηση του MAPE ανταμείβει τις χαμηλές προβλέψεις. Στη διαχείριση αποθέματος: συστηματικά ανεπαρκείς παραγγελίες → **ελλείψεις, χαμένες πωλήσεις, δυσαρεστημένοι πελάτες**. Το κόστος της έλλειψης συνήθως υπερβαίνει κατά πολύ το κόστος διακράτησης — άρα βελτιστοποιείς ακριβώς το λάθος πράγμα.

12. AICc επιλέγει το X, Ljung-Box $p=0,001$.

Το απορρίπτεις. Τα διαγνωστικά καταλοίπων είναι *προϋπόθεση εγκυρότητας*, όχι ένα ακόμη κριτήριο σύγκρισης. Μοντέλο με αυτοσυσχετισμένα κατάλοιπα έχει λάθος standard errors και υποβέλτιστες προβλέψεις. Δες πού είναι τα spikes: lag 12 → πρόσθεσε εποχικούς όρους· lag 1-2 → αύξησε p ή q · σε πολλά lags → πιθανόν λάθος βαθμός differencing ή δομική θραύση.

13. 80% διάστημα καλύπτει μόνο 55%.

Το μοντέλο είναι **υπερβολικά σίγουρο**: τα διαστήματα είναι πολύ στενά. Τρεις αιτίες: (α) *αυτοσυσχέτιση ή ετεροσκεδαστικότητα στα κατάλοιπα* που δεν μοντελοποιήθηκε, οπότε το $\hat{\sigma}$ υποεκτιμάται· (β) τα διαστήματα αγνοούν την *αβεβαιότητα των παραμέτρων* και του ίδιου του μοντέλου — λαμβάνουν υπόψη μόνο τη διακύμανση των σφαλμάτων· (γ) *δομική αλλαγή* στην περίοδο ελέγχου, ή ουρές παχύτερες από την κανονική. Λύσεις: bootstrap ή προσομοίωση για τα διαστήματα, ή empirical prediction intervals από τα σφάλματα του backtest.

ΚΕΦΑΛΑΙΟ 21 — Διαγνωστικά καταλοίπων

Ο στόχος είναι ένας: τα κατάλοιπα να είναι λευκός θόρυβος. Αν έμεινε δομή στα κατάλοιπα, το μοντέλο δεν εξάντλησε την πληροφορία και όλα τα συμπεράσματα — συντελεστές, p-values, διαστήματα — είναι αναξιόπιστα.

Οι τέσσερις ιδιότητες που ελέγχουμε

(1) $E[e_t] = 0$ · (2) $\text{Var}(e_t) = \sigma^2$ σταθερή · (3) $\text{Cov}(e_t, e_{t-k}) = 0 \ \forall k \neq 0$ · (4) [προαιρετικά] κανονικότητα

Οι (1)–(3) απαιτούνται για αμερόληπτες προβλέψεις και σωστά standard errors. Η (4) απαιτείται μόνο για παραμετρικά διαστήματα πρόβλεψης· χωρίς αυτήν, χρησιμοποίησε bootstrap.

21.1 Ο πλήρης κατάλογος ελέγχων

#	Έλεγχος	H_0 / H_1	Τι σημαίνει η αποτυχία και τι κάνεις
1	Residual plot (οπτικά)	—	Ψάξε: μοτίβα, χοάνη (ετεροσκεδαστικότητα), ομαδοποιημένα σφάλματα, ακραίες τιμές, μετατόπιση επιπέδου. <i>Πάντα ξεκίνα από εδώ</i> — το μάτι πιάνει πράγματα που κανένα τεστ δεν πιάνει
2	Μέσος καταλοίπων	$H_0: \mu_e = 0$ (t-test)	Μη μηδενικός μέσος → συστηματική μεροληψία. Αιτίες: παραλειφθείσα σταθερά/τάση, ή <i>back-transformation bias</i> αν δούλεψες σε logs. Διόρθωση: πρόσθεσε τον όρο ή εφάρμοσε τη διόρθωση $\exp(\sigma^2/2)$
3	ACF καταλοίπων	— (οπτικός έλεγχος με ζώνες $\pm 1,96/\sqrt{T}$)	Spike στο lag 1-2 → αύξησε p ή q . Spike στο lag s (12) → ανεπαρκής εποχική δομή, αύξησε P ή Q . Αργή φθίση → λάθος βαθμός differencing
4	Ljung-Box	H_0 : οι πρώτες h αυτοσυσχετίσεις είναι από κοινού μηδέν H_1 : τουλάχιστον μία $\neq 0$	$p > 0,05$ = επιτυχία. $p < 0,05$ → εναπομείνασα δομή· αναθεώρησε την προδιαγραφή. Χρησιμοποίησε $h=10$ (μη εποχικά) ή $h=2s$ (εποχικά) και αφάιρσε $m=p+q$ βαθμούς ελευθερίας
5	Ετεροσκεδαστικότητα Breusch-Pagan / White	H_0 : ομοσκεδαστικότητα H_1 : η διακύμανση εξαρτάται από τους regressors	$p < 0,05$ → οι εκτιμήσεις παραμένουν αμερόληπτες αλλά τα SE είναι λάθος. Λύση: log-μετασχηματισμός ή HAC/robust standard errors
6	ARCH-LM	H_0 : δεν υπάρχουν ARCH effects H_1 : υπό συνθήκη ετεροσκεδαστικότητα	$p < 0,05$ → volatility clustering. Σε υψηλή συχνότητα: GARCH. Σε μηνιαία δεδομένα: πιθανότατα ακραίες τιμές ή αγνοημένη θραύση — <i>μην πηδήξεις στο GARCH</i>
7	Q-Q plot	—	Απόκλιση στις άκρες → παχιές ουρές. Συνέπεια: τα 95% διαστήματα είναι πολύ στενά. Λύση: bootstrap ή empirical intervals
8	Jarque-Bera (ή Shapiro-Wilk για μικρά δείγματα)	H_0 : τα κατάλοιπα είναι κανονικά H_1 : μη κανονικά	$p < 0,05$ → μη κανονικότητα. Δεν ακυρώνει το μοντέλο — οι σημειακές προβλέψεις παραμένουν έγκυρες. Επηρεάζει μόνο τα παραμετρικά διαστήματα
9	Δομική σταθερότητα CUSUM / CUSUMSQ / Chow	H_0 : οι παράμετροι είναι σταθερές H_1 : υπάρχει θραύση	Αποτυχία → το μοντέλο δεν ισχύει σε όλο το δείγμα. Μοντελοποίησε τη θραύση ή περιόρισε το δείγμα στο νέο καθεστώς
10	Εναπομείνασα εποχικότητα	— (ACF στο lag s , $2s$ · seasonal plot καταλοίπων)	Ορατό εποχικό μοτίβο → πρόσθεσε εποχικούς όρους, αρμονικούς, ή εποχικό differencing

21.2 Πίνακας διάγνωσης: από το σύμπτωμα στη λύση

Σύμπτωμα στα κατάλοιπα	Πιθανή αιτία	Διόρθωση
Spike ACF στο lag 1	Ανεπαρκής AR/MA τάξη	$p \rightarrow p+1$ ή $q \rightarrow q+1$
Spike ACF στο lag 12 (μηνιαία)	Ανεπαρκής εποχική δομή	$P \rightarrow 1$ ή $Q \rightarrow 1$ ή αρμονικοί όροι
Αργή φθίση ACF	Under-differencing	$d \rightarrow d+1$ (και επανέλεγχος)
Μεγάλο αρνητικό spike lag 1	Over-differencing	$d \rightarrow d-1$ · τάση ως regressor
Σχήμα χοάνης	Ετεροσκεδαστικότητα επιπέδου	αναλογική Log ή Box-Cox· robust SE
Συστάδες μεγάλων σφαλμάτων	ARCH effects ή αγνοημένο γεγονός	Ψάξε πρώτα το γεγονός· GARCH μόνο σε υψηλή συχνότητα
Μεμονωμένες τεράστιες τιμές	Ακραίες τιμές / γεγονότα	Ταυτοποίησε την αιτία· dummy· ποτέ σιωπηρή διαγραφή
Μετατόπιση επιπέδου καταλοίπων	Δομική θραύση	Step dummy· Bai-Perron για εντοπισμό
Τάση στα κατάλοιπα	Παραλειφθείσα τάση ή μεταβλητή	Πρόσθεσε τάση· επανεξέτασε τη δομή

```
import matplotlib.pyplot as plt
from statsmodels.stats.diagnostic import acorr_ljungbox, het_arch, het_breuschpagan
from scipy import stats

res = model.resid

# 4. Ljung-Box (h=2s για εποχικά, model_df = p+q+P+Q)
print(acorr_ljungbox(res, lags=[12, 24], model_df=2))

# 6. ARCH-LM
lm, lmp, f, fp = het_arch(res, nlags=12)
print(f"ARCH-LM: stat={lm:.2f}  p={lmp:.4f}")

# 8. Jarque-Bera
jb, jbp = stats.jarque_bera(res)[:2]
print(f"Jarque-Bera: stat={jb:.2f}  p={jbp:.4f}")

# 1,3,7,10 μαζί: το τετραπλό πάνελ
model.plot_diagnostics(figsize=(11, 8))
plt.show()
```

ΚΕΦΑΛΑΙΟ 22 — Αβεβαιότητα πρόβλεψης

22.1 Σημειακή πρόβλεψη vs διάστημα

Έννοια	Ορισμός
Point forecast	Μία τιμή — συνήθως ο υπό συνθήκη μέσος $E[y_{T+h} \text{πληροφορία μέχρι } T]$. Είναι η «καλύτερη μονή εικασία» και είναι σχεδόν σίγουρα λάθος
Prediction interval	Εύρος που περιέχει τη μελλοντική παρατήρηση με δεδομένη πιθανότητα
Confidence interval	ΜΗΝ ΤΑ ΜΠΕΡΔΕΥΕΙΣ: αφορά μια παράμετρο, όχι μελλοντική παρατήρηση. Είναι πάντα στενότερο από το prediction interval

$$\hat{y}_{T+h} \pm z_{\alpha/2} \cdot \hat{\sigma}_h$$

$z = 1,28$ για 80% · $z = 1,645$ για 90% · $z = 1,96$ για 95%

22.2 Γιατί η αβεβαιότητα μεγαλώνει με τον ορίζοντα

Για ένα ARIMA, η διακύμανση του σφάλματος h βημάτων μπροστά είναι:

$$\sigma_h^2 = \sigma^2 \cdot (1 + \psi_1^2 + \psi_2^2 + \dots + \psi_{h-1}^2)$$

όπου ψ_i οι συντελεστές της αναπαράστασης $MA(\infty)$. Καθώς αυξάνεται το h , προστίθενται όροι — η διακύμανση δεν μπορεί να μειωθεί.

Τύπος σειράς	Συμπεριφορά σ_h	Πρακτική συνέπεια
Στάσιμη (I(0))	Συγκλίνει στη μη υπό συνθήκη τυπική απόκλιση	Το διάστημα σταθεροποιείται· μακρο-πρόθεσμη πρόβλεψη = ο μέσος
Random walk (I(1))	$\sigma_h = \sigma \sqrt{h}$ — αυξάνεται χωρίς όριο	Στους 24 μήνες το διάστημα είναι ≈ 5 φορές πλατύτερο από τον 1ο μήνα
I(2)	Αυξάνεται ακόμη ταχύτερα ($\sim h^{1.5}$)	Οι μακροπρόθεσμες προβλέψεις είναι πρακτικά άχρηστες

22.3 Γιατί τα διαστήματα είναι σχεδόν πάντα πολύ στενά

Τι ΔΕΝ περιλαμβάνει ένα τυπικό διάστημα πρόβλεψης

Ο τύπος $\hat{y} \pm z \cdot \hat{\sigma}$ λαμβάνει υπόψη **μόνο** τη διακύμανση των τυχαίων σφαλμάτων. Αγνοεί:

- Αβεβαιότητα παραμέτρων** — τα $\hat{\phi}$, $\hat{\theta}$ είναι εκτιμήσεις, όχι αλήθειες.
- Αβεβαιότητα μοντέλου** — επέλεξες ARIMA(1,1,1)· μπορεί να ήταν λάθος δομή.
- Δομικές αλλαγές** — υποθέτεις ότι το μέλλον μοιάζει με το παρελθόν.
- Αβεβαιότητα των X** — αν προέβλεψες τους regressors, η δική τους αβεβαιότητα δεν μεταφέρεται.

Γι' αυτό η εμπειρική κάλυψη ενός «95%» διαστήματος είναι τυπικά 70–85%. **Ανάφερέ το ρητά.**

Μέθοδος	Τι διορθώνει
Bootstrap	Επαναδειγματοληψία καταλοίπων και προσομοίωση τροχιών· δεν απαιτεί κανονικότητα· πιάνει ασυμμετρία και παχιές ουρές
Simulation-based	Ενσωματώνει και την αβεβαιότητα παραμέτρων (δειγματοληψία από την κατανομή τους)
Empirical intervals	Χρησιμοποίησε τα <i>πραγματικά</i> σφάλματα του rolling-origin backtest ανά ορίζοντα h. Η πιο ειλικρινής μέθοδος — αντανακλά ό,τι πραγματικά συνέβη
Ensembles	Η διασπορά μεταξύ μοντέλων προσεγγίζει την αβεβαιότητα μοντέλου

22.4 Βαθμονόμηση (calibration)

Ένα διάστημα είναι *βαθμονομημένο* αν η ονομαστική του πιθανότητα ταιριάζει με την πραγματική κάλυψη.

$$\text{Empirical coverage} = (\# \text{ φορών που } y_t \in [L_t, U_t]) / (\# \text{ προβλέψεων})$$

Παρατηρούμενη κάλυψη (80% ονομαστικό)	Διάγνωση	Ενέργεια
~80%	Καλά βαθμονομημένο	Τίποτα
< 70%	Υπερβολική αυτοπεποίθηση	Έλεγξε κατάλοιπα· χρησιμοποίησε empirical ή bootstrap intervals· ψάξε δομική αλλαγή
> 90%	Υπερβολικά συντηρητικό	Λιγότερο συχνό αλλά υπαρκτό: υπερπαραμετροποίηση ή υπερεκτίμηση σ. Χρήσιμη πληροφορία — μπορείς να είσαι πιο συγκεκριμένος

Πώς παρουσιάζεται μια πρόβλεψη σε απόφαση πολιτικής

Ποτέ μόνο ένας αριθμός. Το ελάχιστο αποδεκτό: **κεντρική εκτίμηση + διάστημα 80%** + ρητή δήλωση των υποθέσεων ("υπό την προϋπόθεση ότι δεν αλλάζει το θεσμικό πλαίσιο"). Για policy briefs, τρία σενάρια (χαμηλό/κεντρικό/υψηλό) που αντιστοιχούν στα ποσοστημόρια 10/50/90 επικοινωνούν την αβεβαιότητα καλύτερα από ένα διάστημα — γιατί κάθε σενάριο μπορεί να συνδεθεί με αφήγηση και με διαφορετική απόφαση.

ΚΕΦΑΛΑΙΟ 23 — Τα 20 μεγαλύτερα λάθη στις χρονοσειρές

Δομή για καθένα: **Λάθος** → **Γιατί είναι λάθος** → **Πώς το διορθώνουμε**.

1. Τυχαίος train-test split

Γιατί: Το training set περιέχει σημεία μετά από σημεία του test — το μοντέλο βλέπει το μέλλον. Μετράς παρεμβολή, όχι προεκβολή. Επιπλέον, γειτονικές παρατηρήσεις είναι σχεδόν αντίγραφα.

Διόρθωση: Χρονολογικός διαχωρισμός και rolling-origin backtesting με ≥ 12 origins.

2. Data leakage στα χαρακτηριστικά

Γιατί: Κυλιόμενοι μέσοι χωρίς shift, κλιμάκωση σε όλο το dataset, backfill κενών, target encoding εκτός fold — όλα εισάγουν μελλοντική πληροφορία. Το αποτέλεσμα είναι εντυπωσιακό backtest και πλήρης αποτυχία στην παραγωγή.

Διόρθωση: Για κάθε χαρακτηριστικό, ο έλεγχος διαθεσιμότητας: «θα το είχα στα χέρια μου στην ημερομηνία T;» Πάντα `.shift(1)` πριν από rolling.

3. Αγνόηση εποχικότητας

Γιατί: Το μοντέλο κάνει συστηματικά τα ίδια λάθη τους ίδιους μήνες κάθε χρόνο. Τα κατάλοιπα δεν είναι λευκός θόρυβος και τα διαστήματα είναι λάθος.

Διόρθωση: Seasonal plot και ACF στο lag s. Εποχικοί όροι (P,D,Q), αρμονικοί, ή εποχική εξομάλυνση. Ελέγχεις με F_S .

4. Αγνόηση δομικών θραύσεων

Γιατί: Οι συντελεστές γίνονται σταθμισμένος μέσος δύο καθεστώτων — δεν περιγράφουν κανένα. Το ADF χάνει ισχύ και ζητά περιττό differencing. Οι προβλέψεις προεκτείνουν σχέση που έπαψε να ισχύει.

Διόρθωση: Οπτικός έλεγχος, CUSUM, Bai-Perron, Zivot-Andrews. Ρητή μοντελοποίηση με dummies όταν ξέρεις την αιτία.

5. Ψευδής παλινδρόμηση (spurious regression)

Γιατί: Δύο ανεξάρτητοι random walks δίνουν $R^2 = 0,7$ και $p < 0,001$ στο 70–75% των περιπτώσεων. Η κοινή τάση αρκεί.

Διόρθωση: Τεστ μοναδιαίας ρίζας πριν από κάθε παλινδρόμηση σε επίπεδα. Σήμα κινδύνου: $R^2 >$ Durbin-Watson. Λύση: διαφορές, ή συνολοκλήρωση + VECM/ARDL.

6. Over-differencing

Γιατί: Εισάγει μη αντιστρέψιμη MA(1) με $\theta = -1$, αυξάνει τη διακύμανση των προβλέψεων και δημιουργεί προβλήματα σύγκλισης.

Διόρθωση: Ο κανόνας διακύμανσης — παίρνεις διαφορές όσο η Var μειώνεται. Αρνητικό spike $-0,5$ στο ACF lag 1 είναι το σήμα. Για ντετερμινιστική τάση χρησιμοποίησε detrending, όχι differencing.

7. Under-differencing

Γιατί: Η μη στασιμότητα παραμένει· οι εκτιμητές δεν είναι συνεπείς και τα p-values άκυρα.

Διόρθωση: ADF και KPSS με συμφωνία· ACF που φθίνει γρήγορα.

8. Επιλογή μοντέλου μόνο από R^2

Γιατί: Το R^2 αυξάνεται μονότονα με κάθε παράμετρο και σε μη στάσιμες σειρές είναι σχεδόν πάντα υψηλό — μετρά κοινή τάση, όχι εξηγητική ισχύ. Δεν λέει τίποτα για την πρόβλεψη.

Διόρθωση: Out-of-sample MASE έναντι baseline. Το R^2 δεν έχει καν νόημα σε διαφορισμένα δεδομένα.

9. Επιλογή μοντέλου μόνο από AIC

Γιατί: Το AIC βελτιστοποιεί την in-sample πρόβλεψη ενός βήματος· αν σε ενδιαφέρει $h=12$, δεν αντιστοιχεί στον στόχο. Είναι ασυμπτωτικό, δεν βλέπει breaks, και δεν συγκρίνεται μεταξύ διαφορετικών d/D .

Διόρθωση: AICc για φιλτράρισμα σε 3-5 υποψήφια· backtesting για την τελική επιλογή.

10. Καθόλου baseline

Γιατί: Χωρίς σημείο αναφοράς, το «RMSE = 1.240» δεν σημαίνει τίποτα. Πολλά πολύπλοκα μοντέλα χάνουν από το seasonal naive — και κανείς δεν το ανακαλύπτει.

Διόρθωση: Naive, seasonal naive και drift σε κάθε ανάλυση. Ανάφερε MASE.

11. Καθόλου διαγνωστικά καταλοίπων

Γιατί: Δομημένα κατάλοιπα σημαίνουν αναξιοποίητη πληροφορία, υποεκτιμημένα SE και υπερβολικά στενά διαστήματα.

Διόρθωση: Ljung-Box, ACF, ετεροσκεδαστικότητα, Q-Q — υποχρεωτικά, πριν από κάθε παρουσίαση αποτελεσμάτων.

12. Καθόλου out-of-sample επικύρωση

Γιατί: Η in-sample προσαρμογή μπορεί να γίνει αυθαίρετα καλή με αρκετές παραμέτρους. Δεν έχει σχέση με προβλεπτική ικανότητα.

Διόρθωση: Rolling-origin, ανάλυση ανά ορίζοντα, Diebold-Mariano για στατιστική σύγκριση.

13. Σύγκριση Granger causality με αιτιότητα

Γιατί: Το Granger ελέγχει προβλεψιμότητα, όχι μηχανισμό. Καταρρέει με παραλειπόμενη κοινή αιτία, προσδοκίες, και χρονική συνάθροιση.

Διόρθωση: Διατύπωσέ το ως εύρημα προβλεψιμότητας. Για αιτιατούς ισχυρισμούς χρειάζεσαι ITS, DiD, synthetic control ή RDD.

14. Πρόβλεψη με regressors άγνωστους στο μέλλον

Γιατί: Για να προβλέψεις το y_{T+h} χρειάζεσαι το X_{T+h} . Αν πρέπει να το προβλέψεις κι αυτό, εισάγεις αβεβαιότητα που συνήθως υπερβαίνει το όφελος — και τα διαστήματα δεν την ενσωματώνουν.

Διόρθωση: Χρησιμοποίησε μόνο γνωστά μελλοντικά X (ημερολογιακά, αποφασισμένες πολιτικές) ή επαρκώς υστερημένα. Αλλιώς: univariate + σεναριακή ανάλυση.

15. Χρήση MAPE σε σειρές με μηδενικά ή μικρές τιμές

Γιατί: Απροσδιόριστο στο μηδέν, εκρήγνυται για μικρά y , και είναι ασύμμετρο — οδηγεί σε συστηματική υποεκτίμηση και ελλείψεις αποθέματος.

Διόρθωση: MASE ή RMSSE. Για intermittent demand, service level.

16. Σιωπηρή διαγραφή ακραίων τιμών

Γιατί: Οι ακραίες τιμές συχνά είναι το πιο ενδιαφέρον μέρος των δεδομένων — πραγματικά γεγονότα με ερμηνεία. Η διαγραφή τους ωραιοποιεί τα διαγνωστικά και υποεκτιμά την πραγματική αβεβαιότητα.

Διόρθωση: Ταξινόμηση: σφάλμα καταχώρισης (διόρθωση), πραγματικό γεγονός (dummy), άγνωστο (ανάλυση ευαισθησίας με και χωρίς). Πάντα τεκμηρίωσε.

17. Αγνόηση της αναθεώρησης δεδομένων

Γιατί: Πολλές επίσημες σειρές (δαπάνη, ΑΕΠ, εποχικά προσαρμοσμένα μεγέθη) αναθεωρούνται. Το backtesting με τελικά δεδομένα υπερεκτιμά την πραγματική επίδοση, γιατί σε πραγματικό χρόνο είχες τις πρώτες εκτιμήσεις.

Διόρθωση: Real-time / vintage data όπου διατίθενται· gap-embargo στο backtesting που αντιστοιχεί στην πραγματική καθυστέρηση.

18. Υπερβολικά στενά διαστήματα πρόβλεψης

Γιατί: Ο τυπικός τύπος αγνοεί την αβεβαιότητα παραμέτρων, μοντέλου, δομικών αλλαγών και των X. Η εμπειρική κάλυψη ενός «95%» διαστήματος είναι τυπικά 70-85%.

Διόρθωση: Έλεγχος κάλυψης στο backtest· empirical ή bootstrap intervals· ρητή δήλωση των υποθέσεων.

19. Σύγχυση στατιστικής με πρακτική σημαντικότητα

Γιατί: Με 200 παρατηρήσεις, μια μείωση 0,3% γίνεται «στατιστικά σημαντική». Δεν σημαίνει ότι έχει σημασία για καμία απόφαση.

Διόρθωση: Ανάφερε *μεγέθη επίδρασης* σε ερμηνεύσιμες μονάδες (€, κουτιά, νοσηλείες) με διαστήματα εμπιστοσύνης. Στα ITS: σωρευτική διαφορά έναντι του αντιπαραδείγματος στους 12/24 μήνες.

20. Μοντέλο που δεν παρακολουθείται μετά την ανάπτυξη

Γιατί: Οι σχέσεις αλλάζουν. Ένα μοντέλο εκτιμημένο το 2019 δεν ίσχυε το 2021. Χωρίς παρακολούθηση, η υποβάθμιση περνά απαρατήρητη μέχρι να προκαλέσει ζημιά.

Διόρθωση: Ορισμός κατωφλίων σφάλματος, περιοδική επανεκτίμηση, έλεγχος για drift, και ημερομηνία λήξης ισχύος για κάθε μοντέλο.

ΚΕΦΑΛΑΙΟ 24 — Decision Tree: «Έχω μια χρονοσειρά. Τι μοντέλο;»

ΕΡΩΤΗΜΑ 0 — Ποιος είναι ο σκοπός;

- └ ΑΙΤΙΑΚΗ ΑΠΟΤΙΜΗΣΗ ("τι προκάλεσε η παρέμβαση;")
 - └ Σαφής ημερομηνία, μία μονάδα, ≥ 12 σημεία πριν & μετά
 - └ Υπάρχει σειρά ελέγχου; —→ NAI → CONTROLLED ITS
 - OXI → ITS (+ placebo test, ευαισθησία)
 - └ Αυτοσυσχέτιση καταλοίπων → ARIMA-with-intervention ή HAC SE
 - └ Πολλές μονάδες, ομάδα ελέγχου —→ DIFFERENCE-IN-DIFFERENCES
 - └ Μία μονάδα, πολλές δυνητικές ελέγχου —→ SYNTHETIC CONTROL
 - └ Κατώφλι σε συνεχή μεταβλητή —→ REGRESSION DISCONTINUITY

└ ΠΡΟΒΛΕΨΗ

- └ ΒΗΜΑ 1: Τύπος δεδομένων
 - └ Πολλά μηδενικά ($ADI \geq 1,32$) —→ CROSTON / SBA / TSB
 - └ Μικροί ακέραιοι (counts) —→ POISSON / NEG. BINOMIAL / INGARCH
 - └ Συνεχή → συνέχισε
- └ ΒΗΜΑ 2: Πλήθος σειρών
 - └ Εκατοντάδες/χιλιάδες ομοειδείς —→ GLOBAL ML (LightGBM) + baselines
 - └ Λίγες → συνέχισε
- └ ΒΗΜΑ 3: Univariate ή multivariate;
 - └ MULTIVARIATE (υπάρχουν χρήσιμα X)
 - └ Τα X είναι ΓΝΩΣΤΑ στο μέλλον;
 - └ OXI → επέστρεψε σε univariate + σενάρια
 - └ NAI ↓
 - └ Ένα σαφές Y, X εξωγενή —→ SARIMAX / DYNAMIC REGRESSION
 - └ Αμοιβαία ενδογένεια:
 - └ Όλες $I(0)$ —→ VAR σε επίπεδα
 - └ Όλες $I(1)$, ΧΩΡΙΣ συνολοκλήρωση → VAR σε διαφορές
 - └ Όλες $I(1)$, ΜΕ συνολοκλήρωση —→ VECM (Johansen: 0 0,3 → εποχικό μοντέλο ↓
 - └ Καμία → μη εποχικό μοντέλο ↓
- └ ΒΗΜΑ 5: Διακύμανση
 - └ Αυξάνεται με το επίπεδο —→ LOG ή BOX-COX (πριν από όλα)
 - └ Volatility clustering + υψηλή συχνότητα → GARCH / EGARCH / GJR
 - (σε μηνιαία δεδομένα: OXI – log + robust SE)
- └ ΒΗΜΑ 6: Τάση & στασιμότητα (ADF × KPSS)
 - └ $I(0)$ —→ ETS(A,N,·) ή ARMA
 - └ Trend-stationary —→ detrend ή τάση ως regressor
 - └ $I(1)$ —→ d=1
- └ ΒΗΜΑ 7: Τελική επιλογή – ΠΑΝΤΑ με baselines
 - └ Πάντα: NAIVE, SEASONAL NAIVE, DRIFT
 - └ Καθαρή τάση/εποχικότητα, λίγα δεδομένα → ETS (συχνά ETS(M,Ad,M))
 - └ Σύνθετη αυτοσυσχέτιση, ανάγκη διαγνωστ. → ARIMA / SARIMA
 - └ Ανάγκη για εξωγενή ή intervention —→ SARIMAX
 - └ ΣΥΝΔΥΑΣΜΟΣ 3–4 μοντέλων —→ ENSEMBLE (απλός μέσος)

ΚΡΙΤΗΡΙΟ ΤΕΡΜΑΤΙΣΜΟΥ:

Ljung-Box $p > 0,05$ ΚΑΙ MASE < 1 σε rolling-origin backtest

Αν όχι → επέστρεψε στο ΒΗΜΑ 4

ΚΕΦΑΛΑΙΟ 25 — Master Checklist

Χρησιμοποιήσέ το σε κάθε πραγματικό dataset. Κάθε γραμμή είναι ένα ερώτημα που πρέπει να μπορείς να απαντήσεις.

A. Ορισμός προβλήματος

- ☐ Πρόβλεψη ή αιτιακή αποτίμηση; (καθορίζει τα πάντα)
- ☐ Ποια ακριβώς είναι η μεταβλητή Y και σε ποιες μονάδες;
- ☐ Ποιος είναι ο ορίζοντας h και ποια απόφαση εξυπηρετεί;
- ☐ Ποιο είναι το κόστος υπερεκτίμησης vs υποεκτίμησης; (καθορίζει τη μετρική)
- ☐ Ποιος είναι ο αποδέκτης και τι μορφή αποτελέσματος χρειάζεται;

B. Έλεγχος δεδομένων (Data Audit)

- ☐ Ημερομηνίες σε σωστό τύπο· min/max λογικά· format επιβεβαιωμένο
- ☐ Συχνότητα δηλωμένη ρητά· έλεγχος για ακανόνιστα διαστήματα
- ☐ Reindex σε πλήρες ημερολόγιο — εντοπισμός *απόντων γραμμών*, όχι μόνο NaN
- ☐ Διπλότυπα ερευνημένα (γιατί υπάρχουν;)
- ☐ Διάκριση πραγματικού μηδενός από ελλείπουσα τιμή
- ☐ Κανονικοποίηση: ανά ημέρα / εργάσιμη / πληθυσμό· αποπληθωρισμός αν χρειάζεται
- ☐ Επιβεβαίωση ότι **δεν άλλαξε ο τρόπος μέτρησης** στη διάρκεια της περιόδου
- ☐ Ημερολόγιο εξωτερικών γεγονότων (COVID, πολιτικές, αργίες, Πάσχα)

C. Οπτικοποίηση

- ☐ Raw time plot · Seasonal plot · Subseries plot
- ☐ Rolling mean & rolling SD (σχέση μεταξύ τους $\rightarrow$ log;)
- ☐ Histogram · Boxplots ανά μήνα
- ☐ ACF & PACF
- ☐ Καταγραφή: τάση; εποχικότητα; breaks; outliers; μεταβολή διακύμανσης;

D. Αποσύνθεση

- ☐ Προσθετική ή πολλαπλασιαστική; (κριτήριο: σταθερό vs αναλογικό εποχικό πλάτος)
- ☐ STL με τεκμηριωμένες παραμέτρους (`seasonal` , `trend` , `robust`)
- ☐ Υπολογισμός F_T και F_S — πόσο ισχυρή είναι κάθε συνιστώσα;
- ☐ Έλεγχος υπολοίπου: μοιάζει με λευκό θόρυβο;

Ε. Στασιμότητα

- ☐ Επιλογή εκδοχής ADF (C ή ct) με βάση το γράφημα
- ☐ ADF **και** KPSS με ίδια προδιαγραφή· ανάγνωση του πίνακα συνδυασμού
- ☐ Αν αντίφαση → Zivot-Andrews / Bai-Perron για breaks
- ☐ Καθορισμός d και D (κανόνας: $d+D \leq 2$)

Φ. Μετασχηματισμοί

- ☐ Πρώτα διακύμανση (log/Box-Cox), μετά μέσος (differencing)
- ☐ Έλεγχος over-differencing: $\text{Var}(Y) > \text{Var}(\Delta Y) > \text{Var}(\Delta^2 Y)$;
- ☐ Εποχική διαφορά πριν από την πρώτη διαφορά
- ☐ Σχέδιο για back-transformation με διόρθωση μεροληψίας

Γ. Baselines

- ☐ Naive · Seasonal Naive · Drift · Mean — υπολογισμένα και καταγεγραμμένα
- ☐ Επιλογή του σωστού benchmark για το MASE (seasonal naive αν εποχικό)

Η. Υποψήφια μοντέλα

- ☐ 3-6 μοντέλα, επιλεγμένα από τη διάγνωση — όχι εξαντλητική αναζήτηση
- ☐ ACF/PACF ως αφετηρία ταυτοποίησης, όχι ως τελική απόφαση
- ☐ Έλεγχος: τα X είναι γνωστά στον χρόνο πρόβλεψης;

Ι. Επιλογή μοντέλου

- ☐ AICc μόνο μεταξύ μοντέλων με ίδιο d , D και ίδιο δείγμα
- ☐ Φιλτράρισμα σε 2-3 φιναλίστ· η τελική απόφαση από backtesting
- ☐ Απλότητα ως tie-breaker

Ζ. Διαγνωστικά καταλοίπων

- ☐ Residual plot · ACF · Q-Q plot
- ☐ Ljung-Box ($h=2s$, σωστά df) — **$p > 0,05$ υποχρεωτικό**
- ☐ Ετεροσκεδαστικότητα (Breusch-Pagan) · ARCH-LM
- ☐ Δομική σταθερότητα (CUSUM)
- ☐ Εναπομείνασα εποχικότητα (ACF στο lag s)

K. Backtesting

- ☐ Rolling ή expanding origin· ≥ 12 origins
- ☐ Επανεκτίμηση παραμέτρων σε κάθε origin (ή δήλωση της συχνότητας)
- ☐ Gap/embargo αν τα δεδομένα οριστικοποιούνται με καθυστέρηση
- ☐ Σφάλμα αναφερόμενο ανά ορίζοντα h

L. Ακρίβεια πρόβλεψης

- ☐ MASE έναντι baseline — < 1 ;
- ☐ Μετρική συμβατή με το κόστος σφάλματος (MAE vs RMSE)
- ☐ Diebold-Mariano: είναι η διαφορά στατιστικά ουσιώδης;
- ☐ Έλεγχος ευστάθειας: κερδίζει σταθερά ή λόγω 1-2 origins;

M. Διαστήματα πρόβλεψης

- ☐ Παραγωγή 80% και 95% διαστημάτων
- ☐ Έλεγχος **εμπειρικής κάλυψης** στο backtest
- ☐ Αν η κάλυψη είναι χαμηλή → bootstrap ή empirical intervals

N. Ερμηνεία

- ☐ Μεγέθη σε ερμηνεύσιμες μονάδες, όχι μόνο p-values
- ☐ Ρητή διάκριση: predictive claim ή causal claim;
- ☐ Καταγραφή όλων των υποθέσεων και περιορισμών
- ☐ Ανάλυση ευαισθησίας στις βασικές επιλογές

O. Παρακολούθηση

- ☐ Κατώφλια σφάλματος που ενεργοποιούν επανεξέταση
- ☐ Πρόγραμμα επανεκτίμησης
- ☐ Παρακολούθηση για drift και δομικές αλλαγές
- ☐ Τεκμηρίωση: κώδικας, εκδόσεις δεδομένων, αποφάσεις — αναπαραγωγικότητα

ΚΕΦΑΛΑΙΟ 26 — Πέντε πλήρη case studies

Κάθε μελέτη ακολουθεί την ίδια ροή: **Πρόβλημα** → **Δεδομένα** → **Γράφημα** → **Διαγνωστικά** → **Στασιμότητα** → **Επιλογή μοντέλου** → **Εκτίμηση** → **Κατάλοιπα** → **Backtesting** → **Πρόβλεψη** → **Ερμηνεία**.

26.1 Μηνιαίες πωλήσεις φαρμακευτικού προϊόντος

Πρόβλημα: Πρόβλεψη πωλήσεων ενός αντιισταμινικού για τους επόμενους 12 μήνες, με σκοπό τον προγραμματισμό παραγγελιών και αποθέματος. Ορίζοντας απόφασης: $h = 3$ (lead time προμηθευτή) και $h = 12$ (ετήσιος προϋπολογισμός).

Δεδομένα: 84 μηνιαίες παρατηρήσεις (Ιαν 2018 – Δεκ 2024), μονάδες πωληθέντων κουτιών.

Γράφημα: Σαφής ανοδική τάση· έντονη κορυφή κάθε Απρίλιο-Μάιο (εποχή γύρης)· το εποχικό πλάτος *μεγαλώνει* με το επίπεδο· ορατή βύθιση Απρ-Ιουν 2020.

Διαγνωστικά: Rolling SD ανάλογο του rolling mean → πολλαπλασιαστική δομή. STL στους λογαρίθμους: $F_T = 0,88$, $F_S = 0,79$ — και οι δύο συνιστώσες ισχυρές. Το υπόλοιπο εμφανίζει ακραία τιμή τον Απρ 2020.

Στασιμότητα: Στο log επίπεδο, ADF (ct) $p = 0,41$ · KPSS $p < 0,01$ → μη στάσιμη. Μετά από εποχική διαφορά ($D=1$): ADF $p = 0,03$ · KPSS $p > 0,10$ → στάσιμη. **$d = 0$, $D = 1$** . (Ο κανόνας διακύμανσης επιβεβαιώνει: η πρώτη διαφορά επιπλέον αυξάνει τη Var.)

Υποψήφια: Seasonal naive (baseline) · ETS(M,A_d,M) · SARIMA(0,0,1)(0,1,1)₁₂ σε logs · SARIMA(1,0,0)(0,1,1)₁₂ · ensemble των δύο καλύτερων. Σε όλα προστίθεται COVID dummy.

```
df['covid'] = df['date'].between('2020-03-01', '2020-06-30').astype(int)
m = SARIMAX(np.log(y), exog=df[['covid']],
             order=(0,0,1), seasonal_order=(0,1,1,12)).fit(dispatch=False)
```

Κατάλοιπα: Ljung-Box(24) $p = 0,31$ ✓ · ACF εντός ζωνών · Q-Q με ελαφρώς παχιές ουρές · ARCH-LM $p = 0,22$ ✓.

Backtesting: Rolling origin, 24 origins, $h = 1...12$.

Μοντέλο	MASE (h=3)	MASE (h=12)	Συμπέρασμα
Seasonal naive	1,00	1,00	Benchmark
ETS(M,A _d ,M)	0,71	0,84	Πολύ καλό
SARIMA(0,0,1)(0,1,1) ₁₂	0,68	0,89	Καλύτερο σε βραχύ h
Ensemble (μέσος)	0,66	0,81	Επιλογή

Ερμηνεία: Το ensemble δίνει 34% βελτίωση έναντι seasonal naive στο $h=3$ και 19% στο $h=12$ — η επιδείνωση με τον ορίζοντα είναι αναμενόμενη. Η αβεβαιότητα στο $h=12$ είναι $\approx 2,5\times$ αυτής του $h=1$. Για παραγγελίες, χρησιμοποίησε το άνω όριο του 80% διαστήματος αν το κόστος έλλειψης υπερβαίνει το κόστος διακράτησης. **PREDICTIVE CLAIM MONO.**

26.2 Δημόσια φαρμακευτική δαπάνη

Πρόβλημα: Προβολή μηνιαίας δημόσιας φαρμακευτικής δαπάνης για 18 μήνες, με σκοπό την εκτίμηση υπέρβασης έναντι κλειστού προϋπολογισμού (clawback exposure).

Δεδομένα: 96 μήνες, € δαπάνη. **ΚΡΙΣΙΜΗ ΣΗΜΕΙΩΣΗ:** τα δεδομένα οριστικοποιούνται με καθυστέρηση 3-4 μηνών· το backtesting πρέπει να χρησιμοποιεί **gap = 3**.

Γράφημα: Ανοδική τάση με αλλαγή κλίσης το 2020· ήπια εποχικότητα (Δεκέμβριος υψηλός λόγω συσσώρευσης, Αύγουστος χαμηλός)· δύο απότομες πτώσεις που αντιστοιχούν σε ανατιμολογήσεις.

Διαγνωστικά & στασιμότητα: CUSUM βγαίνει εκτός ζωνών στα μέσα 2020 → δομική θραύση. Bai-Perron εντοπίζει break τον Απρ 2020 (ΔΕ: Φεβ-Ιουν 2020). ADF απορρίπτει, KPSS απορρίπτει → *αντίφαση* που εξηγείται από τη θραύση. Μετά από ρητή μοντελοποίηση της θραύσης με step dummy, $ADF(ct) p = 0,02$ · $KPSS p > 0,10$ → συμφωνία.

Η κρίσιμη μεθοδολογική απόφαση εδώ

Η φαρμακευτική δαπάνη είναι *ταυτότητα*: Δαπάνη = Όγκος × Τιμή. Πολύ πιο αξιόπιστη προσέγγιση από τη μοντελοποίηση της συνολικής δαπάνης είναι η **χωριστή πρόβλεψη όγκου και μέσης τιμής** — γιατί η τιμή μεταβάλλεται με *διοικητικές αποφάσεις* (γνωστές ή σεναριακές), ενώ ο όγκος έχει ομαλή στατιστική δυναμική. Η ανάμειξή τους σε μία σειρά αναμειγνύει προβλέψιμη με μη προβλέψιμη πληροφορία.

Μοντέλο: SARIMAX σε logs, με step dummy για τη θραύση, dummies για τις ανατιμολογήσεις, και αρμονικούς όρους για την ήπια εποχικότητα.

Backtesting: 18 origins με gap=3. $MASE(h=6) = 0,74$ · $MASE(h=18) = 0,93$ — οριακά καλύτερο από ναίνε σε μακρύ ορίζοντα, που είναι ειλικρινές εύρημα.

Ερμηνεία: Παρουσίαση σε **τρία σενάρια** (100/500/900 ποσοστημόριο) αντί για ένα διάστημα, καθένα συνδεδεμένο με υπόθεση για τιμολογιακή πολιτική. Η εκτιμώμενη υπέρβαση αναφέρεται ως εύρος, όχι ως αριθμός. **ΡΗΤΗ ΔΗΛΩΣΗ:** η προβολή ισχύει υπό αμετάβλητο θεσμικό πλαίσιο· κάθε νέα παρέμβαση την ακυρώνει.

26.3 Μηνιαίες νοσηλείες

Πρόβλημα: Πρόβλεψη μηνιαίων εισαγωγών σε παθολογική κλινική για προγραμματισμό προσωπικού και κλινών.

Δεδομένα: 72 μήνες, αριθμός εισαγωγών (μέσος 145/μήνα, εύρος 98-212). Πληθυσμός αναφοράς διαθέσιμος.

Απόφαση τύπου μοντέλου: Με μέσο 145, οι αριθμοί είναι αρκετά μεγάλοι ώστε η κανονική προσέγγιση να είναι αποδεκτή — αλλά έλεγχος υπερδιασποράς δίνει $Var/Mean = 3,8$, οπότε η επιλογή είναι **Negative Binomial GLM με χρονικούς όρους**, που σέβεται τη διακριτή φύση και δεν παράγει αρνητικές προβλέψεις.

```
import statsmodels.api as sm
X = sm.add_constant(pd.concat([
    df[['t']], # γραμμική τάση
    harmonics(df[['t']], period=12, K=2), # sin/cos k=1,2
    df[['flu_index', 'heat_days', 'holidays']] # εξωγενή
], axis=1))
m = sm.GLM(df[['admissions']], X,
           family=sm.families.NegativeBinomial(alpha=0.15),
           offset=np.log(df[['population']])).fit()
```

Διαγνωστικά: Pearson residuals χωρίς μοτίβο· Ljung-Box στα deviance residuals $p = 0,18$ ✓· έλεγχος υπερδιασποράς μετά την προσαρμογή ✓.

Backtesting: $MASE(h=1) = 0,61$ · $(h=6) = 0,88$. Ο χειμώνας προβλέπεται σαφώς χειρότερα από το καλοκαίρι — αναφέρεται χωριστά, γιατί εκεί ακριβώς χρειάζεται ο προγραμματισμός.

Ερμηνεία: Οι εκτιμήσεις παρουσιάζονται ως *ρυθμοί* ανά 1.000 κατοίκους. Για τον προγραμματισμό κλινών, το κρίσιμο μέγεθος δεν είναι ο μέσος αλλά το **90ό ποσοστημόριο** — η κάλυψη πρέπει να αντέχει τον κακό μήνα, όχι τον μέσο.

26.4 Επίδραση νέας πολιτικής αποζημίωσης (ITS)

Πρόβλημα: Είχε αποτέλεσμα η αλλαγή στον κατάλογο αποζημίωσης μιας θεραπευτικής κατηγορίας, που τέθηκε σε ισχύ τον Ιούνιο 2022; **ΑΙΤΙΑΚΟ ΕΡΩΤΗΜΑ — ΟΧΙ ΠΡΟΒΛΕΨΗ.**

Δεδομένα: 84 μήνες (Ιαν 2018 – Δεκ 2024): 41 πριν, 43 μετά. Διαθέσιμη **σειρά ελέγχου:** παρόμοια θεραπευτική κατηγορία που δεν επηρεάστηκε.

Προκαταρκτικοί έλεγχοι: Επαρκή σημεία εκατέρωθεν ✓ · Σαφής ημερομηνία ✓ · Σταθερή προ-τάση (οπτικός + έλεγχος γραμμικότητας) ✓ · **Ημερολόγιο συγχυτών:** COVID (Μαρ 2020), ανατιμολόγηση (Σεπ 2021), ανακοίνωση της πολιτικής (Μαρ 2022 — 3 μήνες πριν την εφαρμογή).

Απόφαση για την ημερομηνία

Επειδή η ανακοίνωση προηγήθηκε 3 μήνες, υπάρχει σοβαρός κίνδυνος *anticipation effect* (αποθεματοποίηση, εσπευσμένη συνταγογράφηση). Απόφαση: κύρια ανάλυση με ημερομηνία **ανακοίνωσης** (Μαρ 2022)· ανάλυση ευαισθησίας με ημερομηνία εφαρμογής και με εξαίρεση των τριών μηνών μετάβασης.

Μοντέλο (controlled ITS σε logs, με HAC standard errors):

$$\log Y_t = \beta_0 + \beta_1 T + \beta_2 I + \beta_3 TA + \beta_4 G + \beta_5 (G \times T) + \beta_6 (G \times I) + \beta_7 (G \times TA) + \text{αρμονικοί} + \text{COVID} + \varepsilon_t$$

Συντελεστής	Εκτίμηση [95% ΔΕ]		Ερμηνεία
$\beta_6 (G \times I)$	-0,094 [-0,151, -0,037]		Άμεση μείωση επιπέδου 9,0% στην ομάδα παρέμβασης, <i>πέραν</i> ό,τι συνέβη στην ομάδα ελέγχου
$\beta_7 (G \times TA)$	-0,0018 [-0,0031, -0,0005]		Επιπλέον μείωση 0,18 π.μ. στον μηνιαίο ρυθμό. Με $\beta_1 + \beta_5 = +0,004$, η νέα τάση της ομάδας παρέμβασης είναι $\approx +0,22\%$ /μήνα

Διαγνωστικά: Ljung-Box $p = 0,24$ μετά τη HAC διόρθωση ✓ · Breusch-Pagan $p = 0,08$ ✓ · **Placebo test** με ψευδή ημερομηνία Μαρ 2021: β_6 μη σημαντικός ($p = 0,62$) ✓ — ισχυρή ένδειξη ότι το κύριο εύρημα δεν είναι θόρυβος.

Μέγεθος επίδρασης: Σωρευτική διαφορά έναντι του αντιπαραδείγματος στους 24 μήνες: **-14,8%** [-21,3%, -8,1%] της δαπάνης, δηλαδή περίπου Χ εκατ. € σε απόλυτους όρους.

Πώς διατυπώνεται το συμπέρασμα

«Η πολιτική συνδέεται με άμεση μείωση 9,0% [3,7-15,1%] στο επίπεδο δαπάνης και με περαιτέρω επιβράδυνση του ρυθμού αύξησης. Η δαπάνη *εξακολουθεί να αυξάνεται*, με ρυθμό περίπου μισό του προηγούμενου. Η σωρευτική εξοικονόμηση έναντι του αντιπαραδείγματος στους 24 μήνες εκτιμάται σε 14,8%. Το controlled σχέδιο και το placebo test ενισχύουν την αιτιακή ερμηνεία· παραμένει η υπόθεση ότι καμία άλλη παρέμβαση δεν επηρέασε *διαφορετικά* τις δύο ομάδες στην ίδια περίοδο.»

CAUSAL CLAIM, ΜΕ ΔΗΛΩΜΕΝΟΥΣ ΠΕΡΙΟΡΙΣΜΟΥΣ.

26.5 Πληθωρισμός και φαρμακευτική δαπάνη

Πρόβλημα: Υπάρχει μακροχρόνια σχέση μεταξύ γενικού πληθωρισμού και φαρμακευτικής δαπάνης; Και αν ναι, πόσο γρήγορα προσαρμόζεται;

Δεδομένα: 120 μήνες: log δείκτη τιμών καταναλωτή, log πραγματικής φαρμακευτικής δαπάνης, log ΑΕΠ (τριμηνιαίο, παρεμβληθέν με προσοχή και ρητή δήλωση).

Βήμα 1 — Τάξη ολοκλήρωσης: ADF/KPSS και στις τρεις σειρές: όλες I(1) σε επίπεδα, I(0) σε πρώτες διαφορές. Καμία I(2) ✓

Βήμα 2 — Συνολοκλήρωση: Johansen με $p=3$ lags (επιλογή AICc), προδιαγραφή με περιορισμένη σταθερά. Trace test: $r=0$ απορρίπτεται ($p<0,01$)· $r\leq 1$ δεν απορρίπτεται ($p=0,18$) → **$r = 1$** .

Βήμα 3 — VECM με $r=1$:

Παράμετρος	Εκτίμηση	Ερμηνεία
Διάλυσμα συνολοκλήρωσης β	δαπάνη — 0,82·CPI — 0,41·ΑΕΠ	Μακροχρόνια ελαστικότητα δαπάνης ως προς τιμές $\approx 0,82$ — υπο-μοναδιαία, συμβατή με την ύπαρξη διοικητικών ελέγχων τιμών
α (ταχύτητα προσαρμογής, εξίσωση δαπάνης)	-0,11 ($p<0,01$)	11% της απόκλισης διορθώνεται μηνιαίως· χρόνος ημιζωής $\approx 5,9$ μήνες
α (εξίσωση CPI)	-0,01 ($p=0,71$)	Ο πληθωρισμός δεν προσαρμόζεται στη δαπάνη → η δαπάνη είναι η μεταβλητή που «επιστρέφει», ασθενής εξωγένεια του CPI

Ευαισθησία: Επανάληψη με $p=2$ και $p=4$ lags, και με τις πέντε προδιαγραφές ντετερμινιστικών όρων. Το $r=1$ και το πρόσημο του α παραμένουν σταθερά· η ακριβής τιμή της ελαστικότητας κυμαίνεται 0,74-0,89. **Αυτό αναφέρεται.**

Granger causality: Ο CPI Granger-προκαλεί τη δαπάνη ($p<0,01$)· όχι το αντίστροφο ($p=0,44$).

Η διατύπωση που πρέπει να χρησιμοποιήσεις

«Οι δύο σειρές είναι συνολοκληρωμένες: υπάρχει σταθερή μακροχρόνια σχέση με ελαστικότητα $\approx 0,8$, και οι αποκλίσεις διορθώνονται με χρόνο ημιζωής περίπου 6 μηνών. Οι υστερήσεις του πληθωρισμού βελτιώνουν την πρόβλεψη της δαπάνης, όχι το αντίστροφο. Αυτό είναι *εύρημα μακροχρόνιας συνδιακύμανσης και προβλεψιμότητας* — δεν αποδεικνύει ότι μια μεταβολή του πληθωρισμού προκαλεί μεταβολή της δαπάνης, καθώς και τα δύο μπορεί να ανταποκρίνονται σε κοινούς μακροοικονομικούς ή θεσμικούς παράγοντες.» **ASSOCIATION + PREDICTION — OXI CAUSALITY.**

ΕΛΕΓΧΟΣ ΚΑΤΑΝΟΗΣΗΣ — Τεύχος Ε΄

A. Διαγνωστικά & αβεβαιότητα

1. Jarque-Bera $p = 0,002$ αλλά Ljung-Box $p = 0,45$. Είναι το μοντέλο χρησιμοποιήσιμο; Τι επηρεάζεται και τι όχι;
2. Τα κατάλοιπα δείχνουν μέσο $+2,3\%$ συστηματικά. Δούλεψες σε logs. Τι πιθανότατα συνέβη;
3. Γιατί ένα 95% διάστημα πρόβλεψης έχει τυπικά εμπειρική κάλυψη 70–85%; Ανάφερε τρεις πηγές που αγνοεί ο τύπος.

B. Εφαρμογή του decision tree

1. Εβδομαδιαία ζήτηση 800 κωδικών φαρμακείου, οι 550 με $ADI > 2$. Διάτρεξε το decision tree και κατέληξε σε στρατηγική.
2. Τριμηνιαία δεδομένα, 40 παρατηρήσεις, δύο μεταβλητές $I(1)$ με συνολοκλήρωση, ερώτημα προβλεπτικό. Ποιο μοντέλο και γιατί όχι VECM;

Γ. Κριτική των case studies

1. Στο 26.2 προτείνεται χωριστή πρόβλεψη όγκου και τιμής. Δώσε δύο λόγους και ένα μειονέκτημα.
2. Στο 26.4, γιατί η επιλογή της ημερομηνίας ανακοίνωσης αντί εφαρμογής είναι μεθοδολογικά σημαντική — και τι θα συνέβαινε αν την αγνοούσες;
3. Στο 26.5, η ελαστικότητα κυμαίνεται 0,74–0,89 ανάλογα με τις επιλογές. Πώς το αναφέρεις σε policy brief χωρίς να υπονομεύσεις το εύρημα;
4. Στο 26.1 το ensemble κερδίζει και τα δύο επιμέρους μοντέλα. Εξήγησε τον μηχανισμό.
5. Ποια από τα 20 λάθη του Κεφ. 23 αποφεύγονται ρητά στο case study 26.4; Εντόπισε τουλάχιστον πέντε.

Επόμενο και τελευταίο βήμα

Το **Τεύχος ΣΤ΄** ολοκληρώνει το πρόγραμμα με τα Μέρη 27–29: την **παρουσίαση 30–40 διαφανειών** (τίτλος, bullets, βασικό μήνυμα, τύποι, προτεινόμενο γράφημα και speaker notes ανά slide, με ροή Beginner → Intermediate → Advanced → Real-world), το **Exam Mode** με 20 ερωτήσεις πολλαπλής επιλογής, 10 εννοιολογικές, 5 προβλήματα επιλογής μοντέλου και 5 ασκήσεις ερμηνείας — χωρίς απαντήσεις, για βαθμολόγηση αφού απαντήσεις — και το μονοσέλιδο **Cheat Sheet** με τη ροή Πρόβλημα → Test → Ερμηνεία → Μοντέλο → Διαγνωστικό → Επόμενο βήμα.